

기계학습

Chap 1. 지도학습 입문

김용대¹

서울대학교 통계학과¹

목차

- 1절: 기계학습이란?
- 2절: 지도학습의 기본 모형
- 3절: 선형모형부터 Nearest Neighborhood까지
- 4절: 의사결정이론 (Decision theory)
- 5절: 차원의 저주 (Curse of Dimensionality)
- 6절: 과적합 (Overfitting)
- 7절: 지도학습의 4가지 경우

1절: 기계학습이란

전통적인 학습과 기계학습

- 전통적인 학습
 - 자료의 관측이나 직관으로 가설 설정
 - 실험 및 통계추론
 - 결론 도출
- 기계학습
 - 데이터를 모은다.
 - 데이터를 분석한다.
 - 새로운 지식을 찾는다.

“Let the data tell something.”

왜 기계학습이 필요한가?

- 우리가 상상할 수 있는 것은 거의 대부분 알아냈다.
- 인간 (생물학, 의학, 심리학, 뇌과학, 경제학 등)은 자연보다 훨씬 복잡하다.
- 세상이 너무 빨리 변한다.
- IT기기의 발달로 데이터가 빠르게 증가한다.
- 데이터를 분석했더니 새로운 지식이 나오더라.

기계학습으로 풀 수 있는 문제들

- 심장마비의 원인이 뭐지?
- 인종별로 뭐가 다르지?
- 주가는 왜 움직이지?
- 누가 우리 회사에 도움이 되는 고객이지?
- 개하고 고양이를 어떻게 구별하지?
- 음성을 어떻게 인식하지?
- 바둑에서 어떻게 하면 이기지?

데이분석 관점에서의 기계학습

- 고차원 자료 분석: 차원의 저주 극복
- 자료간의 복잡한 관계 규명
- 복잡한 비선형 관계 규명

기계학습의 여러 분야

- 지도학습 (Supervised learning)
 - 입력변수를 이용해서 출력변수를 예측
 - 예: 회귀분석, 분류분석
 - 응용: 이미지분류, 고장 원인 파악, 암 진단
- 비지도학습 (Unsupervised learning)
 - 데이터간의 복잡한 관계를 규명 (출력변수가 없음)
 - 예: 군집분석, 주성분분석, 결합분포추정 (예: 요인분석)
 - 응용: 차원축소, 이미지 압축/생성, Source 분해
- 강화학습
 - 행동에 따라 변화하는 환경에서 최적의 의사결정 방법을 학습
 - 예: Multi-armed badit problem, Markov decision process
 - 응용: AlphaGo, 각종 게임, 로봇

2절: 지도학습의 기본 모형

기본 모형

- 입력(Input, Covariate) : $\mathbf{x} \in \mathbb{R}^p$
- 출력 (Output, Response) : $y \in \mathcal{Y}$
- 시스템 (System, Model): $y = \phi(\mathbf{x}, \epsilon)$
- 손실함수 (Loss function): $l(y, a)$
- 가정 (Assumption) : f belongs to a family of functions $\mathcal{F}$.
- 학습자료 (Training data): $\mathcal{L} = \{(y_i, \mathbf{x}_i), \ i = 1, \dots, n\}$ assumed to be a random sample of $(Y, \mathbf{X}) \sim P$
- 목적: Find $f^0 = \arg \min_{f \in \mathcal{F}} \mathbb{E}_{(Y, \mathbf{X})} l(Y, f(\mathbf{X}))$.
- 예측모형: $\hat{f}(\mathbf{x}) = f(\mathbf{x}, \mathcal{L})$.
- 예측: If new input is $\mathbf{x}_{\text{new}}$, predict unknown y_{new} by $\hat{f}(\mathbf{x}_{\text{new}})$.

y	is	categorical	$\Rightarrow$	Classification
	is	continuous	$\Rightarrow$	Regression

3절: 선형회귀모형 부터 NN (Nearest Neighbor)까지

선형모형

- 가정 : $f(\mathbf{x}) \in \{\beta_0 + \sum_{i=1}^p x_i \beta_i\}$
- Estimate $\beta = (\beta_0, \beta_1, \dots, \beta_p)$ by $\hat{\beta}$ which minimizes the residual sum of square

$$RSS(\beta) = \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{k=1}^p x_{ki} \beta_k \right)^2 .$$

- $f(\mathbf{x}, \mathcal{L}) = \hat{\beta}_0 + \sum_{i=1}^p x_i \hat{\beta}_i.$

NN

- $N_k(\mathbf{x})$: the neighborhood of $\mathbf{x}$ defined by the k closest points $\mathbf{x}_i$ in the training sample.
-

$$f(\mathbf{x}, \mathcal{L}) = \frac{1}{k} \sum_{\mathbf{x}_i \in N_k(\mathbf{x})} y_i.$$


Simulation 1

- 모형: $y = x + \epsilon$ and $\epsilon \sim N(0, 1)$.
- 학습자료 크기는 100이고 예측에러는 크기가 5000인 예측자료에서 계산.
- 결과


Method	Training error	Test error
Linear	0.8247196	3.395535
1 NN	0.0000000	3.915410
5 NN	0.7080551	3.434624
15 NN	0.8412333	3.400420

그림


Linear Regression




Nearest Neighbor with k= 1



Nearest Neighbor with k= 5



Nearest Neighbor with k= 15




Simulation 2


- 모형: $y = x(1 - x) + \epsilon$ and $\epsilon \sim N(0, 1)$.
- 학습자료 크기는 100이고 예측에러는 크기가 5000인 예측자료에서 계산.
- 결과

Method	Training error	Test error
Linear	3.3307623	3.051589
1 NN	0.0000000	1.892876
5 NN	0.9872481	1.387429
15 NN	2.1303585	2.069501


Linear Regression




Nearest Neighbor with $k=1$



Nearest Neighbor with $k=5$



Nearest Neighbor with $k=15$



주목할 사항

- 선형모형은 참모형이 선형모형이 경우에 가장 좋고, 선형모형이 아니면 매우 나쁜 결과를 준다.
- NN은 참모형이 선형이건 비선형이건 적당히 좋은 예측력을 보인다.
- 학습에러는 예측에러의 좋은 추정량이 아니다.
- 복잡한 모형이 항상 좋은 예측력을 갖는 것은 아니다.
- Neighborhood개수 k 는 예측모형의 복잡도를 결정한다.

선형모형과 NN의 비교

	선형모형	NN
가정	선형	없음
자료크기	작거나 중간정도	커야함
해석	쉽다	거의 불가능
예측력	참모형이 선형이면 좋다	참모형에 상관없이 적당히 좋다
조절(tuning) 모수	없다	neighborhood의 크기

4절: 의사결정이론 (Decision Theory)

회귀모형

- 학습자료 $\mathcal{L}$ 은 분포 $P(y, \mathbf{x})$ 를 따르는 모집단에서의 임의추출된 자료라고 하자.
- $l(y, f(\mathbf{x}))$ 는 손실함수인데, 주로 제곱손실함수가 많이 사용된다: $l(y, f(\mathbf{x})) = (y - f(\mathbf{x}))^2$.
- 주어진 예측모형 f 의 기대예측에러 (Expected Predictive Error) ($EPE(f)$)는 다음과 같이 정의된다:

$$EPE(f) = \mathbb{E}(Y - f(\mathbf{X}))^2$$

이고 여기서 $(Y, \mathbf{X}) \sim P(y, \mathbf{x})$.

- 정리 : $f^0(\mathbf{x}) = \mathbb{E}(Y|\mathbf{X} = \mathbf{x})$ 는 $EPE(f)$ 를 최소로 한다.
- $\mathbb{E}(Y|\mathbf{X} = \mathbf{x})$ 를 회귀함수 (regression function)이라고 부른다.

NN방법의 이해: Local 적률추정량

- 예측모형 f 를 $\hat{f}$ 으로 추정하는데

$$\hat{f}(\mathbf{x}) = \text{Ave}(y_i | \mathbf{x}_i \in N_k(\mathbf{x})).$$

- 여기에는 두가지 근사가 사용되어졌는데
 - 기대값이 자료의 평균으로 근사되었고,
 - 조건부 확률이 목표 지점 $\mathbf{x}$ 의 neighborhood로 근사되었다.
- 가정: 적당한 조건하에서, 모든 $\mathbf{x} \in \mathbb{R}^p$ 에 대하여 $n, k \rightarrow \infty$ 이고 $k/n \rightarrow 0$ 이면

$$\hat{f}(\mathbf{x}) \rightarrow f^0(\mathbf{x}).$$

- 조건 $k/n \rightarrow 0$ 은 모형 복잡도가 자료의 크기보다는 천천히 증가하여야 한다는 것을 의미한다.

최소제곱추정량의 이해: Empirical risk minimization

- 먼저 기대예측에러

$$\mathbb{E}(Y - f(\mathbf{X}))^2$$

을 empirical risk

$$\sum_{i=1}^n (y_i - f(\mathbf{x}_i))^2 / n$$

으로 추정한다.

- $f(\mathbf{x})$ 를 $\beta_0 + \sum_{j=1}^p \beta_j x_j$ 로 바꾼다.
- Empirical risk를 최소로 하는 회귀계수를 구한다:

$$\sum_{i=1}^n (y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij})^2 / n.$$

(*) 기대예측에러는 population risk라고도 부른다.

분류모형

- $y \in \{1, \dots, J\}$.
- 주어진 손실함수 l 에 대하여 기대예측에러 (EPE) 는 $\mathbb{E}(l(Y, f(\mathbf{X})))$ 이다.

-

$$EPE(f) = E_{\mathbf{X}} \sum_{j=1}^J l(j, f(\mathbf{X})) P(Y = j | \mathbf{X})$$

이므로 $f(\mathbf{x}) = \arg \min_{k=1, \dots, J} \sum_{j=1}^J L(j, k) P(Y = j | \mathbf{X} = \mathbf{x})$ 가 기대예측에러를 최소화한다.

- 만약 $l(y, f(\mathbf{x})) = I(y \neq f(\mathbf{x}))$ 이면, 최적예측모형 $f(\mathbf{x})$ 는

$$f(\mathbf{x}) = \max_{j=1, \dots, J} P(Y = j | \mathbf{X} = \mathbf{x}). \quad (1)$$

- 이러한 예측모형을 베이즈규칙 (Bayes rule, 베이즈분류모형, Bayes classifier)이라고 하고, 이때의 기대예측에러를 베이즈위험 (Bayes risk)라고 한다.

베이지스규칙의 추정

- 베이지스규칙은 확률을 추정하여 간접적으로 추정할 수 있다:
 - 먼저 $\phi_j(\mathbf{x}) = P(Y = j | \mathbf{X} = \mathbf{x})$ 을 추정한다.
 - (1)에 있는 확률 $P(Y = j | \mathbf{X} = \mathbf{x})$ 을 추정량을 대체한다.
 - ϕ_j 의 NN추정량은 다음과 같이 주어진다:

$$\hat{\phi}_j(\mathbf{x}) = \frac{1}{k} \sum_{\mathbf{x}_i \in N_k(\mathbf{x})} I(y_i = j).$$




- 선형모형은 ϕ_j 를 추정하는데 적합하지 않은데, 그 이유로는 ϕ_j 는 0과 1사이의 값을 가져야 하기 때문이다.
로지스틱회귀모형이 유용한 대안이다.

5절: 차원의 저주 (Curse of Dimensionality)

Phenomenon

- p 가 크면 국소평균 (local average)의 개념이 좋지 않다.
- $\mathbf{X} = (X_1, \dots, X_p) \sim \text{Uniform}[0, 1]^p$
- 목표지점 $\mathbf{x}$ 에서의 hypercube를 생각하자.
- Hypercube를 통해서 $r * 100\%$ 만큼의 자료를 모으고 싶다.
- 이 경우 hypercube의 각 변의 길이는 $e_p(r) = r^{1/p}$ 이 된다.
- $e_{10}(0.01) = 0.63$ 이고 $e_{10}(0.1) = 0.80$.
- 즉 국소평균을 구하기 위해서 1% 또는 10%의 자료를 사용하기 위하여는 hypercube의 각 변이 전체 길이의 63% or 80%를 차지해야 한다.
- 이러한 hypercube는 더이상 “local”의 성질을 가지고 있지 않다.

Phenomenon



6절: 과적합 (Overfitting)

과적합이란?

- 앞에서 보았 듯이, NN에서 neighborhood의 크기 k 가 예측모형의 복잡도를 조절한다. 질문은 k 을 어떻게 결정하느냐이다.
- 만약 모집단의 분포 $P(y, \mathbf{x})$ 가 알려져 있으면, 기대예측에러 EPE를 가장 작게하는 k 를 정하면 된다.
- 하지만, 모집단의 분포 $P(y, \mathbf{x})$ 는 알 수가 없다.
- 단순한 아이디어는 neighborhood크기 k 로 구한 예측모형 $\hat{f}_k$ 의 기대예측에러를 학습에러로 구하는 것이다:

$$\frac{1}{n} \sum_{i=1}^n (y_i - \hat{f}_k(\mathbf{x}_i))^2.$$

과적합이란?

- 학습에러는 항상 예측에러보다 작게 추정이 되는데, 그 이유는 자료를 모형구축과 에러추정에 두번 사용하였기 때문이다.
- 또한, 학습에러는 k 가 작아질 수록 계속 감소하는데 반하여, 예측에러는 처음에는 감소하나 일정값 이하에서는 다시 증가한다.
- 즉, 학습에러를 너무 작게 만드는 모형은 예측에러가 나빠질 수 있다는 것이고, 이러한 현상을 과적합(overfitting)이라고 한다.
- 과적합현상은 편의-분산 균형 (Bias-variance trade off)으로 설명할 수 있다.

편의-분산 균형

- 회귀모형 $Y = f(\mathbf{X}) + \epsilon$ with $\mathbb{E}(\epsilon) = 0$ and $\text{Var}(\epsilon) = \sigma^2$ 을 고려하자.
- 주어진 학습자료 $\mathcal{L}$ 에 대하여 예측모형 $f(\mathbf{x}, \mathcal{L})$ 의 **평균예측에러**는 다음과 같이 주어진다:

$$TE = \mathbb{E}_{\mathcal{L}} \mathbb{E}_{(Y, \mathbf{X})} ((Y - f(\mathbf{X}, \mathcal{L}))^2).$$

- 이 예측에러는 다음과 같이 분해할 수 있다:

$$\begin{aligned} TE &= \mathbb{E}_{(Y, \mathbf{X})} ((Y - f(\mathbf{X}))^2) + \mathbb{E}_{\mathbf{X}} \{ (f(\mathbf{X}) - \mathbb{E}_{\mathcal{L}}(f(\mathbf{X}, \mathcal{L})))^2 \} \\ &\quad + \mathbb{E}_{\mathbf{X}} \{ \mathbb{E}_{\mathcal{L}}(f(\mathbf{X}, \mathcal{L}) - \mathbb{E}_{\mathcal{L}}(f(\mathbf{X}, \mathcal{L})))^2 \} \\ &= \sigma^2 + \mathbb{E}_{\mathbf{X}} (\text{Bias}_{\mathcal{L}}(\mathbf{X})^2 + \text{Variance}_{\mathcal{L}}(\mathbf{X})). \end{aligned}$$

- 일반적으로 모형이 복잡하면 편의는 줄고 분산은 증가한다.

예: k -NN 방법


- $f(\mathbf{x}, \mathcal{L}) = \sum_{l=1}^k (f(x_{(l)}) + \epsilon_{(l)})/k$. 여기서 아래첨자 (l) 은 nearest neighbor에 있는 관측치들을 나타낸다.
- 그러면 편의와 분산은 다음과 같이 주어진다:

$$\text{Bias}_{\mathcal{L}}(\mathbf{x}) = f(\mathbf{x}) - \frac{1}{k} \sum_{l=1}^k f(x_{(l)})$$

and

$$\text{Variance}_{\mathcal{L}}(\mathbf{x}) = \frac{\sigma^2}{k}.$$

- $k = 1$ 일때 편의는 최소화되고 분산은 가장 커진다. 반면에 $k = n$ 이면 편이가 가장 커지고 분산이 가장 작아진다.



Thank you!!