
기계학습

2강: 선형회귀모형

김용대

서울대학교 통계학과

목차

1. 선형회귀모형
 2. 선형로지스틱회귀모형
 3. 모형선택
-

1. 선형회귀모형

회귀분석 (Regression Analysis)

- 회귀분석

- 출력 변수와 입력 변수의 관계를 모형화하는 방법.


- 회귀모형

- $Y = f(X) + \epsilon$, (ϵ 는 error)

- 데이터

- $(y_1, x_1), \dots, (y_n, x_n)$, where $y_i \in \mathbb{R}$ and $x_i \in \mathbb{R}^p$.

- 목적 : 데이터로부터 함수 f 를 추정



선형 회귀 분석


- 선형회귀모형

- 입력 변수와 출력 변수의 관계가 선형방정식

- 비교 : 비선형 회귀모형(예 : $Y = \sin(2x) + \epsilon$)


- 선형회귀모형:

- $Y = x^T \beta + \epsilon, (\beta = (\beta_1, \beta_2, \dots, \beta_p)^T)$



최소 제곱 추정

- 계수 추정 (최소 제곱 추정)
 - β : 회귀계수 $\rightarrow \beta$ 를 추정해서 f 를 추정한다.



$-(y_1, x_1), \dots, (y_n, x_n)$

–최소 제곱 추정방법

$$\hat{\beta} = \operatorname{argmin}_{\beta} \sum_{i=1}^n (y_i - x_i^T \beta)^2$$



Adrien-Marie Legendre, 1806

예측 및 해석

- 예측 및 모형의 해석

- 예측

- 주어진 새로운 입력 변수 x 에 대하여 출력 변수 y 를 $\hat{y}$ 로 예측한다.

- $\hat{y} = x^T \hat{\beta}$

- 모형의 해석

- β_j : x_j 가 한 단위 증가할 때의 y 의 증가량
 - $\beta_j > 0$ 이면 x_j 가 증가하면서 y 가 증가
 - $\beta_j < 0$ 이면 x_j 가 증가하면서 y 가 감소

선형 회귀 분석

- 예제

A건설회사가 고객에게 주로 받는 질문은 겨울에 난방비가 얼마나 나오는가 하는 것이다. 이 질문에 답하기 위하여 A건설회사는 20개의 아파트를 임의로 추출하여 다음의 3가지 항목을 조사하였다.

- 1. 겨울의 평균온도
- 2. 방열재의 두께
- 3. 아파트 나이

선형 회귀 분석

- 예제

- 회귀계수의 추정.

입력변수	회귀계수	표준오차	T	유의확률
절편	427.19	59.60	7.17	0.000
온도	-4.5827	0.7723	-5.93	0.000
방열재	-14.831	4.754	-3.12	0.007
나이	6.101	4.012	1.52	0.148

선형 회귀 분석

- 예제

- 회귀추정식

$$Y = 427 - 4.58X_1 - 14.80X_2 + 6.10X_3$$

- 해석

- 평균온도 1도가 떨어지면 난방비가 4.58단위 증가한다.
 - 방열재의 두께가 1단위 증가하면 난방비가 14.80단위 감소한다.
 - 아파트의 나이가 1년 증가하면 난방비가 6.10단위 증가한다.

2. 선형로지스틱회귀모형

선형로지스틱회귀모형

- 로지스틱 회귀 모형
 - 출력변수가 범주형 변수인 경우(분류문제)에 사용하는 대표적인 회귀모형
 - 범주가 2가지인 경우를 고려하자.
 - $Y = 1$: 출력변수가 첫 번째 범주에 속할 경우.
 - $Y = 0$: 출력변수가 두 번째 범주에 속할 경우.
 - 목적 : 입력변수와 범주형 출력변수간의 관계를 잘 표현할 수 있는 모형 구축

선형로지스틱 회귀 분석

- 모형
 - $P(Y = 1 | X) = F(X^T \beta)$
 - $F(x)$ 는 연속이고 증가하며 0과 1사이에서 값을 갖는 함수
- 여러 가지 $F(x)$
 - 로지스틱 모형: $F(x) = \exp(x) / (1 + \exp(x))$
 - 곱배르츠 모형: $\exp(-\exp(x))$
 - 프로빗 모형: $F(x)$ 가 표준정규분포의 분포함수(distribution function)

선형로지스틱 회귀 분석

- 이중 로지스틱 모형이 계산의 편의성으로 가장 널리 사용됨
- 로지스틱회귀모형
 - $P(Y = 1|X = x) = \frac{\exp(x^T \beta)}{1 + \exp(x^T \beta)}, \quad (\beta = (\beta_1, \beta_2, \dots, \beta_p)^T)$
 - i.e. $\log \left(\frac{P(Y = 1|X = x)}{P(Y = 0|X = x)} \right) = x^T \beta$ (로그오즈가 선형)

선형로지스틱 회귀 분석

- 모수의 추정 (최대 가능도 추정량)
 - 모수 : β
 - 자료 : $(y_1, x_1), \dots, (y_n, x_n)$
 - 최대 가능도 추정량(Maximum likelihood estimator) $\hat{\beta}$
 - 가능도 함수를 최대로 하는 모수값
 - 가능도함수:
 - $L(\beta) = \prod_{i=1}^n F(x_i^T \beta)^{y_i} \times (1 - F(x_i^T \beta))^{1-y_i}$ where $F(x) = \frac{\exp(x)}{1+\exp(x)}$
 - 가능도 함수의 최대화는 수치적 방법(numerical method)를 사용하여 구한다.
 - 예 : Newton-Raphson방법

선형로지스틱 회귀 분석

- 예측 및 모형의 해석

- 예측

- $\hat{P}(Y = 1|X = x) = \frac{\exp(\widehat{\beta}_0 + \widehat{\beta}_1 x)}{1 + \exp(\widehat{\beta}_0 + \widehat{\beta}_1 x)}$
 - $\hat{P}(Y = 1|X = x) > 0.5$ 이면 1로 예측
 - $\hat{P}(Y = 1|X = x) < 0.5$ 이면 0으로 예측

- 해석

- $\beta_1 > 0$: x 가 증가하면 $P(Y = 1|X = x)$ 가 증가한다.
 - $\beta_1 < 0$: x 가 증가하면 $P(Y = 1|X = x)$ 가 감소한다.

선형로지스틱 회귀 분석

- 회귀계수와 오즈비

- 오즈(odds)

$$\text{오즈}(x) = \Pr(Y=1|x) / \Pr(Y=0|x)$$

- 오즈비 (odds ratio)

$$\text{오즈비}(x) = \Pr(Y=1|x+1) \Pr(Y=0|x) / \Pr(Y=0|x+1) \Pr(Y=1|x)$$

- 성질

$$\text{오즈비}(x) = \exp(\beta)$$

선형로지스틱 회귀 분석

- 오즈비의 의미

- x 가 한 단위 증가 할 때 $y=1$ 일 확률과 $y=0$ 일 확률의 비가 증가하는 양
- 예
 - x 는 소득이고 y 는 어떤 상품에 대한 구입여부(1=구입,0=미구입)
 - $b=3.72$
 - 소득이 한 단위 증가하면 물품을 구매하지 않을 확률에 대한 구매할 확률의 비(오즈비)가 $\exp(3.72)=42$ 배 증가함을 의미한다.

선형로지스틱 회귀 분석

- 예제

- 회사채의 신용등급(안정, 위험)과 여러 가지 재무자료들 사이의 관계를 규명한다.

- 입력변수: 여러 재무자료

- x1: 자산대비 부채현황 지표

- x2 : 현금회전율

- x3: 종업원 수(50인 이하=0, 50-100인=1, 100인 이상=2)

- 출력변수: 회사채 신용등급: 안정=1, 위험=0

선형로지스틱 회귀 분석

- 예제: 가변수 생성

- x_3 변수가 질적변수 이므로 가변수가 필요하다.
- x_3 를 위한 가변수 z_1 과 z_2

	z_1	z_2
50인 이하	0	0
50-100인	1	0
100인 이상	0	1

선형로지스틱 회귀 분석

- 예제: 회귀계수 추정

회귀계수의 추정 결과는 다음과 같다.

입력변수	회귀계수	표준오차	Chi-square	유의확률
Intercept	12.2216	3.5942	11.5623	0.000
X1	-1.0727	0.3933	7.4389	0.006
X2	11.5243	4.1313	7.7814	0.005
X3-1	0.6981	0.3571	3.9404	0.047
X3-2	2.6141	0.7915	10.9078	0.001

선형로지스틱 회귀 분석

- 예제: 결과 해석

- X_1 의 회귀계수의 부호가 음수인데, 이는 부채비율이 높을 수록 회사채의 신용이 낮음을 의미한다.
- X_2 의 회귀계수의 부호가 양수인데, 이는 현금회전율이 높을 수록 회사채의 신용이 높아짐을 의미한다.
- X_3-1 과 x_3-2 는 가변수 z_1 과 z_2 의 회귀계수의 추정치를 나타낸다.

선형로지스틱 회귀 분석

- 예제: 결과 해석 (이어서)

- X3-1의 회귀계수로부터 50-100인 규모의 회사와 50인 미만의 회사의 회사채 신용등급의 오즈비를 구할 수 있다. 이는 $\exp(0.6981)=2.00$ 으로 50-100인 규모의 회사의 회사채가 50인 미만의 회사채에 비하여 약 2배정도 신용이 좋다고 볼 수 있다.
- 마찬가지로, X3-2의 회귀계수로부터 100인 이상 규모의 회사와 50인 미만의 회사의 회사채 신용등급의 오즈비를 구할 수 있다. 이는 $\exp(2.6141)=13.65$ 으로 100인 이상 규모의 회사의 회사채가 50인 미만의 회사채에 비하여 약 13.65배정도 신용이 좋다고 볼 수 있다.

3. 변수선택

변수선택

- 변수의 선택
 - 일반적으로 많은 입력 변수 중에서 출력 변수에 영향을 미치는 변수는 그리 많지 않다.
 - 목표:
 - 많은 입력 변수 중에서 출력 변수에 영향을 미치는 소수의 입력 변수를 찾아내는 것

변수선택

- 변수선택이 필요한 이유
 - 많은 입력 변수를 관리하는데 필요한 노력과 비용 절약
 - 적절한 모형의 복잡도(변수의 개수) 유지로 **예측 오차 감소** 가능
- ▣ 유의한 입력변수를 모형에 넣지 않으면, 중요한 정보를 놓칠 수 있으며, 또한 그 결과가 편향된다.

변수선택

- 단변량 변수선택 방법의 문제점
 - 각 입력변수와 출력변수와의 상관계수를 구하고, 이 상관계수의 절대값이 큰 순서대로 변수를 선택한다.
 - 다음의 문제점 때문에 이러한 단순한 방법은 올바른 변수를 선택하지 못한다.
 - 다중공선성 (Multicollinearity)

다중공선성

- 다중공선성 예제

예제: 월소득(X1)과 가구원수(X2)가 월저축액(Y)에 미치는 영향
단변량 회귀분석 결과

	비표준화계수		유의확률
	B	표준오차	
월소득	.205	.035	.000

	비표준화계수		유의확률
	B	표준오차	
가구인원수	1.625	1.182	.206

다중공선성

- 다중공선성 예제

예제: 월소득(X1)과 가구원수(X2)가 월저축액(Y)에 미치는 영향

다변량 회귀분석 결과

	비표준화계수		유의확률
	B	표준오차	
월 소득	.301	.029	.000
가구인원수	-2.091	.470	.003

다중공선성

- Simpson's paradox

Berkeley Admission Data

	합격	불합격	지원자(계)
남자	1400(52%)	1291(48%)	2691(100%)
여자	772(42%)	1063(58%)	1835(100%)
전체	2172(48%)	2354(52%)	4526(100%)

- 합격, 불합격 변수에 관심을 두고 전체 결과만 놓고 보면, 남자의 합격률이 여자의 합격률보다 높다.
⇒ 성차별 주장이 제기.

다중공선성

- Simpson's paradox

	남		여	
분야	지원자	합격률	지원자	합격률
A	825	62%	108	82%
B	560	63%	25	68%
C	325	37%	593	34%
D	417	33%	375	35%
E	191	28%	393	24%
F	373	60%	341	70%

➤ 분야별로 보면 남자의 합격률보다 오히려 여자의 합격률이 더 높다. **성차별 주장은 잘못되었다.**

다중공선성

단변량 회귀모형:

$$r = \sqrt{\frac{\text{Var}(x)}{\text{Var}(y)}} \hat{\beta}$$

다변량 회귀모형:

$$\hat{\beta}_j \propto \text{Corr}(y, x_j | x_1, \dots, x_{j-1}, x_{j+1}, \dots, x_p)$$

변수선택

- 모형을 선택하는 이 단계
 - 다양한 복잡도의 후보모형들을 만든다.
 - 후보모형들 중 최적의 모형을 선택한다.

변수선택

- 후보모형을 만드는 방법
 - 모든 가능한 회귀 모형(All possible method)
 - 전진 선택법(Forward selection)
 - 후진 소거법(Backward elimination)
 - 단계적 방법(Stepwise method)

변수선택

- 최적 모형 선택 방법

- AIC(Akaike Information Criteria)

- 모형의 예측성능을 측정하는 통계량
 - AIC :

$$-\log(\text{가능도함수값}) + 2k$$

- k : 선택된 변수의 개수
 - 주어진 모형 중에 AIC를 최소로 하는 모형을 선택한다.

- BIC (Bayesian Information Criteria)

- $\log(\text{가능도함수값}) + (\log n)k$

변수선택

- 예제

- Red wine data


- 1599개 red wine대상
 - 물리 화학적 계측법으로 얻어진 값
 - 산도, 알콜량, 당도 등등 11개 항목
 - 관능검사로 얻어진 값
 - 사람의 감각으로 종합적인 평가
 - Quality가 여기에 해당
 - Quality : 0~10



변수선택


- 예제

- Wine의 quality를 물리화학적으로 계측한 변수로 모델링.
- AIC를 이용한 전진선택법으로 변수를 선택해보자.




변수선택

- 예제 - 1번째 변수선택




변수선택

- 예제 - 1번째 변수선택




변수선택

- 예제 - 1번째 변수선택



변수선택

- 예제 - 2번째 변수선택




변수선택

- 예제 - 2번째 변수선택



변수선택

- 예제 - 3번째 변수선택



변수선택

- 예제 - 최종 모형



변수선택

- 전진선택법의 장단점
 - 방법의 이해가 쉽다.
 - 변수의 개수가 많은 경우에도 사용할 수 있다.
 - 최적의 모형을 선택하지 못할 수도 있다.
 - 변수 값의 작은 변동에도 결과가 크게 달라진다.
 - 한 변수가 선택된 경우 상관관계가 큰 다른 변수는 선택되지 못한다.
 - “Usually overly greedy”

*Thank
you*

