
기계학습

Chap 3: 고차원회귀모형

김용대

서울대학교 통계학과

목차

1. 고차원회귀모형 소개
 2. 능형회귀
 3. 라쏘회귀
 4. 변수선택, 능형회귀, 라쏘회귀의 비교
 5. Elastic Net
 6. Fused Lasso for Image Denoising
-

1. 고차원 모형 소개

고차원 선형회귀모형

- 선형회귀모형에서 설명변수의 수 p 가 데이터의 수 n 보다 큰 경우
- 다중 공선성(Multicollinearity)
 - 몇 개의 설명 변수들은 굉장히 높은 상관 관계를 가지고 있을 수 있다.
 - 선형 회귀 분석에서 최소 제곱 추정량이 유일하지 않을 수 있다.
- 과대적합(overfitting)
 - 실제 모델보다 더 많은 설명 변수를 사용해 모델을 적합하게 될 수 있다.
 - 과대 적합은 좋지 않은 예측력을 유발한다.


고차원 선형회귀모형의 예

- 이미지 분석

original image




noisy image



고차원 선형회귀모형의 예

- 이미지 분석(이어서...)
 - 잡음이 포함된 이미지의 모형화



If 3-channel 640480 image, $p=3 \times 640 \times 480$


고차원 선형회귀모형의 예

- 이미지 분석(이어서...)
 - 잡음이 포함된 이미지의 모형화
 - 1) 모형
 - : $y = \beta + \epsilon$
 - y 는 관측된 픽셀들의 정보
 - β 는 잡음을 제거한 이미지의 픽셀정보
 - 2) 이미지 분석의 목적
 - : y 를 관측한 후 β 에 대한 추정하는 것


고차원 선형회귀모형의 예

- 이미지 분석(이어서...)
 - 벌점화 방법으로 이미지 잡음제거를 한 결과

lasso denoising





fusion denoising



고차원 선형회귀모형의 예

- 브레인 네트워크 분석
 - 뇌의 활동을 그래프 모형으로 표현한 것



고차원 선형회귀모형의 예

- 브레인 네트워크 분석
 - 브레인 네트워크 그래프 모형
 - 1) 노드 : 뇌의 각 지역
 - x_i : i 번째 지역의 혈류량
 - $x = (x_1, \dots, x_p)$: p 개 지역에서 혈류량
 - 2) 두 개의 지역이 뇌의 행동에 연관되어 있느냐?
 - 편상관계수로 이해
 - 3) 모형 (편상관성 추정)
 - $X_k = \sum_{i \neq k} \beta_{ki} X_i + \epsilon_k$
 - k 번째와 i 번째 지역의 편상관계수가 0 $\Leftrightarrow \beta_{ki} = 0$
 - 벌점화 방법을 이용하여 회귀계수 추정

고차원 선형회귀모형의 예

- SNS를 이용한 신용평가



Text Mining

ID	nova	galaxy	heat	h'wood	film	role	diet	fur
A	10	5	3					
B	5	10						
C				10	8	7		
D				9	10	5		
E							10	10
F							9	10
G	5		7			9		
H		6	10	2	8			
I				7	5		1	3



고차원회귀

고차원 선형회귀모형의 예

- SNS를 이용한 신용평가
 - 출력변수는 신용상태
 - 입력변수는 사용한 단어의 빈도
 - 입력변수의 수는 사용 가능한 단어의 수 (거의 무한대)
 - 입력변수의 대부분이 0이다 (자료가 sparse하다!)
 - 예상: 신용평가에 영향을 주는 단어는 아주 많지 않을 것이다

고차원 선형회귀모형의 예

- Feature learning (for 비선형 회귀모형)
 - 원자료에 비선형 변환을 적용하여 특성 (feature)를 얻고, 특성을 입력변수로 하는 선형모형 구축
 - 예: 다항회귀, 푸리에 변환, 부스팅, Kernel 방법론, 딥러닝 등
 - 특성의 차원은 매우 크기 때문에 고차원 선형회귀 방법론이 필수적임

2. 능형회귀 (RIDGE REGRESSION)

벌점화 방법 소개

- 벌점화 방법

- 주어진 벌점함수 $J_\lambda(\cdot)$ 에 대해서 다음의 벌점화 잔차제곱합을 최소로 하는 회귀계수 추정하는 방법

$$\operatorname{argmin}_{\beta} \sum (y_i - x_i' \beta)^2 + \sum J_\lambda(|\beta_k|)$$

: λ 는 양의 실수로 조율모수이며, 벌점함수가 추정량에 미치는 영향을 조절

능형회귀

- 선형회귀분석에서 최소 제곱 추정량은

$$\begin{aligned}\hat{\beta} &= \operatorname{argmin}_{\beta} \sum_{i=1}^n (y_i - \mathbf{x}_i^T \beta)^2 \\ &= (X^T X)^{-1} X^T y\end{aligned}$$

- 설명변수의 숫자가 표본의 숫자보다 크게 되면 (즉, $p > n$) $X^T X$ 의 역행렬이 존재하지 않는다.
 - 최소 제곱 추정량이 유일하지 않다.
 - 능형회귀!

능형회귀

- 능형회귀 정의

- 능형 추정량은 벌점함수 $J_\lambda(|\beta|) = \lambda\beta^2$ 을 사용하여 구한 벌점화 최소제곱추정량

$$\begin{aligned} & \operatorname{argmin}_\beta \sum (y_i - x_i' \beta)^2 + \lambda \sum \beta_k^2 \\ &= (X^T X + \lambda I)^{-1} X^T y \end{aligned}$$

- 능형 회귀에서의 벌점화 함수는 제곱 형태를 띠고 있으므로 l_2 -벌점화 함수라고도 한다.

능형회귀

- 축소추정량
 - 입력변수들끼리 독립인 경우
 - 능형회귀 추정량은 a *최소제곱추정량으로 주어지고, 여기서 a 는 1보다 작다.
 - 즉, 능형회귀추정량을 최소제곱추정량을 0으로 축소시키는 추정량이다.
 - 이러한 추정량을 축소추정량 (shrinkage estimator)라 부른다.

능형회귀

- 축소추정량
 - 1차원 정규모집단에서 평균벡터를 추정할 때 표본평균이 가장 좋은 추정량이다.
 - 2차원 정규모집단에서 평균벡터를 추정할 때 표본평균이 가장 좋은 추정량이다.
 - 3차원이상의 정규모집단에서 평균벡터를 추정할 때 표본평균이 가장 좋은 추정량이 아니다.
 - 표본평균을 축소하므로써 더 좋은 추정량을 얻을 수 있다.
 - James-Stein 추정량

능형회귀

Term	LS	Selection	Ridge
Intercept	2.480	2.495	2.467
x_1	0.680	0.740	0.389
x_2	0.305	0.367	0.238
x_3	-0.141		-0.029
x_4	0.210		0.159
x_5	0.305		0.217
x_6	-0.288		0.026
x_7	-0.021		0.042
x_8	0.267		0.123
Test Error	0.586	0.574	0.540

능형회귀

- 능형회귀의 한계
 - 모든 회귀 계수들의 추정값이 0이 아니므로 설명 변수가 많을 경우 과대적합 및 해석력의 문제가 생길 수 있다.
 - 변수 선택의 기능까지 있는 벌점화 함수가 필요!
- **LASSO (Least Absolute Shrinkage and Selection Operator)!**

3. 라쏘회귀 (LASSO REGRESSION)

라쏘회귀

- 라쏘 벌점함수 : $J_\lambda(|\beta|) = \lambda|\beta|$
- 라쏘 추정량
 - 라쏘 벌점함수를 이용하여 구한 벌점화 최소제곱 추정량



$$\hat{\beta} = \operatorname{argmin}_{\beta} \sum_{i=1}^n (y_i - \mathbf{x}_i^T \beta)^2 + \lambda \sum_{j=1}^p |\beta_j|$$

- 라쏘 추정방법을 사용하면 몇 개의 회귀 계수들이 정확히 0으로 추정된다.(Model is sparse!)

왜 라쏘는 sparse할까?

- Equivalent optimization problem
 - 능형회귀
Minimize $\sum_{i=1}^n (y_i - \mathbf{x}_i^T \beta)^2$ subject to $\sum \beta_k^2 < s$ for some $s > 0$.
 - 라쏘회귀
Minimize $\sum_{i=1}^n (y_i - \mathbf{x}_i^T \beta)^2$ subject to $\sum_{j=1}^p |\beta_j| < s$ for some $s > 0$.
- s 와 λ 사이에 일대일 관계가 있음

왜 라쏘는 sparse할까?



라쏘회귀

- 회귀 계수 추정량 비교

Term	LS	Ridge	Lasso
Intercept	2.480	2.467	2.477
x_1	0.680	0.389	0.545
x_2	0.305	0.238	0.237
x_3	-0.141	-0.029	
x_4	0.210	0.159	0.098
x_5	0.305	0.217	0.165
x_6	-0.288	0.026	
x_7	-0.021	0.042	
x_8	0.267	0.123	0.059
Test Error	0.586	0.540	0.491



변수 선택 기능!

조율모수 선택방법

- 교차확인법 (Cross-validation)
 - 데이터를 몇 개의 조각을 나눈 후 예측 오차를 구하는 방법
 - 1. 주어진 데이터 D 를 k 개의 조각 $D_1, \dots, D_k$ 으로 나눔(서로 배반)
 - 2. 주어진 λ 에 대해 k 번 반복 수행
 - ① 주어진 j 에 대해서 $\cup_{i \neq j} D_i$ 만을 이용하여 능형 또는 라쏘 추정량 구함
 - ② D_j 데이터에서 예측오차 구함
 - 3. k 개의 오차의 평균을 λ 에 대한 교차확인오차라 하고 이것이 가장 작은 λ 선택

4. 변수선택, RIDGE, LASSO 비교

변수선택






FIGURE 3.4. All possible subset models for the prostate cancer example. At each subset size is shown the residual sum-of-squares for each model of that size.

변수선택과 Ridge



Ridge와 Lasso의 Solution Path




FIGURE 3.6. Profiles of ridge coefficients for the prostate cancer example, as tuning parameter λ is varied. Coefficients are plotted versus df , the effective degrees of freedom. A vertical line is drawn at $df = 4.16$, the value chosen by cross-validation.




FIGURE 3.8. Profiles of lasso coefficients, as tuning parameter t is varied. Coefficients are plotted versus $s = t / \sum_1^p |\hat{\beta}_j|$. A vertical line is drawn at $s = 0.5$, the value chosen by cross-validation. Compare Figure 3.4.3; the lasso profiles hit zero, while those for ridge do not.

5. ELASTIC NET

Motivation

입력변수끼리 상관관계가 높은 경우에는 변수를 선택하는 방법이 최적이지 아니다.

- An example is a factor model.
 - True model: $Y = F + \epsilon$ where $F \sim N(0, 1) \perp \epsilon_i \sim N(0, \sigma^2)$.
 - Data: (Y, X_1, X_2) where $X_j = F + \xi_j$ and $\xi_j \sim N(0, 1) \perp F$.
 - Then

$$\operatorname{argmin}_{\beta_1, \beta_2} \mathbb{E}(Y - \beta_1 X_1 - \beta_2 X_2)^2 = (1/2, 1/2).$$

Elastic Net 추정량

$$\hat{\beta} = \operatorname{argmin}_{\beta} \sum_{i=1}^n (y_i - \mathbf{x}_i^T \beta)^2 + \lambda_1 \sum_{j=1}^p |\beta_j| + \lambda_2 \sum_{j=1}^p \beta_j^2$$

- 두개의 조율모수가 있다 (계산이 어렵다).
- Lasso 조율모수는 모형의 sparsity를 조절하고, Ridge의 조율모수는 상관성이 높은 입력변수를 얼마나 합치냐를 결정한다.
- 실증적으로 매우 우수한 예측력을 보인다는 것이 알려져 있다.


6. FUSED LASSO FOR IMAGE DENOISING

이미지 디노이징 예제

original image



noisy image



모형

$$Y_{ij} = \beta_{ij} + \epsilon_{ij}$$

Y_{ij} : (i,j) 픽셀 관측값

β_{ij} : (i,j) 픽셀 실제값

ϵ_{ij} : (i,j) 픽셀에 더해진 잡음

Minimize

$$\sum_{i,j} (Y_{ij} - \beta_{ij})^2 + \lambda \sum_{i,j} \sum_{(k,l) \in N(i,j)} |\beta_{ij} - \beta_{kl}|$$

감사합니다.
