


제 4강

의사결정나무

서울대학교 통계학과
김용대

4-1. 의사결정나무란?


의사결정나무의 예



의사결정나무의 구성요소들

- 뿌리마디(**root node**): 나무구조가 시작되는 마디로 전체 자료로 이루어져 있다.
- 자식마디(**child node**): 하나의 마디로부터 분리되어 나간 2개 이상의 마디들
- 부모마디(**parent node**): 주어진 마디의 상위마디
- 끝마디(**terminal node**): 자식마디가 없는 마디
- 중간마디(**internal node**): 부모마디와 자식마디가 모두 있는 마디
- 가지 (**branch**): 한의 마디로부터 끝마디 까지 연결된 일련의 마디들.
- 깊이 (**depth**): 뿌리마디부터 끝마디 까지의 중간마디의 수

의사결정나무의 구성요소들



4-2. 의사결정나무 구축방법

의사결정나무의 형성과정

- 나무의 성장(growing): 각 마디에서 적절한 최적의 분리규칙을 찾아서 나무를 성장 시킨다. 정지규칙을 만족하면 성장을 중단한다.
- 가지치기(pruning): 분류오류를 크게 할 위험이 높거나 부적절한 추론규칙을 가지고 있는 가지를 제거한다. 또한, 불필요한 가지를 제거한다.
- 타당성 평가: 평가용 자료 (validation sample)의 사용이나 교차확인법 (cross validation) 등을 이용하여 의사결정나무를 평가한다.
- 해석 및 예측: 구축된 나무모형을 해석하고 예측모형을 설정한다.

분리규칙

- 각 마디에서 분리규칙은 분리에 사용될 입력변수 (분리변수, **split variable**)의 선택과 분리가 이루어 질 기준 (분리 기준, **split criterion**)를 정해야 한다.
- 분리에 사용될 변수(**X**)가 연속 변수인 경우에는 분리 기준(**c**)은 하나의 숫자로 주어지며, 일반적으로 분리변수 **X**가 **c**보다 작으면 왼쪽 자식마디로 **X**가 **c**보다 크면 오른쪽 자식마디로 자료를 분리한다.
- 분리변수가 범주형인 경우에는 분리기준은 전체 범주를 두 개의 부분집합으로 나누는 것이 된다. 예를 들면, 전체 범주가 {1,2,3,4}이면 분리기준의 예로는 {1,2,4}과 {3}이 되고 이때는 분리변수가 범주 {1,2,4}에 속하면 왼쪽자식마디로 범주 {3}에 속하면 오른쪽 자식마디로 자료를 분리한다.

순수도


- 각 마디에서 분리변수와 분리기준은 목표변수의 분포를 가장 잘 구별해주는 쪽으로 정한다.
- 목표변수의 분포를 얼마나 잘 구별하는가에 대한 측정치로 순수도 (purity) 또는 불순도 (impurity)를 사용한다.
- 예를 들어 그룹0과 그룹 1의 비율이 45%와 55%인 마디는 각 그룹의 비율이 90%와 10%인 마디에 비하여 순수도가 낮다 (또는 불순도가 높다)라고 이야기 한다.
- 각 마디에서 분리변수와 분리 기준의 설정은 생성된 두 개의 자식마디의 순수도의 합이 가장 큰 분리변수와 분리기준을 선택한다.

순수도의 조건


- 의사결정나무는 각 마디에서 분리에 의해 커진다.
- 분리는 분리 후에 자식마디가 부모마디보다 순수하도록 이루어진다.
- 자식마디가 부모마디보다 순수하다는 것은 분리 후에 각 마디 안에 있는 자료의 구성이 어느 한 그룹에만 해당하는 비율이 높다는 것이다.
- 분리를 할 때, 분리변수의 선택은 불순도의 감소를 최대로 만드는 변수를 선택한다.
- 불순도의 측정으로 가장 쉽게 생각할 수 있는 것이 오분류율이다. 즉, 자식마디의 오분류율을 가장 작게 하는 분리변수와 분리기준을 선택하는 것은 매우 자연스럽다.

순수도의 조건(계속)

➤ 그러나 다음의 그림을 보면, split 1과 split 2에서 오분류율은 200/800으로 같지만, 다음 단계의 분리를 생각하면 split 2가 더 바람직하다.



Split 1



Split 2

순수도의 조건(계속)

- 이렇듯, 한 마디에서 오분류율을 감소시키는 것이 나무 전체의 오분류율을 감소시키는 것이 아니다.
- 이러한 점에서, 단순히 오분류율을 불순도로 생각하는 것은 바람직하지 않다.
- 적절한 불순도는 두 개의 자식마디 중 어느 한쪽의 오분류율이 아주 작은 경우에 적어지는 것이 바람직하다.
- 이러한 관점에서 `split 2`가 더 작은 불순도를 갖는다고 말할 수 있다.

불순도 측정량

➤ 분류모형

- 카이제곱 통계량 (chi-square statistics)
- 지니지수 (Gini index)
- 엔트로피지수 (Entropy index)

➤ 회귀모형

- 분산분석에 의한 F- 통계량(F-Statistics)
- 분산의 감소량

카이제곱 통계량

- 주어진 분리변수와 분리기준에 의하여 다음의 표를 작성할 수 있다.

	good	bad	total
left	32	48	80
right	178	42	220
total	210	90	300

- 위의 표를 실제도수(O)라고 한다.

카이제곱 통계량(계속)

- 앞의 표에서 각 셀에 대한 기대도수(E)를 다음과 같이 구할 수 있다.

	good	bad	total
left	$80/300 \times 210/300 \times 300 = 54$	$80/300 \times 90/300 \times 300 = 24$	80
right	154	66	220
total	210	90	300

카이제곱 통계량(계속)

- 실제도수와 기대도수를 이용하여 카이제곱 통계량을 다음과 같이 구한다.

카이제곱 통계량 = $\sum ((\text{기대도수} - \text{실제도수})^2 / \text{기대도수})$ 의 합

- 앞의 표로부터 카이제곱 통계량을 구하면

$$(56-32)^2/56 + (24-48)^2/24 + (154-178)^2/154 + (66-42)^2/66 = 46.75$$

- 모든 분리변수와 분리기준 중 이 카이제곱통계량이 가장 크게되는 분리변수와 분리기준을 사용하여 분리를 실시한다.

지니지수 (Gini Index)

- 지니지수는 다음과 같이 구한다.

$$\text{지니지수} = \text{left에서 good일 확률} * \text{left에서 bad일 확률} \\ + \text{right에서 good일 확률} * \text{right에서 bad일 확률}$$

- 앞의 표에서 지니지수를 구하면

$$\text{지니지수} = (32/80) * (48/80) + (178/220) * (42/220) = 0.3944$$

모든 분리변수와 분리기준에서 지니지수를 가장 작게 하는 분리변수와 분리기준을 사용하여 분리를 수행한다.

엔트로피 지수 (Entropy Index)

➤ 엔트로피는 다음과 같이 구한다.

$$\begin{aligned}\text{엔트로피} = & \text{left에서 good의 확률} * \log(\text{left에서 good의 확률}) \\ & + \text{left에서 bad의 확률} * \log(\text{left에서 bad의 확률}) \\ & + \text{right에서 good의 확률} * \log(\text{right에서 good의 확률}) \\ & + \text{right에서 bad의 확률} * \log(\text{right에서 bad의 확률})\end{aligned}$$

➤ 앞의 표에서 엔트로피를 구하여 보면

$$\begin{aligned}\text{엔트로피는} = & (32/80) * \log(32/80) + (48/80) * \log(48/80) \\ & + (178/200) * \log(178/200) + (42/200) * \log(42/200) \\ = & -0.4796\end{aligned}$$

엔트로피 지수 (Entropy Index)

- 모든 분리변수와 분리기준 쌍에서 엔트로피를 가장 작게 하는 변수와 기준을 선택하고 이를 이용하여 분리를 수행한다.

분리방법: 예제

➤ 아래의 자료에 대하여 지니지수를 이용하여 최적의 분리를 찾아보자.

Temperature	Humidity	Windy	Class
Hot	High	False	N
Hot	High	True	N
Hot	High	False	P
Mild	High	False	P
Cool	Normal	False	P
Cool	Normal	True	N
Cool	Normal	True	P

Temperature	Humidity	Windy	Class
Mild	High	False	N
Cool	Normal	False	N
Mild	Normal	False	P
Mild	Normal	True	P
Mild	High	True	P
Hot	Normal	false	N
Mild	highl	True	P

분리방법: 예제

1. Temperature를 기준으로 분리

1-1. left node={hot}, right node={mild,cold}

	N	P	total
left	3	1	4
right	3	7	10
total	6	8	14

➤ Gini index = $\frac{3}{4} * \frac{1}{4} + \frac{3}{10} * \frac{7}{10} = 0.3975$

분리방법: 예제

1. Temperature를 기준으로 분리

1-2. left node={mild}, right node={hot,cold}

	N	P	total
left	1	5	6
right	5	3	8
total	6	9	14

➤ Gini index = $1/6 * 5/6 + 5/8 * 3/8 = 0.373$

분리방법: 예제

1. Temperature를 기준으로 분리

1-3. left node={cold}, right node={hot,mild}

	N	P	total
left	2	2	4
right	4	6	10
total	5	9	14

➤ Gini index = $2/4 * 2/4 + 4/10 * 6/10 = 0.49$

분리방법: 예제

2. Humidity를 기준으로 분리

2-1. left node={high}, right node={normal}

	N	P	total
left	3	4	7
right	3	4	7
total	6	8	14

➤ Gini index = $3/7 * 4/7 + 3/7 * 4/7 = 0.489$

분리방법: 예제

3. windy를 기준으로 분리

3-1. left node={false}, right node={true}

	N	P	total
left	4	4	8
right	2	4	6
total	6	8	14

➤ Gini index = $4/8 * 4/8 + 2/6 * 4/6 = 0.472$

분리방법: 예제

- 1, 2, 3의 결과를 종합하여 불순도가 가장 작은 분리를 선택한다.
- 따라서, 1번 `temperature`를 기준으로 마디를 분리한다.

정지규칙

- 현재의 마디가 더 이상 분리가 일어나지 못하게 하는 규칙이다.
 - 규칙의 종류로는
 - 모든 자료가 한 그룹에 속할 때
 - 마디에 속하는 자료가 일정 수 이하일 때
 - 불순도의 감소량이 아주 작을 때
 - 뿌리마디로부터의 깊이가 일정 수 이상일 때
- 등이 있다.

가지치기

- 지나치게 많은 마디를 가지는 의사결정나무는 새로운 자료에 적용할 때 예측오차가 매우 클 가능성이 있다.
- 성장이 끝난 나무의 가지를 적당히 제거하여 적당한 크기를 갖는 나무모형을 최종적인 예측모형으로 선택하는 것이 예측력의 향상에 도움이 된다.
- 적당한 크기를 결정하는 방법은 평가용 자료(validation data)를 사용하거나 교차확인을 이용하여 예측에러를 구하고 이 예측에러가 가장 작은 나무모형을 선택한다.

가지치기 (Pruning)

- 가장 높은 예측력을 갖는 나무를 가지치기를 통하여 찾아낸다.
- 가지치기를 얼마나 해야 하는가를 결정하기 위해서 반복적인 가지치기의 과정을 통하여 부분나무의 후보를 우선 파악한다.
- 그리고, 각 끝마디에서 최소의 부가적인 예측력을 제공해주는 가지를 우선 잘라낸다.
- 제일 유용하지 않은 가지를 알아내기 위해서는 나무에 수정된 오분류율의 개념을 적용시켜 나무의 오분류율을 감소시키지 못하는 가지를 잘라낸다.
- 수정된 오분류율은 평가용자료를 이용하여 구하거나 교차확인방법을 사용하여 구한다.

가지치기 (Pruning) 과정

- 주어진 나무 T 와 양수 a 에 대하여 비용 복잡도(cost complexity)는 다음과 같이 정의 된다.

$$\text{비용복잡도}(a) = \text{나무 } T \text{의 오분류율} + a |T|$$

여기서 $|T|$ 는 나무 T 의 끝마디의 개수이다.

- 일반적으로 나무가 커지면 (즉 $|T|$ 가 커지면) 오분류율을 줄게 된다. 하지만 $a|T|$ 이 증가하여 비용복잡도는 항상 감소하지 않는다.
- 나무성장과정을 통하여 생성된 큰 나무 T_m 대하여, 주어진 a 에 대하여 비용복잡도(a)를 최소로 하는 T_m 의 부분나무를 $T(a)$ 라 하자.
- 일반적으로 a 가 크면 $T(a)$ 의 크기가 작아진다.
- 최적의 a 를 평가용자료나 교착확인으로 찾는다.

4-4. 의사결정나무의 장/단점

의사결정나무의 장점

- 이해하기 쉬운 규칙을 생성시켜 준다.
- 분류작업이 용이하다.
- 연속형변수와 범주형 변수를 모두 다 취급할 수 있다.
- 가장 좋은 변수를 명확히 알아낸다.
- 이상치에 덜 민감하다.
- 모형의 가정 (선형성, 등분산성 등)이 필요 없다. 즉, 비모수적 모형이다.

의사결정나무의 장점

- 이해하기 쉬운 규칙을 생성시켜 준다.
- 분류작업이 용이하다.
- 연속형변수와 범주형 변수를 모두 다 취급할 수 있다.
- 가장 좋은 변수를 명확히 알아낸다
- 이상치에 덜 민감하다.
- 모형의 가정 (선형성, 등분산성 등)이 필요 없다. 즉, 비모수적 모형이다.



의사결정나무의 단점

- 목표변수가 연속형인 회귀모형에서는 그 예측력이 떨어진다.
- 나무가 너무 깊은 경우에는 예측력의 저하뿐 아니라 해석도 하기가 쉽지 않다.
- 계산량이 많을 수 있다.
- 비사각영역에서 문제가 있다.
- 결과가 불안정하다.
- 선형성 또는 주효과의 결여

의사결정나무의 단점

- 목표변수가 연속형인 회귀모형에서는 그 예측력이 떨어진다.
- 나무가 너무 깊은 경우에는 예측력의 저하뿐 아니라 해석도 하기가 쉽지 않다.
- 계산량이 많을 수 있다.
- 비사각영역에서 문제가 있다.
- **결과가 불안정하다.**
- 선형성 또는 주효과의 결여

- Two trees from two bootstrap samples of the Boston Housing data with node size 5



수고하셨습니다.