

기계학습

6강. Support Vector Machine

김용대¹

¹서울대학교 통계학과

목차


- 1절: SVM 소개
- 2절: Optimal Separating Hyperplane (OSH)
- 3절: OSH의 계산
- 4절: Linearly nonseparable한 경우: Soft Margin
- 5절: 비선형 경계를 향하여
- 6절: Support Vector Machine
- 7절: ERM원리를 이용한 SVM의 이해

1절: SVM의 소개

- Support Vector Machine (SVM)은 Vapnik (1996)에 의해서 개발된 분류모형이다.
- SVM은 Neural Network (NN)의 성능을 크게 향상시켜서 큰 인기를 얻었다.
- 특별히 SVM은 NN에 비하여 이론적 기반이 충실하다.
- SVM의 원리 설명에는 두가지 방법이 있는데
 - Vapnik (1996)의 설명은 Optimal separating hyperplane으로 부터 시작하는 방법으로 매우 직관적이며
 - Empirical risk minimization과 Reproducing Kernel Hilbert space를 이용하는 Wahba (2002) 방법이 있는데, 매우 이론적인 반면에 확장성이 매우 좋다.
- 본 강의에서는 Vapnik (1996)의 설명을 주로 따라 가며, 마지막에 Wahba (2002) 방법을 이용한 결과에 대해서 간단하게 살펴본다.


2절: Optimal separating hyperplane

- 두 그룹 분류문제에서 두 그룹의 자료가 직선에 의해서 완벽하게 나누어진다고 가정하자.
- 이 때, 이 두 그룹의 자료를 나누는 직선을 Separating hyperplane이라고 부른다.



- 자료가 linearly separable하면 separating hyperplane은 무한개다.
- Vapnik (1996)은 separating hyperplane중 margin을 최대화 하는 hyperplane을 optimal separating hyperplane (OSH)라고 정의하였다.
- 여기서 margin은 다음과 같이 정의된다.

$$\text{margin}(\mathbf{w}, b) = \min_i \{ \text{the distance of } \mathbf{x}_i \\ \text{from the boundary } \mathbf{w}'\mathbf{x} + b = 0. \}$$



- OSH 아이디어를 실제 분류문제에 적용하기 위해서는 다음의 4가지 질문에 답을 하면 된다.
 - OSH를 어떻게 구하는 가? (최적화문제)
 - Linearly separable하지 않은 자료에서는 어떻게 하는가?
 - 비선형 모형으로는 어떻게 확장하는가?

2절: OSH의 계산



- OSH를 구하기 위해서는 다음의 최적화 문제를 풀면 되는 것이 알려져 있다.
 - Minimize $\tau(\mathbf{w}) = \|\mathbf{w}\|^2/2$
 - subject to $y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1$ for $i = 1, \dots, n$.
- 위의 최적화 문제를 QP (Quadratic Programing) 라 부르면, 쌍대 (dual) 최적화 문제는 다음이 되며
 - Maximize $W(\alpha) = \sum_{i=1}^n \alpha_i - \sum_{i,j} \alpha_i \alpha_j y_i y_j \mathbf{x}_i' \mathbf{x}_j / 2$
 - subject to $\alpha_i \geq 0$,
- 최종 OSH는 $\text{sign}(\sum_{i=1}^n \alpha_i y_i \mathbf{x}_i' \mathbf{x} + b)$ 로 주어진다.

- 주어진 $\mathbf{x}$ 에 대해서 OSH는 $\mathbf{x}$ 와 $\mathbf{x}_1, \dots, \mathbf{x}_n$ 의 내적에만 의존한다. 이러한 성질은 후에 비선형경계를 만드는데 매우 중요하게 사용된다.
- 쌍대 최적화 문제에서의 미지수의 개수 (즉, α 의 차원)은 입력변수의 차원과 무관하게 항상 자료의 수 n 이다. 이러한 성질은 특히 입력변수 $\mathbf{x}$ 의 차원이 클 때 SVM이 좋은 성능을 갖게 한다..

- 주어진 $\mathbf{x}_i$ 가 OSH와의 거리가 최소가 될 때 이 관측치를 **support vector**라고 부르며, $\mathbf{x}_i$ 가 support vector이면 $\alpha_i > 0$ 이고 support vector가 아니면 $\alpha_i = 0$ 이 됨이 알려져 있다.
- 즉, OSH는 support vector들만의 함수이다.
- OSH의 이러한 성질 때문에 OSH는 outlier에 강건하다.

3절: Linearly nonseparable인 경우: Soft Margin


- 아이디어: Slack variables을 이용하자.
- Slack variable를 이용한 OSH는 다음의 최적화 문제를 풀어서 구한다:
 - Minimize $\tau(\mathbf{w}, \xi) = \|\mathbf{w}\|^2/2 + C \sum_{i=1}^n \xi_i$
 - subject to
 - $y_i(\mathbf{w}' \mathbf{x}_i + b) \geq 1 - \xi_i$ for $i = 1, \dots, n$
 - $\xi_i \geq 0$ for $i = 1, \dots, n$.



- 상수 C 는 soft margin을 얼마나 허용하는냐를 결정한다.
 $C = \infty$ 이면 slack variable이 없는 linearly separable에서의 OSH가 되며, $C = 0$ 이면 $\mathbf{w} = 0$ 이 OSH가 된다. 즉, 상수 C 는 OSH의 복잡도를 결정한다.
- Slack variable을 이용한 OSH의 쌍대 최적문제는 다음과 같다:
 - Maximize $W(\alpha) = \sum_{i=1}^n \alpha_i - \sum_{i,j} \alpha_i \alpha_j y_i y_j \mathbf{x}_i' \mathbf{x}_j / 2$
 - subject to $0 \leq \alpha_i \leq C$ and $\sum_{i=1}^n \alpha_i y_i = 0$.

4절: 비선형 경계를 향하여

- 핵심 아이디어는 $\mathbf{x}$ 를 비선형적으로 변환 한 후, 변환된 입력변수를 이용한 최적의 선형경계를 찾는다.
- 주어진 비선형 함수 $\phi : R^p \rightarrow \mathcal{F}$, 변환된 입력 $\phi(\mathbf{x})$ 를 feature라고 부르고, 이 때 $\mathcal{F}$ 를 feature공간이라고 부른다.



- Feature공간에서 OSH를 구하기 위해서는 다음의 최적화 문제를 풀어야 한다:
 - Maximize $W(\alpha) = \sum_{i=1}^n \alpha_i - \sum_{i,j} \alpha_i \alpha_j y_i y_j k(\mathbf{x}_i, \mathbf{x}_j) / 2$
 - subject to $\alpha_i \geq 0$
 - where $k(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)' \phi(\mathbf{x}_j)$.
- 따라서, feature space에서 OSH를 구하기 위해서는 feature $\phi(\mathbf{x})$ 들 사이의 내적 $\phi(\mathbf{x}_i)' \phi(\mathbf{x}_j)$ 만 알면되며, 이 때 내적 $k(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)' \phi(\mathbf{x}_j)$ 을 kernel이라고 부른다.
- 실제 자료분석에서는 feature map ϕ 를 정하는 대신 kernel k 를 선택한다.
- OSH의 계산은 feature space의 차원에 의존하지 않는다. 따라서 무한차원의 feature space도 사용할 수 있다.

- 주어진 bi-linear 함수 $k(\mathbf{x}_1, \mathbf{x}_2)$ 가 특정한 feature map의 내적이 되기 위한 필요충분조건은 임의의 n 에 대해서 가능한 모든 n 개의 입력변수 $\mathbf{x}_1, \dots, \mathbf{x}_n$ 에 대해서 행렬 $[k(\mathbf{x}_i, \mathbf{x}_j)]_{i,j}$ 이 양정치행렬이 되어야 한다.
- 이러한 필요충분조건을 만족하는 kernel 함수를 Mercer kernel 이라 부른다.
- Mercer kernel의 예는 다음과 같다:
 - Polynomial: $k(\mathbf{x}_1, \mathbf{x}_2) = (1 + \mathbf{x}_1' \mathbf{x}_2)^d$
 - Radial Basis: $k(\mathbf{x}_1, \mathbf{x}_2) = \exp(-\|\mathbf{x}_1 - \mathbf{x}_2\|^2/c)$
 - Neural network: $k(\mathbf{x}_1, \mathbf{x}_2) = \tanh(\kappa_1 \mathbf{x}_1' \mathbf{x}_2 + \kappa_2)$

5절: Support Vector Machine

$$\text{SVM} = \text{Feature space (kernel)} + \text{soft margin}$$

- SVM을 사용하기 위하여는 kernel $k(\mathbf{x}_1, \mathbf{x}_2)$ 와 soft margin의 regularization모수인 C 를 선택하여야 한다.
- Systematic하게 커널과 regularization모수를 찾는 방법으은 없다.
- 즉, 커널과 regularization모수의 선정은 통계학적 관점에서 **모형선택**이 되며 다양한 방법이 제안되었다.

- SVM의 장점

- 다른 방법에 비해서 이론이 잘 정립되어 있다.
- Kernel만 잘 선택하면 입력변수의 차원은 모형의 추정에 전혀 관여하지 않는다. 즉, 고차원 자료의 분석을 쉽게 할 수 있다.
- 추정된 모형이 이상치에 강건하다.

- SVM의 단점

- Kernel의 선택이 어렵다 (보통 Gaussian kernel이 많이 사용된다).
- n 이 클때 계산량이 많다 ($O(n^3)$).
- 모형의 해석이 거의 불가능하다.

6절: ERM원리를 이용한 SVM의 이해

- SVM 모형은 다음의 최적화 문제를 푼다:
 - Minimize $\tau(\mathbf{w}, \xi) = \|\mathbf{w}\|^2/2 + C \sum_{i=1}^n \xi_i$
 - subject to
 - $y_i(\mathbf{w}' \mathbf{x}_i + b) \geq 1 - \xi_i$ for $i = 1, \dots, n$
 - $\xi_i \geq 0$ for $i = 1, \dots, n$.
- 위의 최적화 문제는 다음의 최적화 문제와 동치이다:
 - Minimize

$$\|\mathbf{w}\|^2/2 + C \sum_{i=1}^n [1 - y_i(\mathbf{w}' \mathbf{x}_i + b)]_+ \quad (1)$$

with respect to $\mathbf{w}$ where $[z]_+ = zI(Z > 0)$.

- “Hinge loss”라 불리는 손실함수 $l(y, f) = [1 - yf]_+$ 을 고려하면, 식 (1) 을 다음과 같이 쓸 수 있다:

$$\sum_{i=1}^n l(y_i, \mathbf{w}' \mathbf{x}_i + b) + \lambda \|\mathbf{w}\|^2 / 2.$$

for some $\lambda > 0$.

- 따라서, SVM은 hinge loss와 ridge penalty를 이용한 shrinkage 추정량이 된다.

- 두가지 질문
 - Hinge loss의 장점은 무엇인가? (나중에 설명)
 - Hinge loss를 다른 loss로 바꿔서 kernel technique를 사용할 수 있을까?
- Result by Wahba (2002)
 - For any loss function, the minimizer of the empirical risk on the feature space has the form

$$f(\mathbf{x}) = \alpha_0 + \sum_{i=1}^n \alpha_i K(\mathbf{x}, \mathbf{x}_i).$$

- 이러한 모형을 “kernel machine”이라 부른다.

References

- Vapnik, V. (1996). *The nature of statistical learning theory*, Springer-Verlag, New-York.
- Wahba, G. (2002). Soft and Hard Classification by Reproducing Kernel Hilbert Space Methods. Proceedings of the National Academy of Sciences, 99, 16524-16530.

감사합니다.