



# 기계학습

## 7강. 차원축소

서울대학교 통계학과  
김용대 교수





# 주성분분석 Principal Component Analysis


# | 1 주성분 분석 개요

## 1 주성분분석 개요

### 주성분분석 (Principal Component Analysis)


여러 개( $p \geq 2$ )의 다변량 양적변수를 선형결합으로 표시되는 중요한  $m (\leq p)$ 개의 주성분으로 표현하여 전체의 변동을 설명하는 것. 차원의 단순화를 통해 서로 상관되어 있는 변수들 간의 복잡한 구조를 분석하는 것이 목적.

# | 1 주성분 분석 개요




Step 1 : 주어진 자료를

# | 1 주성분 분석 개요




Step 2 : 좌표를 중심으로 이동시킨다.

# | 1 주성분 분석 개요




Step 3 : 이것을 새로운 좌표로 이용한다.

# | 1 주성분 분석 개요



Step 4 : 산포가 최대가 되는 방향을 찾는다.


# | 1 주성분 분석 개요



Step 5 : 다음의 수직방향을 찾는다.




# | 1 주성분 분석 개요




Step 6 :회전된 축만 남겨 놓다.

# | 1 주성분 분석 개요




Step 7 : 축을 회전시켜 원래 자리로 이동한다.

# | 1 주성분 분석 개요




Step 8 : 새로운 좌표계 완성.  
X축 분산이 매우 (제일) 크다.

# | 1 주성분 분석 개요



Step 9 : 자료를 X축으로 내려서 차원 축소 가능

# | 1 주성분 분석 개요



Step 10 : 차원축소 완성

# | 2 행렬대수

## 2 행렬대수

### 고유값(eigenvalues)과 고유벡터 (eigenvector)

$A : k \times k$  행렬

$Ax = \lambda x$  ( $x \neq 0$ ) 일 때,

$\lambda$ :  $A$ 의 고유값 (  $|A - \lambda I| = 0$  의 해 )

$x$ :  $A$ 의 고유벡터


$A : k \times k$  대칭행렬일 때,  $k$ 개의 고유값에 대응되는 고유 벡터 존재  
( $\lambda_1, e_1$ ), ( $\lambda_2, e_2$ ), ..., ( $\lambda_k, e_k$ ) 존재

이 때, 고유벡터들은 서로 수직이며, 단위벡터로 선택한다.

$$e_i' e_j = 0, \forall i \neq j$$

$$e_i' e_i = 1, \forall i = 1, \dots, k$$

$e_1, \dots, e_k$ : orthonormal



## | 2 행렬대수

### Spectral decomposition (스펙트럴 분해)

$A : k \times k$  대칭행렬

$\lambda_1, \dots, \lambda_k$  eigenvalues


$e_1, \dots, e_k$  : 대응되는 eigenvectors

such that  $e_i' e_i = 1, \forall i$ ;  $e_i' e_j = 0, \forall i \neq j$

**Spectral decomposition of  $A$  :**  $A = P \Lambda P' = \lambda_1 e_1 e_1' + \lambda_2 e_2 e_2' + \dots + \lambda_k e_k e_k'$   
(  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_k > 0$  )

## | 2 행렬대수

### 스펙트럴 분해의 기하학적 이해





## | 2 행렬대수

예제 )

$$p = 2, \Sigma = \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}$$

$$\rho > 0$$

$$\lambda_1 = 1 + \rho, \quad e_1 = \left( \frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}} \right)$$

$$\lambda_2 = 1 - \rho, \quad e_2 = \left( \frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{2}} \right)$$


$$Y_1 = \frac{X_1 + X_2}{\sqrt{2}}$$

$$Y_2 = \frac{X_1 - X_2}{\sqrt{2}}$$


## | 2 행렬대수

예제 )


1)  $\rho = 0, X'\Sigma^{-1}X$



2)  $\rho = 1, X'\Sigma^{-1}X$



3)  $\rho > 0, X'\Sigma^{-1}X$



# 3 주성분의 정의 및 계산

$$C_1 = a_1' X = a_{11}X_1 + a_{21}X_2 + \cdots + a_{p1}X_p$$

$$C_2 = a_2' X = a_{12}X_1 + a_{22}X_2 + \cdots + a_{p2}X_p$$

$\vdots$

$$C_p = a_p' X = a_{1p}X_1 + a_{2p}X_2 + \cdots + a_{pp}X_p$$

$$Var(C_i) = Var(a_i' X) = a_i' \Sigma a_i, \quad i = 1, 2, \dots, p$$

$$Cov(C_i, C_k) = Cov(a_i' X, a_k' X) = a_i' \Sigma a_k, \quad i, k = 1, 2, \dots, p$$

첫 번째 주성분 :  $a_1' a_1 = 1$  이라는 조건하에서 분산  $Var(a_1' X)$  을 최대화 하는  
선형결합

두 번째 주성분 :  $a_2' a_2 = 1, Cov(C_1, C_2) = 0$  이라는 조건하에서  $Var(a_2' X)$  을  
최대화하는 선형결합

$i$  번째 주성분 :  $a_i' a_i = 1, Cov(C_i, C_j) = 0, for j < i$  이라는 조건하에서  
 $Var(a_i' X)$  을 최대화하는 선형결합

# 3 주성분의 정의 및 계산

## 정리1

확률벡터  $X = [X_1, X_2, \dots, X_p]$  의 공분산행렬  $\Sigma$  에서 구한  $p$ 개 고유값과 이에 대응되는 고유벡터 짝을 고유값 크기순으로 배열하면,

$$(\lambda_1, e_1), (\lambda_2, e_2), \dots, (\lambda_p, e_p), \quad \text{where } \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$$

이때,  $a_i$  (주성분  $C_i$  의 선형결합계수) =  $e_i$  ( $\Sigma$  에서 구한 고유값  $\lambda_i$  에 대응되는 고유벡터) 가 되어, 아래와 같은 주성분  $C_i$  를 얻을 수 있다.

$$C_i = e_i'X = e_{1i}X_1 + e_{2i}X_2 + \dots + e_{pi}X_p$$

공분산은 아래와 같다.

$$\begin{aligned} \text{Var}(C_i) &= \text{Var}(e_i'X) = e_i'\Sigma e_i = \lambda_i \\ \text{Cov}(C_i, C_k) &= \text{Cov}(e_i'X, e_k'X) = e_i'\Sigma e_k = 0, i \neq k \end{aligned}$$



# 다차원척도법 Multidimensional Scaling (MDS)

# | 1 다차원척도법 개요

## 1 다차원척도법 개요

### 다차원 척도법 Multidimensional Scaling (MDS)

다차원 관측값 또는 개체들 간의 거리(distance) 또는 비유사성(dissimilarity)을 이용하여 개체들을 원래의 차원보다 낮은 차원(2차원 또는 3차원)의 공간상의 점으로 표현(spatial configuration)하는 통계적 분석방법

**목적** ➡ 차원의 축소를 통해 개체들 사이의 관계를 쉽게 파악

예) 정치 후보자, 소비자 제품들의 성향에 대한 구조를 파악하고자 할 때, 이들 개체들의 특성을 측정한 후에 개체들의 거리 또는 비유사성을 구한 뒤, 이들 개체들을 2차원 또는 3차원 공간상에 표현하여 개체들 사이의 관계를 파악하는데 이용

# 1 다차원척도법 개요

예) 1830년도의 프랑스 내의 86개 정부부처들간의 비행거리에 대한 자료가 다음과 같이 주어졌다고 하자. 이를 이용하여 MDS를 이용한 거리지도를 그려보면 다음과 같다.


```
> library(smacof)
> library(RgoogleMaps)
> data(Guerry)
> head(Guerry)
```

|              | Ain      | Aisne   | Allier   | Basses_Alpes | Hautes_Alpes | Ardeche  | Ardennes |
|--------------|----------|---------|----------|--------------|--------------|----------|----------|
| Ain          | 0.0000   | 236.127 | 97.4827  | 136.4560     | 102.8580     | 96.9111  | 227.8940 |
| Aisne        | 236.1270 | 0.000   | 204.5250 | 372.5810     | 338.5050     | 312.9950 | 46.0778  |
| Allier       | 97.4827  | 204.525 | 0.0000   | 203.8090     | 179.4800     | 120.2220 | 216.0980 |
| Basses_Alpes | 136.4560 | 372.581 | 203.8090 | 0.0000       | 36.5306      | 94.5906  | 362.8050 |
| Hautes_Alpes | 102.8580 | 338.505 | 179.4800 | 36.5306      | 0.0000       | 85.8828  | 327.3240 |
| Ardeche      | 96.9111  | 312.995 | 120.2220 | 94.5906      | 85.8828      | 0.0000   | 313.6630 |

```
> fit.guerry <- mds(Guerry)
> op <- par(mfrow = c(1,2))
> plot(fit.guerry)
> theta <- 82*pi/180 ## degrees to radians
> rot <- matrix(c(cos(theta), sin(theta), -sin(theta), cos(theta)), ncol = 2)
> configs82 <- fit.guerry$conf %*% rot ## rotated configurations
> francemap1 <- GetMap(destfile="mypic1.png", zoom = 6, center = c(46.55, 3.05),
+ maptype = "satellite")
> PlotOnStaticMap(francemap1)
> text(configs82*280, labels = rownames(configs82), col = "white", cex = 0.7)
> par(op)
```



# 1 다차원척도법 개요





## | 2 추정

### 최적모형의 적합

✓ 부적합도 : STRESS or S-STRESS 이용 각 개체들을 공간상에 표현

$$STRESS = \sqrt{\frac{\sum_{i < j} (S_{ij} - \widehat{S}_{ij})^2}{\sum_{i < j} S_{ij}^2}}$$

$$S - STRESS = \sqrt{\frac{\sum_{i < j} (S_{ij} - \widehat{S}_{ij})^2}{\sum_{i < j} (S_{ij}^2)^2}}$$

$\widehat{S}_{ij}$  : 측정 모형에서 구한  $S_{ij}$  의 적합값

- ✓ 부적합 도를 최소로 하는 방법으로 반복알고리즘을 이용하게 적합
- ✓ 부적합도 값 일정한 수준이하로 될 때 최종적으로 적합된 모형으로 제시

I

수고하셨습니다.