

기계학습
8강:군집분석

김 용 대
서울대학교 통계학과

1절. 군집분석 입문

군집분석의 정의

- 군집분석은 모집단 또는 범주에 대한 사전 정보가 없는 경우에
- 주어진 관측값들 사이의 거리 또는 유사성 을 이용하여
- 전체를 몇 개의 집단으로 그룹화 하여
- 각 집단의 성격을 파악함으로써
- 데이터 전체의 구조에 대한 이해를 돕고자 하는 분석법이다.

군집분석의 응용

- 고객 세그멘테이션 => 세그먼트별로 다른 마케팅 수행
- 예측모형을 만드는 경우에도 각 군집별로 다른 예측모형을 만들 수 있다 (예: 남녀별 모형, 소득별 모형 등)
- 데이터 압축: 검색 등에 응용

비유사성의 척도: 거리

- 군집분석에서는 관측값들이 서로 얼마나 유사한지 또는 유사하지 않은지를 측정할 수 있는 척도가 필요하다.
- 군집분석에서는 보통 유사성(similarity)보다는 비유사성(dissimilarity)을 기준으로 하며 거리(distance)를 사용한다.
- 거리의 정의: 두 점 x 와 y 의 거리 $d(x,y)$ 는 다음을 만족한다.
 - $d(x,y)=0 \Rightarrow x=y$
 - $d(x,y) \geq 0$
 - $d(x,y)=d(y,x)$
 - $d(x,y) \leq d(x,z)+d(z,y)$ (triangular inequality)

거리 측정의 종류들

➤ 유클리드(Euclid) 거리


➤ p 차원 공간에서 주어진 두 점 $x=(x_1, \dots, x_p)$ 와 $y=(y_1, \dots, y_p)$ 사이의 유클리드 거리 $d(x, y)$ 는

$$d(x, y) = \left(\sum_{i=1}^p (x_i - y_i)^2 \right)^{1/2}$$

로 정의 된다.

➤ $p=2$ 인 경우

$$d(x, y) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2}$$



거리 측도의 종류들(계속)

➤ Minkowski 거리

$$d(x, y) = \left(\sum_{i=1}^p (x_i - y_i)^m \right)^{1/m}$$

➤ 표준화 거리

$$d(x, y) = \left(\sum_{i=1}^p ((x_i - y_i) / s_i)^2 \right)^{1/2}$$

➤ Mahalanobis 거리

$$d(x, y) = \mathbf{x}' \Sigma^{-1} \mathbf{y}$$

범주형 자료의 거리

➤ 불일치 항목수

➤ 예

개체	성별	학력	출신지역
A	남자	고졸	경기
B	여자	고졸	전남
C	남자	대졸	경기

$$d(A,B)=2, d(A,C)=1, d(B,C)=3$$

군집분석의 유형

➤ 상호배반적(disjoint) 군집

- 각 관찰치가 상호배반적인 여러 군집 중 오직 하나에만 속함
- 예: 한국인, 중국인, 일본인

➤ 계보적(hierarchical) 군집

- 한 군집이 다른 군집의 내부에 포함되는 형태로 군집간의 중복은 없으며, 군집들이 매 단계 계층적인(나무) 구조를 이룬다.
- 예: 전자제품 -> 주방용 -> 냉장고

군집분석의 유형(계속)

➤ 확률 군집

- 관찰치가 소속되는 특정한 군집을 표현하는 것이 아니라, 각 군집에 속할 가능성을 표현
- $\text{Pr}(\text{개체가 군집 A에 속함})=0.7$, $\text{Pr}(\text{개체가 군집 B에 속함})=0.3$

군집분석의 특징

- 군집분석은 그 기준의 설정, 즉 유사성이나 혹은 비유사성의 정의나 군집의 형태 등 매우 다양한 방법이 있다.
- 군집분석은 자료의 사전정보 없이 자료를 파악하는 방법으로, 분석자의 주관에 결과가 달라질 수 있다.
- 따라서, 군집분석은 한번에 분석이 끝나는 것이 아니고, 매회 결과를 잘 관찰하여 의미 있는 정보요약을 얻어내야 한다.
- 특이값을 갖는 개체의 발견, 결측값의 보정 등에 군집분석이 사용될 수 있다.
- 군집분석에서 군집을 분석하는 중요한 변수의 선택이 중요하다.

2절. 계층적 군집분석

계층적 군집분석의 개요


- 가까운 관측값들 끼리 묶는 병합(agglomeration)방법과 먼 관측값들을 나누어가는 분할(division) 방법으로 나눌 수 있다.
- 계층적 군집분석에서는 주로 병합 방법이 주로 사용된다.
- 계층적 군집분석의 결과는 나무구조인 덴드로그램(dendrogram)을 통해 간단하게 나타낼 수 있고, 이를 이용하여 전체 군집들간의 구조적 관계를 쉽게 살펴볼 수 있다.

병합방법

- 처음에 n 개의 자료를 각각 하나의 군집으로 생각한다. 즉 군집의 수는 n 이다.
- 이 n 개의 군집 중 가장 거리가 가까운 두 개의 군집을 병합하여 $n-1$ 개의 군집으로 군집을 줄인다.
- 그 다음, $n-1$ 개의 군집 중 가장 가까운 두 군집을 병합하여 군집을 $n-2$ 개로 줄인다.
- 이를 반복하여 계속하여 군집의 수를 줄여 나간다.
- 이 과정은 시작부분에는 군집의 크기는 작고 동질적이며, 끝부분에서는 군집의 크기는 커지고 이질적이 된다.

병합방법(계속)

- 군집들간의 거리를 측정하는 방법에 따라 다양한 종류의 방법이 있다.
- 최단거리, 최장거리, 평균거리 방법 등이 있다.



[그림5-1] 군집 사이의 거리

최장(완전)연결법(Complete Linkage Method)

- 두 군집 사이의 거리를 각 군집에서 하나씩 관측값을 뽑았을 때 나타날 수 있는 거리의 최대값으로 측정
- 같은 군집에 속하는 관측치는 알려진 최대 거리보다 짧다.
- 군집들의 내부 응집성에 중점을 둔다.

최장연결법:예제

➤ 다음에 주어진 5개의 관측값에 대한 거리 행렬 (유사성 행렬)에 대하여 최장연결법으로 군집을 얻고 덴드로그램으로 나타내보자.

1	0				
2	7	0			
3	1	6	0		
4	9	3	8	0	
5	8	5	7	4	0

최장연결법:예제(계속)

➤ 1단계

- 1단계는 최단연결법의 1단계와 같다. 즉, 관측값 1과 3이 최단거리에 위치하고 이를 묶어서 새로운 군집 (1,3)을 만든다.

- 군집 (1,3)과 관측값 2,4,5와의 거리

$$\diamond d((2),(1,3)) = \max\{d(2,1), d(2,3)\} = d(2,1) = 7$$

$$\diamond d((4),(1,3)) = \max\{d(4,1), d(4,3)\} = d(4,1) = 9$$

$$\diamond d((5),(1,3)) = \max\{d(5,1), d(5,3)\} = d(5,1) = 8$$

를 구하여 다음과 같은 거리 행렬을 만든다.

최장연결법:예제(계속)

(1,3)	0			
2	7	0		
4	9	3	0	
5	8	5	4	0

➤ 2단계

- 다음의 거리 행렬에서 $d(2,4)=3$ 이 최소값을 가지므로 관측값 2와 4를 묶어 군집 (2,4)를 만든다.

최장연결법:예제(계속)

➤ 2단계 (계속)

- 군집 (2,4)와 군집 (1,3), (5)와의 거리를 구한 후

$$\diamond d((2,4),(1,3)) = \max\{d((2),(1,3)), d((4),(1,3))\} = d((4),(1,3)) = 9$$

$$\diamond d((5),(2,4)) = \max\{d(5,2), d(5,4)\} = d(2,4) = 5,$$

거리 행렬을 다시 다음과 같이 만든다.

(1,3)	0		
(2,4)	9	0	
5	7	5	0

최장연결법:예제(계속)

➤ 3단계

- $d((5),(2,4))=4$ 이 최소값을 가지므로 군집 (2,4)와 (5)를 묶어 (2,4,5)를 만든 후 $d((1,3),(2,4,5))=d(1,4)=9$ 을 이용하여 다음의 거리행렬을 얻는다.

(1,3)		0	
(2,4,5)		9	0


최장연결법:예제(계속)

➤ 4단계

- 마지막 단계로 전체가 하나의 군집을 이룬다.

최장연결법:예제(계속)

- 덴드로그램을 그리면 다음과 같다.



3절. 비계층적 군집분석

비계층적 군집분석의 개요

- 비계층적 군집분석에는 흔히 관측값들을 몇 개의 군집으로 나누기 위하여 주어진 판정기준을 최적화 한다.
- 따라서, 최적분리 군집분석이라고 한다.
- 대표적인 비계층적 군집분석 방법이 k-평균 방법이다.

K-평균 군집방법

- 사전에 결정된 군집수 k 에 기초하여
- 전체 데이터를 상대적으로 유사한 k 개의 군집으로 구분한다.
- k -평균 군집법은 계보적 군집법에 비하여 계산량이 적다.
- 따라서, 대용량 데이터를 빠르게 처리할 수 있다.


K-평균 군집법의 알고리즘

- 군집수 k 를 결정한다.
- 초기 k 개 군집의 중심을 선택한다.
- 각 관찰치를 그 중심과 가장 가까운 거리에 있는 군집에 할당한다.
- 위의 과정을 기존의 중심과 새로운 중심의 차이가 없을 때까지 반복한다.


알고리즘 설명

➤ 다음의 그림을 생각하자

〈그림 7-3〉
k-평균 군집법
: 초기 군집의 중심



〈그림 7-4〉
k-평균 군집법
: 중심의 이동



알고리즘 설명(계속)

- 그림 7-3은 거리를 표현하는 변수가 x_1, x_2 로 하여 2차원으로 표현한 각 관찰치의 위치이다.
- 그림을 보고 먼저, 군집수를 3으로 결정한다.
- 자료를 임의로 3등분하여 각각의 평균을 각 군집의 평균으로 정한다.
- 그림 7-4와 같이 주어진 군집의 중심을 기준으로 관찰치를 가장 가까운 군집에 할당한다.
- 새로운 군집의 생기면 각 새로운 군집의 중심을 각 군집의 평균으로 갱신한다. 그림 7-4에서 회색점이 과거 중심이고 검은점이 갱신된 중심이다.

초기군집수의 결정

- K-평균 군집분석법의 결과는 초기 군집수 k 의 결정에 민감하게 반응한다.
- 실제 자료의 분석에서는 여러 가지의 k 값을 선택하여 군집분석을 수행한 후 가장 좋다고 생각되는 k 값을 이용한다.
- 여러 개의 군집분석 결과 중 어떤 결과가 좋은가 하는 문제는 군집내의 관측값 간의 평균 거리와 군집간의 평균거리를 비교함으로써 수행한다.
- 가장 좋은 방법은 자료의 시각화를 통한 최적 군집수의 결정인데, 자료의 시각화를 위하여는 차원의 축소가 필수적이고, 이를 위하여 주성분 분석방법이 널리 사용된다.
- 시각화가 어려운 경우에는, 여러 가지 통계량을 사용하는데, 예를 들면, 각 그룹의 산포행렬의 행렬식을 최소로 하는 군집수를 찾는다.

단위 변환

- 군집분석은 자료 사이의 거리를 이용하여 수행되기 때문에, 각 자료의 단위가 결과에 큰 영향을 미친다.
- 예를 들면, (x,y,z) 세 개의 변수가 어떤 거리를 측정하였다고 했을 때, 그 단위가 x 는 야드, y 는 센티미터, z 는 마일로 측정되었다면, 그 거리의 계산에 유의하여야 한다.
- z 의 단위 1의 차이는 y 의 단위 185,200의 차이와 같고, x 의 2,025와 같다.
- 만약, 서로 다른 종류의 측정치로 자료가 구성되어 있으면, 위와 같은 상대적인 평가도 불가능 하다.
- 예를 들면, 대지면적, 수입, 건평 등으로 이루어진 자료는 각 변수가 서로 비교될 수 가 없다.

단위 변환(계속)

- 이러한 문제를 해결하기 위하여, 가장 널리 쓰이는 방법이 표준화 방법이다.
- 표준화 방법이란 각 변수의 관찰값으로부터 그 변수의 평균을 빼고, 그 변수의 표준편차로 나누는 것이다.
- 표준화된 자료는 모든 변수가 평균이 0이고 표준편차가 1이 된다.
- 표준화된 자료의 유클리드거리는 표준화거리와 같다.

4절. 군집분석의 장단점

군집분석의 장점

- 탐색적인 기법: 주어진 자료의 내부구조에 대한 사전정보 없이 의미있는 자료구조를 찾아낼 수 있다.
- 다양한 형태의 데이터에 적용가능: 거리만 잘 정의되면, 모든 종류의 자료에 적용할 수 있다. 예를 들면, 신문기사와 같은 텍스트 자료도 그 거리만 잘 정의하면 얼마든지 군집분석을 사용할 수 있다.
- 분석방법의 적용 용이성: 자료의 사전정보를 필요로 하지 않아서 누구나 쉽게 분석할 수 있다.

군집분석의 단점

- 거리 정의: 거리를 어떻게 정의하는가에 따라 군집분석의 결과가 아주 민감하게 반응한다.
- 초기 군집수 k 의 결정이 쉽지 않다.
- 불필요한 변수가 많은 경우에 결과가 안좋은 경향이 있다.
- 결과의 해석이 어렵다. 특히, 찾아진 군집이 무엇을 의미 하는지 데이터만을 이용해서는 알 수가 없다.

Thank you!