

9강. AI와 데이터사이언스

김용대¹


서울대학교 통계학과¹

목차

- 1절. 인공지능의 두 얼굴: 자동화 vs 지능화
- 2절: 인공지능 기술 동향
- 3절. 딥러닝을 이용한 이상치 탐색
- 4절: Foundation모델을 이용한 데이터표준화
- 5절: 예측을 위한 Foundation model
- 6절. 결론

1절: 인공지능의 두 얼굴: 자동화 **vs** 지능화

IT혁명의 역사



IT transformation의 흐름

IT transformation: IT 기술로 인한 우리 생활의 변화

**Digital
Transformation**



**Data
Transformation**



**AI
Transformation**



Client server and internet
1990s~2000s




Cloud, mobile and big data
2000s~2010s



Intelligent technologies
2010s~2020s

Digital transformation

Transformation of our business by use of digital technologies



Data transformation

Transformation of our way of thinking by use of data technologies



Netflix movie recommendation



Durg discovery



AI transformation

Digital Transformation + Data Transformation

Automation + Intelligence

AI의 두얼굴

자동화 vs 지능화




Figure 1: The Transformer - model architecture.



Windows 정품 인증

[이제부터 윈도우와 Windows를 정품 인증합니다.]

인공지능을 위한 데이터

- AI를 위한 알고리즘을 데이터에서 찾음
- 기계학습: 데이터에서 AI알고리즘을 찾는 방법론
- 딥러닝: 기계학습의 하나의 방법론, AI에 매우 적합한 기계학습 알고리즘
- 응용분야
 - 이미지 인식 및 생성
 - 음성 인식 및 생성
 - 언어 인식 및 생성
- 인간 지적 활동의 자동화
- 데이터에 noise가 적음

데이터를 위한 인공지능

- 데이터 기반 의사결정을 위해서 AI방법론 사용
- 응용분야
 - 시장예측
 - 유전자 탐색
 - 마케팅 효과 측정
 -
- 데이터로부터 새로운 지식 탐색
- 데이터과학의 한 분야
- 데이터에 노이즈가 많음




2절: 인공지능 기술 동향

• 인공 신경망(Artificial Neural Network)


- 기계 학습(Machine Learning)의 한 분야로, 생물학의 뇌 구조(신경망)를 모방하여 만든 수학적인 모델.
- 인간의 뇌가 문제를 해결하는 방식과 유사하게 구현.

• 인공 신경망의 역사

- 1943년, W.S.McCulloch와 W.Pitts의 MP-model
- 1957년, F.Rosenblatt의 single layer perceptron
- 1986년, D.E.Rumelhart의 multilayer perceptrons (backpropagation 알고리즘 개발)
- 2006년, G.E.Hinton의 Deep neural network에서의 혁신적인 학습 방법 개발.



Fully connected Neural Network




이미지, 언어 등 특별한 구조를 가지는 데이터에는 적합하지 않음!

Windows 정품 인증


Convolutional Neural Network (CNN)

이미지 데이터에 특화된 인공신경망




Recurrent Neural Network (RNN)

언어데이터에 특화된 인공신경망 (예: 번역)



Neural Network for Image generation




Noise



Image


Windows 정품 인증

Neural Network for image to text



Windows 첫눈 인종

Transformer



- 멀리 떨어져 있는 단어들 사이의 관계 파악이 어려움
- 예
 - Question: "Marry went to the room, and Jane went to the room too. Jane said 'hi' to ()."
 - Answer: 'Marry'
- The answer is the first word while the question locates at the 17th position.

Transformer

Attention Is All You Need

Ashish Vaswani*
Google Brain
avaswani@google.com

Noam Shazeer*
Google Brain
noam@google.com

Niki Parmar*
Google Research
nikip@google.com

Jacob Uszkoreit*
Google Research
usz@google.com


Llion Jones*
Google Research
llion@google.com

Aidan N. Gomez*[†]
University of Toronto
aidan@cs.toronto.edu

Lukas Kaiser*
Google Brain
lukasz.kaiser@google.com

Illia Polosukhin*[†]
illia.polosukhin@gmail.com

2017




Windows 정품 인증
정품 인증을 받으려면 Windows Hello를 사용하십시오.

Transformer

트랜스포머 (Transformer)


- Attention을 이용한 언어 번역 신경망모형



Windows 정품 인증

Transformer


기존 언어 모델을 압도하는 뛰어난 번역 성능으로 큰 주목을 받음



출처: <https://arxiv.org/pdf/1609.08144v2.pdf>

3절: 딥러닝을 이용한 이상치 탐색

딥뉴럴네트워크



딥뉴럴네트워크

- $\mathbf{z}^{(l+1)} = \mathbf{A}_l \mathbf{h}^{(l)} + \mathbf{b}_l$
- $\mathbf{h}^{(l+1)} = \sigma(\mathbf{z}^{(l+1)})$ for $l = 0, \dots, L - 1$
- $\Pr(Y = j | \mathbf{x}) = f_j(\mathbf{x}) \propto \exp(-\mathbf{h}^{(L)}(\mathbf{x})^\top \gamma_j)$.

Memorization effect

- 딥러닝의 특징 중 하나는 모형이 매우 유연하여 데이터를 완벽하게 분류할 수 있음 (easily overfit)
- 딥러닝이 데이터를 overfit할 때, 학습이 진행되면서 정상데이터를 먼저 overfit하고 이상치를 나중에 overfit하는 현상이 있고, 이러한 현상을 **Memorization effect (ME)** 라고 함.
- Label noise 문제 (분류문제에서 label이 잘 못 부여된 데이터 탐지)에 널리 사용됨

Label noise problem

- 데이터: $(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)$ 이고 $\mathbf{x}_i \in \mathbb{R}^p, y_i \in \{-1, 1\}$.
- Label noise 문제
 - y_i^{gt} 를 i 번째 관측치의 실제 속하는 그룹의 라벨
 - 몇몇 관측치에서 관측라벨 y_i 가 실제라벨 y_i^{gt} 와 다른 경우
 - 분석의 목적은 라벨이 잘못 붙여진 데이터 $\{i : y_i \neq y_i^{\text{gt}}\}$ 를 찾는 것이다.
 - 이 문제의 어려운 점은 실제라벨 y_i^{gt} 이 전혀 관측되지 않는다는 것이다.


Label noise가 생기는 이유 및 해결책

- 보통 라벨은 사람이 붙이는데, 사람의 실수로
- 최근에는 인공지능을 이용한 라벨링이 널리 사용되는데, 인공지능 알고리즘이 부정확해서
- Label noise알고리즘을 적용해서 탐지된 데이터에 대해서, 전문가가 한번 더 확인하므로써, 데이터의 품질 향상 가능

Memorization effect를 이용한 Label noise 탐지방법

- 먼저, 딥뉴럴네트워크를 데이터에 살짝 적합한다.
- 여기서, ‘살짝’이란 DNN을 학습하는 알고리즘을 10번 미만으로 돌린다 (참고: 보통은 수천번 돌림).
- 살짝 학습된 딥뉴럴네트워크가 잘 못 맞추는 데이터를 골라내서 noise label 데이터라고 판단한다.

Memorization effect를 이용한 Label noise 탐지방법



Memorization effect를 이용한 이상치탐색

- 딥뉴럴네트워크의 Memorization effect를 성질을 이용해서 이상치 탐색도 가능함.
- 이상치 탐색을 하는 일반적인 프로세스
 - 데이터의 분포를 추정한다 (정규분포가정, 비모수적 방법)
 - 데이터에 이상치가 있기 때문에, 보통 robust한 방법으로 분포를 추정한다.
 - 추정된 분포에서 많이 벗어나는 데이터 (추정된 분포에서 확률이 작은 데이터)를 이상치로 판단한다.

Memorization effect를 이용한 이상치탐색

- 일반적인 이상치 탐지 프로세스의 어려움
 - Robust하게 분포를 추정하는 것이 기술적으로 매우 어려움.
 - 정규분포를 가정하면 상대적으로 쉬우나, 비모수적 robust분포 추정은 쉽지 않음.
 - 특별히, 데이터의 다중공선성이 강한 경우 일반적인 방법들의 효율이 급격히 떨어짐.
- 분포를 추정하는 DNN의 Memorization effect를 이용하면 매우 효율적으로 이상치 탐색이 가능함!

딥 생성모형

- Data: $\mathbf{x}_1, \dots, \mathbf{x}_n$ 이고 확률변수 $\mathbf{X} \in \mathbb{R}^p$ 의 independent realization이라고 가정
- 목적: $\mathbf{X}$ 의 분포 추정
- 확률적 생성모형
 - Let $\mathbf{X} = f(\mathbf{Z}) + \epsilon$, where $\mathbf{Z} \sim N_q(0, \mathbb{I})$ and ϵ is a noise.
 - 비선형 요인모형 (nonlinear factor model)
 - f 의 추정을 통해서 $\mathbf{X}$ 의 분포를 추정
- 학습알고리즘
 - Likelihood based: Variational autoencoder (VAE) and its variations
 - Adversarial learning: Generative adversarial network (GAN) and its variations
 - Diffusion models, Normalized flow and ...

딥생성모형을 이용한 이상치 탐색

- 주어진 데이터를 딥생성모형으로 살짝 적합한다.
- 여기서, ‘살짝’이란 딥생성모형을 학습하는 알고리즘을 10번 미만으로 돌린다 (참고: 보통은 수천번 돌림).
- 살짝 학습된 딥생성모형이 잘 생성하지 못하는 데이터를 골라내서 이상치로 판단한다.
- ODIM (Outlier Detection via Inlier Memorization effect): Dongha Kim et al. (2024, ICML)

Numerical results: accuracy

Table 1: Averaged AUC and AP scores over 30 tabular datasets.




Method	OCSVM	LoF	IF	COPOD	ECOD	DeepSVDD	RSRAE	ODIM
AUC	0.706	0.649	0.781	0.749	0.749	0.643	0.656	0.790
AP	0.309	0.228	0.381	0.335	0.343	0.196	0.277	0.398

Table 2: Results of AUC scores on image and text data.

Method	OCSVM	LoF	IF	COPOD	ECOD	DeepSVDD	RSRAE	ODIM
MNIST	0.847	0.703	0.819	0.774	0.767	0.753	0.902	0.836
FMNIST	0.874	0.497	0.909	0.867	0.843	0.808	0.844	0.909
CIFAR10	0.659	0.675	0.878	0.902	0.884	0.617	0.866	0.921
MNIST-C	0.726	0.567	0.717	0.714	0.720	0.540	0.710	0.740
MVTec-AD	0.726	0.851	0.832	0.805	0.816	0.639	0.801	0.900
WM-811K	0.731	0.327	0.680	0.704	0.695	0.505	0.672	0.747
20News	0.649	0.727	0.645	0.646	0.645	0.513	0.636	0.702
Agnews	0.658	0.764	0.681	0.686	0.672	0.522	0.649	0.804
Idmb	0.496	0.524	0.517	0.499	0.494	0.485	0.491	0.519
Yelp	0.588	0.661	0.611	0.607	0.580	0.505	0.589	0.669


4절: **Foundation** 모형^을 이용한 데이터표준화

다양한 DNNs




Transformer

- Attention을 이용한 언어 번역 신경망모형




Visual transformer




Foundation model


- 대규모의 데이터를 학습, 다양한 AI 작업을 수행할 수 있도록 설계된 인공지능 모형



Contrastive Language-Image Pretraining (CLIP)



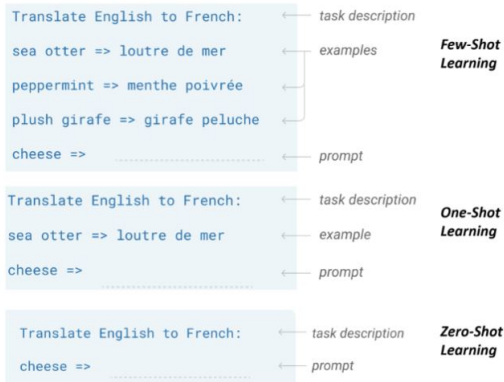
Foundation model을 이용한 데이터 표준화: 이상치 탐지 예제



ResAD: A Simple Framework for Class Generalizable Anomaly Detection (ICLR, 2024)

5절: 예측을 위한 foundation model

In-context learning이란?



(source: Foundation Models in Brief: A Historical Socio-Technical Focus)

In-context learning의 해석

- In-context learning중 어떠한 parameter update를 전혀 하지 않음.
- LLM은 이미 세상의 모든 문서를 학습해 놓았음.
- 인간이 할 일은 LLM이 가지고 있는 정보를 잘 뽑아 내는 것임
- Prompt engineering은 이러한 작업을 하는 것임.
- 통계학적으로 보면 LLM은

$$\mathbb{P}(Y = y | \mathbf{X} = \text{prompts})$$

을 이용해서 정보 (y)를 제공하는데, 우리가 원하는 올바른 정보를 얻기 위해서는 $\mathbf{X}$ 를 잘 넣어줘야 함.

- $\mathbf{X}$ 를 sequential하게 update하는 과정이 prompt engineering 임.

예측모형에서의 In-context learning

- 세상의 모든 데이터를 학습해 놓으면 어떻게 될까?
- 이 경우, 새로운 데이터를 prompt라 해석하면, LLM이 따로 parameter의 학습 없이 예측이 가능할 수도 있을 것임.
- 이러한 상상이 실현되려면, 세상의 모든 데이터를 모아야 하나 거의 불가능함 (데이터는 보통 외부에 공개 안함)
- 2025년에 스위스의 연구진들은 가상으로 데이터를 엄청나게 생성하여 이러한 목적을 달성함.

예측모형에서의 In-context learning

In context Data Analysis

X로 y를 예측하는거야.

X1 => y1

X2 => y2

X3 => y3

X4 => ??

No model training at all!

nature

Explore content ▾ About the journal ▾ Publish with us ▾

[nature](#) > [articles](#) > [article](#)

Article | [Open access](#) | Published: 08 January 2025

Accurate predictions on small data with a tabular foundation model

Noah Hollmann , Samuel Müller , Lennart Purucker, Arjun Krishnakumar, Max Körfer, Shi Bin Hoo, Robin Tibor Schirrmeyer & Frank Hutter 

Nature 637, 319–326 (2025) | [Cite this article](#)


Analyzing first, Collecting later!

TabPFN


- Tabular data Prior-data Fitted Network (Hollman et al. 2022, NeurIPS)
- 알고리즘의 핵심은 가상의 데이터를 다양하게 그러나 실제 상황과 비슷하게 생성하는 것임.
- 이를 위하여, 연구진은 Structural Causal Model (SCM) probability model을 개발하였음.
- 900만개 이상의 가상 데이터 (각 데이터의 크기는 $n = 1000, p = 100$)를 생성하여 LLM을 학습

SCM prior


- Tabular data: causal relationships between columns.
- Sample DAG structure & deterministic functions.
 - 1 Sample MLP structure(layers, nodes) and its weights(E_{ij}).
 - 2 Drop a random set of edges (MLP with dropped edges = DAG structure).
 - 3 Sample feature nodes and a label node.
 - 4 Sample noise distribution $p(\epsilon) \sim P(p(\epsilon))$.
 - 5 Sample noise variables $\epsilon_i \sim p(\epsilon)$.
 - 6 Compute node values as $z_i = a((\sum_{j \in PA_{\mathcal{G}(i)}} E_{ij} z_j) + \epsilon_i)$.
 - 7 Retrieve the values of feature nodes and the output node.



(a) A BNN




(b) An SCM



(c) SCMs sampled from the prior

Figure 2: Overview of graphs generating data in our prior. Inputs x are mapped to the output y through unobserved nodes z . Plots based on Müller et al. (2022).


Performance




TabPFN2

- TabPFN의 규모를 확대한 것 (Hollman et al. 2025, Nature)
- 1억개 이상의 데이터set ($n = 10000$, $p = 500$)으로 LLM을 학습
- Categorical input도 수용 가능하고, regression과 classification문제뿐 아니라 robust regression과 density 추정도 in-context로 가능

SCM prior for TabPFN2



Performance



6절: 결어

개인적인 소고

- DNN은 인공지능 문제들 (image, language, voice등의 인지 및 생성)에서 매우 우수한 성능을 보인다.
- 오늘의 강연에서는 DNN이 데이터분석에서도 좋은 도구로 사용될 수 있다는 것을 보았다.
- 특히, 데이터 분석에서 **DNN**이 단순히 기존의 방법론의 효율적인 대체재가 아니라, 새로운 도구이다!

고맙습니다