

부록

군집분석 예제

담당 교수 : 김 용 대
(ydkim903@snu.ac.kr)

군집분석 실습: 시리얼 예제 자료

➤ 시리얼 자료 (**cereal.csv**) : 미국에서 판매되는 77가지 시리얼의 영양성분과 위치에 관한 자료.

➤ 변수명

- Name : 시리얼의 이름
- Mfr : 시리얼 제조사
- Type : 조리 방법 (cold/hot)
- Calories : 1회 제공량 당 칼로리
- Protein : 단백질 함량 (g)
- Fat : 지방 함량 (g)
- Sodium : 소금 함량 (mg)
- Fiber : 식이섬유 함량 (g)
- Carbo : 복합탄수화물 함량 (g)
- Sugars : 설탕 함량 (g)
- Potass : 칼륨 함량 (mg)
- Vitamins : FDA 기준치 대비 비타민, 미네랄 함량 %
- Shelf : 진열대 위치
- Weight : 1회 제공량 당 무게 (온스)
- Cups : 1회 제공량 당 컵 단위
- Rating : 소비자 조사에 의한 평점

군집분석 실습: 씨리얼 예제 자료

- 칼로리, 단백질, 지방, 소금, 식이섬유, 복합 탄수화물, 설탕, 칼륨, 그리고 비타민 함량의 9개의 변수를 선택하여 이용하기로 한다.
- **Missing value**가 있는 자료는 삭제하기로 한다.

```
In [56]: cereal.isnull().sum(axis=1)==0
...: cereal_com = cereal.ix[cereal.isnull().sum(axis=1)==0,:]
...: cereal_com.isnull().sum(axis=1)
...: sum(cereal_com.isnull().sum(axis=1))
...: cereal_com = cereal_com.ix[:,["name","calories","protein","fat","sodium","fiber","carbo","sugars","potass","vitamins"]]
...: cereal_com.index = cereal_com.ix[:, "name"]
...: cereal_com = cereal_com.ix[:,["calories","protein","fat","sodium","fiber","carbo","sugars","potass","vitamins"]]
```

군집분석 실습: 씨리얼 예제 자료

- 변수 선택 및 결측치 제거 후 74개의 관측치와 9개의 변수로 이루어진 자료를 얻는다.
- 각 변수간의 단위를 맞춰주기 위해, 각 변수의 표준편차로 나누어준다.

```
In [60]: cereal_rsc = cereal_com / cereal_com.std()
...: cereal_rsc.std()
Out[60]:
calories    1.0
protein     1.0
fat         1.0
sodium      1.0
fiber       1.0
carbo       1.0
sugars      1.0
potass      1.0
vitamins    1.0
dtype: float64
```

군집분석 실습: 계층적 군집분석

➤ 계층적 군집분석

- 계층적 군집분석을 결정짓는 두 요인 : 거리 측정 & 연결 방법

1. 거리 측정 : `metric()` – 거리 행렬을 계산

- 가능한 방법 : **Euclid**


2. 군집 분석 : `method()` – 군집 분석 방법을 선택

- 가능한 방법 : **complete, single, average**

군집분석 실습: 계층적 군집분석

- 계층적 군집분석 – 최장 연결법


```
In [66]: hclust = linkage(cereal_com, method = 'complete')  
  
In [67]: plt.figure(figsize=(15, 6))  
...: plt.title('Hierarchical Clustering Dendrogram')  
...: plt.xlabel('index')  
...: plt.ylabel('distance')  
...: dendrogram(  
...:     hclust,  
...:     leaf_rotation=90.,  
...:     leaf_font_size=8.,  
...: )  
...: plt.show()
```



군집분석 실습: 계층적 군집분석

- 계층적 군집분석 – 최단 연결법


```
In [68]: hclust = linkage(cereal_com, method = 'single')  
  
In [69]: plt.figure(figsize=(15, 6))  
...: plt.title('Hierarchical Clustering Dendrogram')  
...: plt.xlabel('index')  
...: plt.ylabel('distance')  
...: dendrogram(  
...:     hclust,  
...:     leaf_rotation=90.,  
...:     leaf_font_size=8.,  
...: )  
...: plt.show()  
...:
```




군집분석 실습: 계층적 군집분석

- 계층적 군집분석 – 평균 연결법

```
In [70]: hclust = linkage(cereal_com, method = 'average')
In [71]: plt.figure(figsize=(15, 6))
...: plt.title('Hierarchical Clustering Dendrogram')
...: plt.xlabel('index')
...: plt.ylabel('distance')
...: dendrogram(
...:     hclust,
...:     leaf_rotation=90.,
...:     leaf_font_size=8.,
...: )
...: plt.show()
```



군집분석 실습: 최장연결법 선택



군집분석 실습: 계층적 군집분석

- 계층적 군집 분석 – 군집내 비교 (최장 연결법)
 - 각 군집에서 각 변수의 평균과 분산 계산

	Calories	Protein	Fat	Sodium	Fiber	Carbo	Sugars	Potas	Vitamins
평균(1)	3.19	3.72	0.66	2.13	4.54	1.71	0.84	4.37	1.12
분산(1)	0.34	0	0.33	0.76	1.19	0.15	0.54	0.14	0
" (2)	6.32	2.96	1.63	2.07	1.71	3.47	2.44	2.71	1.43
" (2)	1.24	0.14	1.24	0.26	0.22	0.38	0.44	0.28	1.03
" (3)	4.87	2.01	0.72	0.56	0.64	3.42	1.61	0.99	0.75
" (3)	1.05	0.64	1.72	0.44	0.30	0.67	1.75	0.37	0.30
" (4)	5.53	2.21	0.97	2.52	0.53	4.17	1.49	1.00	1.52
" (4)	0.30	1.12	0.60	0.31	0.23	0.85	0.68	0.21	1.22

군집분석 실습: 계층적 군집분석

- 계층적 군집 분석 – 군집내 비교 (최장 연결법)
 - 각 군집에서 각 변수의 평균과 분산 계산

	Calories	Protein	Fat	Sodium	Fiber	Carbo	Sugars	Potas	Vitamins
평균(1)	3.19	3.72	0.66	2.13	4.54	1.71	0.84	4.37	1.12
분산(1)	0.34	0	0.33	0.76	1.19	0.15	0.54	0.14	0
" (2)	6.32	2.96	1.63	2.07	1.71	3.47	2.44	2.71	1.43
" (2)	1.24	0.14	1.24	0.26	0.22	0.38	0.44	0.28	1.03
" (3)	4.87	2.01	0.72	0.56	0.64	3.42	1.61	0.99	0.75
" (3)	1.05	0.64	1.72	0.44	0.30	0.67	1.75	0.37	0.30
" (4)	5.53	2.21	0.97	2.52	0.53	4.17	1.49	1.00	1.52
" (4)	0.30	1.12	0.60	0.31	0.23	0.85	0.68	0.21	1.22

- 그룹1: 건강식 시리얼 (저칼로리, 고단백, 고섬유질, 저탄수화물)

군집분석 실습: 계층적 군집분석

- 계층적 군집 분석 – 군집내 비교 (최장 연결법)
 - 각 군집에서 각 변수의 평균과 분산 계산

	Calories	Protein	Fat	Sodium	Fiber	Carbo	Sugars	Potas	Vitamins
평균(1)	3.19	3.72	0.66	2.13	4.54	1.71	0.84	4.37	1.12
분산(1)	0.34	0	0.33	0.76	1.19	0.15	0.54	0.14	0
" (2)	6.32	2.96	1.63	2.07	1.71	3.47	2.44	2.71	1.43
" (2)	1.24	0.14	1.24	0.26	0.22	0.38	0.44	0.28	1.03
" (3)	4.87	2.01	0.72	0.56	0.64	3.42	1.61	0.99	0.75
" (3)	1.05	0.64	1.72	0.44	0.30	0.67	1.75	0.37	0.30
" (4)	5.53	2.21	0.97	2.52	0.53	4.17	1.49	1.00	1.52
" (4)	0.30	1.12	0.60	0.31	0.23	0.85	0.68	0.21	1.22

- 그룹 2 : 비 건강식 (칼로리, 지방, 설탕 함량 최다) – 건강 보다는 맛을 추구?


군집분석 실습: 계층적 군집분석

- 계층적 군집 분석 – 군집내 비교 (최장 연결법)
 - 각 군집에서 각 변수의 평균과 분산 계산


	Calories	Protein	Fat	Sodium	Fiber	Carbo	Sugars	Potas	Vitamins
평균(1)	3.19	3.72	0.66	2.13	4.54	1.71	0.84	4.37	1.12
분산(1)	0.34	0	0.33	0.76	1.19	0.15	0.54	0.14	0
" (2)	6.32	2.96	1.63	2.07	1.71	3.47	2.44	2.71	1.43
" (2)	1.24	0.14	1.24	0.26	0.22	0.38	0.44	0.28	1.03
" (3)	4.87	2.01	0.72	0.56	0.64	3.42	1.61	0.99	0.75
" (3)	1.05	0.64	1.72	0.44	0.30	0.67	1.75	0.37	0.30
" (4)	5.53	2.21	0.97	2.52	0.53	4.17	1.49	1.00	1.52
" (4)	0.30	1.12	0.60	0.31	0.23	0.85	0.68	0.21	1.22

- 그룹 3,4: 매우 유사


Hierarchical with complete in PCA




Hierarchical with single in PCA




Hierarchical with average in PCA




K-means in PCA




Hierarchical with complete in MDS




Hierarchical with single in MDS



Hierarchical with average in MDS



K-means in MDS



THANK YOU!