

부록

샘플링과 오즈비

담당 교수 : 김 용 대
(ydkim903@snu.ac.kr)

자료추출의 필요성

개 요

- 기계학습에 사용되는 자료는 일반적으로 매우 대 용량이다. (수 십 테라바이트, 수 백만명의 고객 등)
- 이러한 자료를 모두 이용하여 분석을 하는 경우 시간적, 금전적으로 많은 손해를 입을 수 있다.
- 적절한 양의 자료를 원자료로부터 추출하여 분석을 하는 것이 효과적일 수 있다.
- 물론, 문제에 따라 원자료를 다 사용해야 하는 경우도 있다

자료추출의 필요성

입력변수의 불균형

- 자료의 입력변수가 매우 심하게 불균형을 이룬 경우 원자료를 다 사용하는 것이 비효율적일 수 있다.

예 수입과 특정상품의 구매력과 관계

- 매우 고가의 상품에 대한 구매력의 경우, 그 구매력은 수입이 아주 많은 고객과 그렇지 않은 고객에서 많은 유의성을 보인다.
- 원자료에 수입이 아주 많은 고객은 그리 많지 않다.
- 수입이 아주 많은 고객에서 일정량의 자료를 추출하고 수입이 아주 많지 않은 고객에게서 일정량의 자료를 추출한 후 이를 이용하여 분석을 한다.

자료추출의 필요성

그룹간 분포의 불균형

- 분류 문제에서는 자료의 그룹간의 분포가 매우 불균형적인 경우가 많다.

예 부도에측 모형

- **목 적** : 재무자료 등을 이용하여 회사의 1년 후의 부도여부를 예측한다.
- **자 료** : 우리나라 과거 회사의 재무자료 및 부도여부
- **문제점** : 일반적으로 부도가 날 확률은 매우 적다. 따라서, 자료의 대부분이 건전한 회사이고 매우 극소수의 회사만이 부도를 경험한다. 이러한 자료를 모두 써서 분석하면, 유용한 정보를 찾기가 어려울 수 있다.
- **해결책** : 각 그룹에 따라, 적절한 자료를 추출한 후 분석한다.
- **예** : 부도회사 100개와 건전한 회사 100개를 추출하여 200개의 자료를 이용하여 분석한다.

자료의 추출과 결과의 해석

- 원자료가 아닌 추출된 자료를 사용할 경우 그 결과의 해석에 주의하여야 한다.
- 특히, 분류문제에서 확률을 추정할 경우 매우 주의하여야 한다.
- **예** : 부도예측예제에서 부도회사 100개와 건전기업 100개를 추출하여 분석을 한 경우 부도확률이 50% 부근에서 나타난다. 그러나, 실제 부도확률은 매우 작은 값이다.
- 본 부록에서는 자료를 추출하는 방법과 추출된 자료의 분석결과를 해석하는 방법에 대해서 배운다.

자료추출의 방법

- 자료를 추출하는 방법은 추출하는 목적에 따라 다르게 적용된다.

☞ 경우에 따른 적절한 자료 추출법

경 우 1 : 원 자료의 양이 너무 방대하여 자료의 일부분을 사용하여 분석할 경우 → 임의추출법 (Simple random sampling)

경 우 2 : 입력변수의 불균형을 해소하기 위하여 자료를 추출하는 경우 → 층화추출법 (Stratified sampling)

경 우 3 : 그룹변수의 불균형을 해소하기 위하여 자료를 추출하는 경우 → 사후추출법 (case-control sampling)

* 참고 : 경우 3의 경우 사후추출법(case-control sampling)은 일반적으로 사용되는 용어가 아니고, 본 강의에서만 사용함.

임의추출법

Simple Random Sampling

임의추출법은 원자료의 분포를 추출된 자료가 보존하도록 고안된 방법이다. 따라서, 추출된 자료에서의 분석결과는 원자료를 해석하는데 그대로 적용될 수 있다.

N 이 적당히 크면 (1000개 이상) 원자료와 추출된 자료의 분포는 거의 비슷하다.

- 원자료의 개수 = N , 이 중 n 개의 자료를 추출하려면?
 - 1 ~ N 의 숫자가 할당된 N 개의 공이 바구니에 들어있다고 생각하자.
 - 이 바구니로부터 n 개의 공을 비복원(한번 선택되어진 공은 바구니에 다시 넣지 않는다)방법으로 추출한다.
 - 선택되어진 n 개의 공에 대응되는 자료를 원자료로부터 추출한다.

층화추출법

Stratified Sampling

층화추출법은 입력변수에 따라 자료를 추출하는 방법이다.

층화추출법을 사용한 경우에는 추출된 자료의 분포는 원자료와 다르지만, 입력변수와 출력변수와 관계는 유지가 된다. 따라서, 추출된 자료를 사용하여 분석한 입력변수와 출력변수와의 관계는 원자료에도 그대로 적용될 수 있다.

- 입력변수가 두개의 값 0과 1을 갖을 때 (예: 남자 와 여자) 자료를 추출하려면?
 - 자료 중 입력변수가 1인 자료에서 임의추출법을 사용하여 n_1 개의 자료를 추출하고, 자료 중 입력변수가 0인 자료에서 임의추출법을 사용하여 n_2 개의 자료를 추출한다.
 - 두 자료를 합쳐서 분석을 한다.

사후추출법 (A posterior sampling)

Case-control Sampling

사후추출법은 원래 역학(epidemiology)에서 많이 사용되는 방법이다.

사후추출법으로 추출된 자료의 분포는 원자료의 분포와 매우 다르며, 또한 층화추출법과는 다르게 입력변수와 출력변수와의 관계도 다르다.

따라서, 분석 결과의 해석에 주의 하여야 한다.

사후추출법

분류문제에서 출력변수(그룹변수)의 분포가 매우 불균형을 이룬 경우에 사용한다.

- 암환자와 건강한 사람의 분포, 부도회사와 건전한 회사와의 분포
 - 두 그룹 분류문제의 경우 첫 번째 그룹에서 n_1 명의 자료를 임의추출법을 사용하여 추출하고 두 번째 그룹에서 n_2 명의 자료를 임의 추출한다.
 - 그리고, 이 두 자료를 모두 사용하여 분석한다.

사후추출법

발생빈도가 아주 낮은 병에 대한 그 병의 위험요인과의 관계를 알려고 할 때 사용되는 방법이다.

➤ 흡연이 암에 미치는 영향에 대한 연구

- **일반적 sampling**: 흡연자 100명과 비흡연자 100명을 추출하여 어느 쪽이 암 발생 확률이 높은지를 조사한다.
- **문제점**: 암의 발생확률이 매우 낮아서 200명의 자료 중 아무도 암에 걸리지 않을 확률이 매우 높다.
- **해결책**: 암환자 100명과 건강한 사람 100명을 추출하여 흡연 유무를 조사한다.

사후추출법의 결과의 해석

사후추출법으로 추출된 자료는 원자료와 그 분포가 매우 상이하여 분석 결과의 해석에 매우 조심하여야 한다.

➤ 두 그룹 분류 문제를 생각하자.

- $P(x)$ 를 원자료에서 입력변수 x 가 주어진 경우의 자료가 두번째 그룹에 속할 확률이라 하자. ($1-P(x)$ 는 입력변수 x 가 주어진 경우의 자료가 첫 번째 그룹에 속할 확률이다)
- $Q(x)$ 는 사후추출법으로 추출된 자료에서 입력변수 x 가 주어진 경우의 자료가 두번째 그룹에 속할 확률이라 하자. ($1-Q(x)$ 는 입력변수 x 가 주어진 경우의 자료가 첫 번째 그룹에 속할 확률이다)

사후추출법의 결과의 해석(계속)

- 일반적으로 $P(x)$ 와 $Q(x)$ 는 매우 다르다.
- 사후추출법으로 추출된 자료를 이용하면 확률 $Q(x)$ 를 추정하게 된다.
- 하지만, 관심사는 원자료에서의 확률 $P(x)$ 이다.
- 원자료에서 두 그룹의 분포를 아는 경우에는 이 정보를 이용하여 $Q(x)$ 로 부터 $P(x)$ 를 구할 수 있다.
- 많은 분류문제에서는 $P(x)$ 의 정확한 값보다는 두개의 주어진 입력변수 x_1 과 x_2 에 대하여 $P(x_1)$ 과 $P(x_2)$ 의 대소를 비교하는 것을 목적으로 한다.

사후추출법의 결과의 해석(계속)

예 : DM (Direct Mail) 발송

- 한 회사에서 전체 고객 10만명 중 구매확률이 높을 것으로 예상되는 10000명의 고객에게 DM을 발송하려고 한다.
- 이 경우, 알아야 할 사항은 각 고객의 상품구매확률이 아니라, 전체 고객 중 구매력이 큰 10000명이 고객이 누군가 하는 것이다.
- 즉, $P(x)$ 의 값은 알려지지 않아도, 전체 고객 10만명에 대하여 $P(x)$ 가 상위 10000명인 고객은 알 수 있으면 된다.

사전정보를 이용한 P(x)의 추정

- 원자료에서 첫번째 그룹에 속하는 자료의 수를 N1, 두 번째 그룹에 속하는 자료의 수를 N2라 하자 (사전정보)
- 추출된 자료에서 첫번째 그룹에 속하는 자료의 수를 n1, 두 번째 그룹에 속하는 자료의 수를 n2라 하자.
- 그러면, 다음의 관계가 성립된다.

$$P(x)/(1-P(x)) = Q(x)/(1-Q(x)) * N2*n1/(N1*n2)$$

Q(x)를 이용한 P(x)의 대소 비교

- 원자료의 정보가 없는 경우에도, Q(x)를 이용하여 P(x)의 대소를 알 수 있다.
- Q(x)와 P(x)사이에는 다음의 관계가 성립된다.
- 주어진 두개의 입력변수 x_1 과 x_2 에 대하여 만약 $Q(x_1) < Q(x_2)$ 이면 $P(x_1) < P(x_2)$ 를 만족한다.
- 앞의 DM예제에서, P(x)가 큰 상위 10000명의 선택은 Q(x)가 큰 상위 10000명과 같다.
- Q(x)와 같이 원자료의 P(x)와 대소가 같은 값을 스코어(score)라고 부른다.

사후추출법과 오즈비

- Theorem: $Q(x)$ 의 오즈비 = $P(x)$ 의 오즈비
- 즉, 오즈비는 사후추출에 대해서 변하지 않는다.
- 따라서, 선형로지스틱회귀모형은 사후추출 데이터에 대해서도 회귀계수를 추정할 수 있다.

수고하셨습니다.