

부록: 선형대수학 (linear algebra)

김용대¹

¹서울대학교 통계학과

벡터


- 좌표평면(추상적인 벡터공간)을 구성하는 원소이다.
- 벡터 $\mathbf{x} \in \mathbb{R}^n$

$$\mathbf{x} = (x_1, \dots, x_n)^\top = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}$$

- x_i 를 벡터 $\mathbf{x}$ 의 i 번째 성분이라고 하며, $\mathbf{x}$ 는 n 개의 성분으로 구성되어 있다.
- 벡터 $\mathbf{x} \in \mathbb{R}^n$ 는 좌표평면 위의 점 $(x_1, x_2, \dots, x_n)$ 에 대응된다.

벡터

- $\mathbb{R}^2$ 에서 벡터 $\mathbf{v} = (3, 2)^\top$ 의 기하학적 의미



- 벡터 $\mathbf{v}$ 는 좌표공간 위의 좌표 $(3, 2)$ 에 대응된다.

벡터의 연산

- 두 벡터 $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$

$$\mathbf{x} = (x_1, \dots, x_n)^\top, \mathbf{y} = (y_1, \dots, y_n)^\top$$

- 두 벡터의 합과 차




$$\mathbf{x} + \mathbf{y} = (x_1 + y_1, \dots, x_n + y_n)^\top \quad \mathbf{x} - \mathbf{y} = (x_1 - y_1, \dots, x_n - y_n)^\top$$

- 실수배

$$c \cdot \mathbf{x} = (cx_1, \dots, cx_n)^\top$$

벡터의 연산

- $\mathbb{R}^2$ 에서 벡터 $\mathbf{v} = (1, 4)$, $\mathbf{u} = (4, 1)$ 그리고 $\mathbf{w} = (1, 1)$



- $c \cdot \mathbf{w}$
- $\mathbf{v} + \mathbf{u}$
- $\mathbf{u} - 5 \cdot \mathbf{w}$

* $-\mathbf{v}$ 는 $\mathbf{v}$ 와 방향이 반대이다.

벡터의 크기와 방향

- 벡터 $\mathbf{x} \in \mathbb{R}^n$

$$\mathbf{x} = (x_1, \dots, x_n)^\top$$


- 벡터의 크기 $\|\mathbf{x}\|_2 = \sqrt{x_1^2 + \dots + x_n^2}$
 - $\mathbf{v}^\top = (3, 2) \rightarrow \|\mathbf{v}\|_2 = \sqrt{2^2 + 3^2} = \sqrt{13}$
 - $\mathbf{u}^\top = (1.5, 1) \rightarrow \|\mathbf{u}\|_2 = \sqrt{(3/2)^2 + 1^2} = \frac{\sqrt{13}}{2}$
- 크기가 1인 벡터를 단위벡터라고 정의한다.
 - 임의의 벡터 $\mathbf{x}$ 와 그 크기($\|\mathbf{x}\|_2$)를 이용하여, 크기가 1인 단위벡터를 만들 수 있다.

$$\frac{\mathbf{x}}{\|\mathbf{x}\|_2}$$

- 임의의 벡터 $\mathbf{x}$ 의 단위 벡터가 해당벡터의 방향이다.

벡터의 크기와 방향

- $\mathbb{R}^2$ 에서 벡터 $\mathbf{v}^\top = (3, 2)$ 와 $\mathbf{u}^\top = (1.5, 1)$



- 벡터 $\mathbf{u}$ 는 벡터 $\mathbf{v}$ 와 방향은 같으나, 크기가 작다.

선형 결합

- 벡터 $\mathbf{v}_1, \dots, \mathbf{v}_m \in \mathbb{R}^n$ 와 실수 $c_1, \dots, c_m \in \mathbb{R}$ 에 대해 다음을 $\mathbf{v}$ 를 $\mathbf{v}_1, \dots, \mathbf{v}_m$ 의 선형 결합이라고 한다.

$$\mathbf{v} = \sum_{i=1}^m c_i \mathbf{v}_i$$

- 벡터 $\mathbf{v}_1, \dots, \mathbf{v}_m \in \mathbb{R}^n$ 의 선형결합으로 표현가능한 벡터들의 집합을 $span\{\mathbf{v}_1, \dots, \mathbf{v}_m\}$ 이라고 한다.

$$span\{\mathbf{v}_1, \dots, \mathbf{v}_m\} = \left\{ \mathbf{v} \in \mathbb{R}^n \mid \mathbf{v} = \sum_{i=1}^m c_i \mathbf{v}_i \text{ for some } c_1, \dots, c_m \in \mathbb{R} \right\}$$

- $span\{\mathbf{v}_1, \dots, \mathbf{v}_m\}$ 은 직선, 평면 혹은 공간을 구성한다.
 - ex) 좌표평면($\mathbb{R}^2$)은 $span\{(1, 0)^\top, (0, 1)^\top\}$ 으로 생각할 수 있다.

선형 결합

- 주어진 2차원 벡터 두 개의 선형결합으로 2차원 좌표평면의 모든 점을 표현할 수 있을까?
 - 두 벡터 $\mathbf{x} = (1, 0)^T, \mathbf{y} = (0, 1)^T$
 - 점 $(3, 2) \rightarrow 3\mathbf{x} + 2\mathbf{y}$
 - 점 $(a, b) \rightarrow a\mathbf{x} + b\mathbf{y}$
 - 두 벡터 $\mathbf{x} = (1, 0)^T, \mathbf{y} = (-1, 0)^T$
 - 점 $(3, 0) \rightarrow 3\mathbf{x}$ or $-3\mathbf{y}$
 - 점 $(3, 1) \rightarrow 3\mathbf{x} + \dots?$
- 선형독립과 선형종속에 대한 이해가 필요하다.

선형 독립

- 벡터 $\mathbf{v}_1, \dots, \mathbf{v}_m \in \mathbb{R}^n$ 이 다음을 만족하면 선형 독립(linearly independent)이라 한다.
 - $c_1, \dots, c_m \in \mathbb{R}$ 에 대해, 다음 식을 만족한다면 이는 모든 j 에 대해 $c_j = 0$ 임을 의미한다.

$$\sum_{i=1}^m c_i \cdot \mathbf{v}_i = 0$$

- 이는 선형 독립이면 어떤 벡터 $\mathbf{v}_j$ 를 나머지 벡터들의 선형 결합($1 \leq j \leq m, j \neq j$)으로 표현할 수 없음을 의미한다.
- ex) 두 벡터 $\mathbf{x} = \{1, 0\}, \mathbf{y} = \{0, 1\}$

선형 종속

- 벡터 $\mathbf{v}_1, \dots, \mathbf{v}_m \in \mathbb{R}^n$ 이 다음을 만족하면 선형 종속(linearly dependent)이라 한다.
 - 실수 $c_1, \dots, c_m \in \mathbb{R}$ 이 존재해서 어떤 $1 \leq j \leq m$ 에 대해 $c_j \neq 0$ 이면서 다음 식을 만족한다.

$$\sum_{i=1}^m c_i \cdot \mathbf{v}_i = \mathbf{0}$$

- 위 j 에 대해, 다음과 같은 식이 성립한다.

$$\mathbf{v}_j = \sum_{i \neq j} \frac{c_i}{c_j} \cdot \mathbf{v}_i$$

즉, 선형 종속이면 어떤 벡터 $\mathbf{v}_j, 1 \leq j \leq m$ 이 다른 벡터들의 선형 결합으로 표현된다(역 또한 성립한다).

선형 독립, 선형 종속

- 벡터들의 모임이 선형 종속이라는 것은 이들의 선형 결합을 고려할 때 몇몇 벡터는 불필요하다는 것을 의미한다.
 - 두 벡터 $\mathbf{x} = \{1, 0\}, \mathbf{y} = \{-1, 0\}$
 - $\mathbf{x} = -\mathbf{y}$
 - 결국 두 벡터 $\mathbf{x}, \mathbf{y}$ 모두 필요하다고 할 수 있을까?
- n 차원 벡터는 최대 몇 개의 벡터가 선형독립일 수 있을까?
 - 벡터 $\mathbf{x} = \{1, 0\}, \mathbf{y} = \{0, 1\}, \mathbf{z} = \{1, 1\}$
 - 벡터 $\mathbf{x} = \{1, 0\}, \mathbf{y} = \{0, 1\}$ 는 좌표평면($\mathbb{R}^2$)의 모든 점을 표현할 수 있는데...

선형 독립, 기저, 차원

- n 차원 벡터가 n 개보다 많이 있으면 이들은 선형 종속이다. 즉, $m > n$ 이면 $\mathbf{v}_1, \dots, \mathbf{v}_m \in \mathbb{R}^n$ 은 선형 종속이다. 따라서, $\mathbf{v}_1, \dots, \mathbf{v}_m \in \mathbb{R}^n$ 이 선형 독립이면 $m \leq n$ 이다.
- $\mathbb{R}^n$ 을 span하는 n 차원 벡터 $\mathbf{v}_1, \dots, \mathbf{v}_m$ 이 선형 독립인 경우, $\mathbf{v}_1, \dots, \mathbf{v}_m$ 을 기저 (basis)라고 한다.
 - $\mathbf{v}_1, \dots, \mathbf{v}_m \in \mathbb{R}^n$ 이 선형 독립이므로 $m \leq n$ 이다.
 - $\mathbf{v}_1, \dots, \mathbf{v}_m \in \mathbb{R}^n$ 이 $\mathbb{R}^n$ 을 span하므로 $m \geq n$ 이다.
 - 따라서, $m = n$ 이다. 즉, $\mathbb{R}^n$ 의 기저는 정확히 n 개의 벡터로 구성된다.
- $\mathbb{R}^n$ 의 기저는 $\mathbb{R}^n$ 공간을 span하기 위해, 필요한 최소한의 벡터의 집합으로 생각할 수 있다.

선형 독립, 기저, 차원

- $\mathbb{R}^n$ 의 기저는 무한히 많다.
 - $\mathbb{R}^2$ 의 기저.

$$\mathcal{B}_1 = \{(1, 0)^\top, (0, 1)^\top\}$$

$$\mathcal{B}_2 = \{(5, 0)^\top, (0, 5)^\top\}$$

$$\mathcal{B}_3 = \{(1, 1)^\top, (0, 1)^\top\}$$

$$\mathcal{B}_4 = \{(1, 2)^\top, (3, 1)^\top\}$$

...

벡터의 연산(2), 내적(dot product)

- $\mathbf{x} = (x_1, \dots, x_n)^\top, \mathbf{y} = (y_1, \dots, y_n)^\top$ 를 n 차원 벡터라 하자.
- 차원이 같은 두 벡터 간의 내적은 다음과 같이 정의된다.

$$\mathbf{x} \cdot \mathbf{y} = \mathbf{x}^\top \mathbf{y} = \sum_{i=1}^n x_i \cdot y_i$$


- 벡터의 크기 (norm)는 내적을 이용해 다음과 같이 정의할 수 있다.

$$\|\mathbf{x}\|_2 = \sqrt{\sum_{i=1}^n x_i^2} = \sqrt{\mathbf{x} \cdot \mathbf{x}}$$

벡터의 연산(2), 내적(dot product)

- 두 벡터 $\mathbf{x}, \mathbf{y}$ 간의 사잇각을 θ 라 하면 다음 식이 성립한다.

$$\mathbf{x} \cdot \mathbf{y} = \|\mathbf{x}\|_2 \cdot \|\mathbf{y}\|_2 \cdot \cos(\theta)$$




- 두 벡터 $\mathbf{x}, \mathbf{y}$ 가 수직관계에 있는 경우, 즉 사잇각이 90도인 경우, $\cos 90^\circ = 0$ 이므로 $\mathbf{x} \cdot \mathbf{y} = 0$ 이 성립한다.
- 벡터들이 서로 직교하는 경우, orthogonal하다고 표현하며 특히 벡터의 크기가 1인 경우 orthonormal하다고 표현한다.

Orthogonal basis

- 직교하는 벡터 $\mathbf{x}_1, \dots, \mathbf{x}_n$ 은 선형 독립이다.
- n 차원 벡터 $\mathbf{x}_1, \dots, \mathbf{x}_n$ 이 직교하는 경우 이들은 n 차원 기저(basis)를 이룬다.
- 서로 직교하는 기저를 orthogonal basis, 특히 서로 직교하며, 기저벡터의 크기가 1인 경우를 orthonormal basis라고 부른다.
- 일반적으로 많이 이용하는 직교기저로는 $\{\mathbf{e}_i\}, i = 1, \dots, n$ 으로 이를 정규직교기저라 부른다. 이때, $\mathbf{e}_i$ 는 i 번째 성분만 1, 나머지는 0인 벡터이다.


Orthogonal basis



- 수선의 발까지의 벡터를 한 벡터가 다른 벡터를 설명하는 정도라 하면, 두 벡터가 직교한다면 한 벡터에서 다른 벡터를 설명하는 정도가 없음을 의미한다.
- 관측된 데이터로 구성된 두 벡터가 직교한다는 것은 두 특성 간의 (선형적) 관계가 없음을 의미한다.

벡터의 차원

- 다양한 기저가 필요한 이유?



- 기저의 두 벡터 중, 어떤 것이 더 중요할까?
- 관점을 달리하면(기저), 다른 결론에 이를 수 있다.

기저의 변환

- 기저는 선형결합을 통해, 좌표평면 위의 모든 벡터를 표현할 수 있다.
- 즉, 기저끼리 선형결합을 통해 변환이 가능하다.
- 예시
 - $\{(1, 0)^T, (0, 1)^T\}, \{(1, 2)^T, (3, 1)^T\}$ 는 모두 $\mathbb{R}^2$ 의 기저이다.
 - $\{\mathbf{x} = (1, 0)^T, \mathbf{y} = (0, 1)^T\} \rightarrow \{\mathbf{x} + 2\mathbf{y}, \mathbf{x} + 3\mathbf{y}\} = \{(1, 2), (3, 1)\}$
- 기저변환을 이해하기 위해서는 선형 변환에 대한 이해가 필요하다.

행렬

- $m \times n$ 행렬 $A \in \mathbb{R}^{m \times n}$ 은 다음과 같이 정의된다.

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix}$$

- $a_{ij} \in \mathbb{R}$ 를 행렬 A 의 (i,j) 성분이라고 한다.
- $m = n$ 인 경우, 정사각행렬이라고 한다.
- 또한, 벡터는 $n \times 1$ 행렬로 생각할 수 있다.

행렬의 연산

- 행렬의 합 (두 행렬 $A, B \in \mathbb{R}^{m \times n}$)

$$A + B = \begin{pmatrix} a_{11} + b_{11} & a_{12} + b_{12} & \cdots & a_{1n} + b_{1n} \\ a_{21} + b_{21} & a_{22} + b_{22} & \cdots & a_{2n} + b_{2n} \\ \vdots & \vdots & & \vdots \\ a_{m1} + b_{m1} & a_{m2} + b_{m2} & \cdots & a_{mn} + b_{mn} \end{pmatrix}$$

- 실수배 ($c \in \mathbb{R}$)

$$c \cdot A = \begin{pmatrix} c \cdot a_{11} & c \cdot a_{12} & \cdots & c \cdot a_{1n} \\ c \cdot a_{21} & c \cdot a_{22} & \cdots & c \cdot a_{2n} \\ \vdots & \vdots & & \vdots \\ c \cdot a_{m1} & c \cdot a_{m2} & \cdots & c \cdot a_{mn} \end{pmatrix}$$

행렬의 연산(2), 행렬의 곱

- 행렬의 곱 (두 행렬 $A \in \mathbb{R}^{m \times p}$, $B \in \mathbb{R}^{p \times n}$)

$$AB = \begin{pmatrix} \sum_{i=1}^p a_{1i}b_{i1} & \sum_{i=1}^p a_{1i}b_{i2} & \cdots & \sum_{i=1}^p a_{1i}b_{in} \\ \sum_{i=1}^p a_{2i}b_{i1} & \sum_{i=1}^p a_{2i}b_{i2} & \cdots & \sum_{i=1}^p a_{2i}b_{in} \\ \vdots & \vdots & & \vdots \\ \sum_{i=1}^p a_{mi}b_{i1} & \sum_{i=1}^p a_{mi}b_{i2} & \cdots & \sum_{i=1}^p a_{mi}b_{in} \end{pmatrix} \in \mathbb{R}^{m \times n}$$

- 행렬 A 의 i 번째 행과, 행렬 B 의 j 번째 열의 내적값이 행렬 AB 의 (i,j) 성분이 된다.
- 일반적으로 교환법칙이 성립하지 않는다. ($A \in \mathbb{R}^{m \times n}$, $B \in \mathbb{R}^{n \times m}$)

$$AB \neq BA$$

행렬의 연산(2), 행렬의 곱

- 예시

$$\begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} \times \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} = \begin{pmatrix} 1 \times 1 + 2 \times 3 & 1 \times 2 + 2 \times 4 \\ 3 \times 1 + 4 \times 3 & 3 \times 2 + 3 \times 4 \end{pmatrix}$$

- 행렬과 벡터의 곱

$$\begin{pmatrix} ax_1 + bx_2 \\ cx_1 + dx_2 \end{pmatrix} = \begin{pmatrix} a & b \\ c & d \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$$

* 행렬을 통해, 벡터 $\mathbf{x}$ 를 선형변환할 수 있다.

선형변환과 행렬

- 함수 $f : \mathbb{R}^m \rightarrow \mathbb{R}^n$ 이 모든 $a, b \in \mathbb{R}, \mathbf{x}, \mathbf{y} \in \mathbb{R}^m$ 에 대해 다음 성질을 만족하면 f 를 선형 변환이라고 한다.

$$f(a \cdot \mathbf{x} + b \cdot \mathbf{y}) = a \cdot f(\mathbf{x}) + b \cdot f(\mathbf{y})$$

- 임의의 $n \times m$ 행렬 A 에 대해, 함수 $f_A : \mathbb{R}^m \rightarrow \mathbb{R}^n$ 를 $f_A(\mathbf{x}) = A \cdot \mathbf{x}$ 로 정의하면 f_A 는 벡터($\mathbf{x}$)에 대한 선형 변환이 된다.
- * 참고로 모든 선형변환은 행렬로 표현가능하며, 둘은 1-1 대응 관계에 있다.

항등행렬, 역행렬, 전치행렬, 대칭행렬

- 항등행렬 ($\mathbb{R}^{n \times n}$); 대각성분만 1, 나머지는 0인 행렬

$$I = \begin{pmatrix} 1 & 0 & 0 & \cdots & 0 \\ 0 & 1 & 0 & \cdots & 0 \\ 0 & 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & & \vdots \\ 0 & 0 & 0 & \cdots & 1 \end{pmatrix}$$

- 행렬의 곱셈에 대한 항등원이다.

$$A \cdot I = I \cdot A = A$$

행렬, 역행렬, 전치행렬, 대칭행렬

- ($A \in \mathbb{R}^{n \times n}$)에 대한 역행렬 A^{-1}

$$AA^{-1} = A^{-1}A = I$$

- 행렬 A 의 곱셈에 대한 역원이다.
- 항상 존재하진 않는다.

항등행렬, 역행렬, 전치행렬, 대칭행렬

- A 에 대한 전치행렬 A^T

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix} \rightarrow A^T = \begin{pmatrix} a_{11} & a_{21} & \cdots & a_{n1} \\ a_{12} & a_{22} & \cdots & a_{n2} \\ \vdots & \vdots & & \vdots \\ a_{1m} & a_{2m} & \cdots & a_{nm} \end{pmatrix}$$

- $A = A^T$ 인 경우 대칭행렬이라 한다.

고유값(eigenvalue)와 고유벡터(eigenvector)

- 임의의 $n \times n$ 행렬 A 에 대해 벡터 $\mathbf{v} \in \mathbb{R}^n$ 과 실수 λ 가 존재해서 $A\mathbf{v} = \lambda\mathbf{v}$ 를 만족하면 λ 를 ($\mathbf{v}$ 에 대응되는) A 의 고유값, $\mathbf{v}$ 를 (λ 에 대응되는) A 의 고유벡터라고 한다.
- A 가 $n \times n$ 대칭행렬인 경우, n 개의 고유값과 이에 대응되는 고유벡터쌍 $(\lambda_1, \mathbf{v}_1), \dots, (\lambda_n, \mathbf{v}_n)$ 이 존재하며, 이 때 고유벡터들은 orthonormal하게 선택할 수 있다.

고유값(eigenvalue)와 고유벡터(eigenvector)

- $n \times n$ 대칭행렬 A 의 n 개의 고유값과 이에 대응되는 고유벡터쌍이 $(\lambda_1, \mathbf{v}_1), \dots, (\lambda_m, \mathbf{v}_m)$ 인 경우, 다음 식이 성립한다 (스펙트럴 분해 - spectral decomposition)

$$A = P\Lambda P' = \lambda_1 \mathbf{v}_1 \mathbf{v}_1' + \dots + \lambda_m \mathbf{v}_m \mathbf{v}_m'$$

이 때 Λ 은 대각성분이 $(\lambda_1, \dots, \lambda_m)$ 이고 나머지는 0인 행렬,

$P = \begin{pmatrix} | & \cdots & | \\ \mathbf{v}_1 & \cdots & \mathbf{v}_m \\ | & \cdots & | \end{pmatrix}$ 인 orthonormal한 행렬이며, 각 쌍의 순서가 바뀌어도 위 식은 성립한다.

고유값(eigenvalue)와 고유벡터(eigenvector)

- 행렬 P 는 정규직교기저인 $\{\mathbf{e}_i\}, i = 1, \dots, n$ 를 eigenvector로 이루어진 기저 $\{\mathbf{v}_i\}, i = 1, \dots, n$ 로 변환하는 선형변환이다.

$$\mathbf{v}_i = P\mathbf{e}_i = \begin{pmatrix} | & \cdots & | \\ \mathbf{v}_1 & \cdots & \mathbf{v}_m \\ | & \cdots & | \end{pmatrix} \begin{pmatrix} 0 \\ \cdots \\ 1 \\ \cdots \\ 0 \end{pmatrix}$$

- 즉, 행렬 A 는 정규직교기저를 $\{\lambda_i \mathbf{v}_i\}, i = 1, \dots, n$ 로 기저를 변환시켜주는 행렬이다.

데이터분석에서 벡터와 행렬

- 데이터분석에서 벡터와 행렬에 대한 이해
- 다음 두 주제에서 벡터와 행렬의 개념이 어떻게 이용되는지 확인해보고자 한다.
 - 회귀분석
 - 주성분분석 (Principle Component Analysis)

회귀분석에서의 벡터와 행렬

- p 개의 변수 $x_1, \dots, x_p$ 을 이용해서 y 를 추정하는 선형 회귀 모델을 고려하자.

$$y = \beta_1 x_1 + \dots + \beta_p x_p + \epsilon$$

- n 개의 관측 데이터, $(\mathbf{x}_i^\top, y_i), i = 1, \dots, n$, where $\mathbf{x}_i = (x_{i1}, \dots, x_{ip})^\top$ 가 주어진 경우 회귀계수 $\boldsymbol{\beta} = (\beta_1, \dots, \beta_p)$ 를 추정하는 문제이다.
- 이를 다음을 최소화하는 $\boldsymbol{\beta} = (\beta_1, \dots, \beta_p)$ 로 추정

$$\operatorname{argmin}_{\beta_1, \dots, \beta_p} \frac{1}{n} \sum_{i=1}^n (y_i - \beta_1 x_{i1} - \dots - \beta_p x_{ip})^2$$

회귀분석에서의 벡터와 행렬

- 해당 문제를 행렬과 벡터를 이용하여 표현.
- $\mathbf{X}, \mathbf{y}, \boldsymbol{\beta}$ 를 다음과 같이 정의할 때,


$$\mathbf{X} = \begin{pmatrix} x_{11} & \cdots & x_{1p} \\ \vdots & \vdots & \vdots \\ x_{n1} & \cdots & x_{np} \end{pmatrix}, \mathbf{y} = \begin{pmatrix} y_1^\top \\ \cdots \\ y_n^\top \end{pmatrix}, \boldsymbol{\beta} = \begin{pmatrix} \beta_0^\top \\ \cdots \\ \beta_p^\top \end{pmatrix}$$

- $\mathbf{y} - \mathbf{X}\boldsymbol{\beta}$ 의 크기인 $(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})$ 최소화하는 $\boldsymbol{\beta}$ 로 추정하며,
 $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ 이다.
- $\mathbf{y}$ 에 대한 추정값은 $\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ 이다.

회귀계수의 의미

- $\mathbf{y} - \mathbf{X}\boldsymbol{\beta}$ 의 크기를 최소화될 때는 $\mathbf{y}$ 에서 $\mathbf{X}$ 가 span하는 공간($\text{span}\{\mathbf{x}_1, \dots, \mathbf{x}_p\}$, $\mathbf{x}_j = (x_{1j}, \dots, x_{nj})^\top$)에 수선의 발을 내렸을 때이다.
- $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ 는 수선의 발에 해당하는 벡터를 표현할 때의 선형결합의 계수이다.
- $\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ 에서 $\mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$ 은 $\mathbf{X}$ 가 span하는 공간에 수선의 발을 내리는 선형변환인 projection matrix로 생각할 수 있다.

회귀계수의 의미



- 관측된 설명변수의 선형공간 위에서 y 를 어떻게 인식할까? → 수선의 발

Hat 행렬

- $\hat{\mathbf{y}} = H\mathbf{y}$ 이고

$$H = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top.$$

- $H^2 = H$ 임을 쉽게 보일 수 있다 (called 'idempotent matrix').

(*) 임의의 idempotent 행렬은 projection 행렬이다.


- 응용: $\hat{\mathbf{y}} \cdot (\mathbf{y} - \hat{\mathbf{y}}) = 0$.

주성분분석 (Principle Component Analysis)에서의 벡터와 행렬

- 일반성을 잃지 않고 관측데이터 $\{\mathbf{x}_j, j = 1, \dots, p\}$, $\mathbf{x}_j = (x_{11}, \dots, x_{n1})^\top$ 의 평균이 0이라고 가정하자. (평균을 빼면 된다.)
- 이때, 관측된 데이터로부터 추정한 공분산벡터 Σ 는 다음과 같이 정의된다.


$$\Sigma = \frac{1}{n} \mathbf{X}^\top \mathbf{X} = \frac{1}{n} \begin{pmatrix} | & \cdots & | \\ \mathbf{x}_1 & \cdots & \mathbf{x}_p \\ | & \cdots & | \end{pmatrix}^\top \begin{pmatrix} | & \cdots & | \\ \mathbf{x}_1 & \cdots & \mathbf{x}_p \\ | & \cdots & | \end{pmatrix}$$

주성분분석 (Principle Component Analysis)에서의 벡터와 행렬



- 공분산행렬이 Σ 인 데이터의 분포
- 각 contour는 $\mathbf{x}' \Sigma^{-1} \mathbf{x} = k\sigma, k = 1, 2, 3$ 인 타원
- 이 타원의 장축과 단축을 찾아라 => 주성분분석

주성분분석 (Principle Component Analysis)에서의 벡터와 행렬



- 수학적으로 직교 선형 변환으로, 기저를 관측된 데이터의 변동을 가장 잘 설명하는 직교기저로 변환하는 방법이다.
- 기저변환후, 중요하지 않은 기저 벡터를 줄여 차원을 축소하는 방법으로 사용된다.

주성분분석 (Principle Component Analysis)에서의 벡터와 행렬

- 이때, 관측된 데이터로부터 추정한 공분산벡터 Σ 은 대칭행렬으로 n 개의 고유값과 이에 대응되는 고유벡터쌍이 $(\lambda_1, \mathbf{v}_1), \dots, (\lambda_m, \mathbf{v}_m), \lambda_1 \geq \dots \geq \lambda_p \geq 0$ 이 존재하고 스펙트럴 분해를 통해 다음 식이 성립한다.

$$\Sigma = P\Lambda P' = \lambda_1 \mathbf{v}_1 \mathbf{v}_1' + \dots + \lambda_m \mathbf{v}_m \mathbf{v}_m'$$

- P 를 이용하여 정규기저를 공분산벡터의 고유벡터로 이루어진 기저로 기저변환을 할 수 있다.
- 이때, 고유값의 크기 순서대로 이에 해당하는 고유벡터들을 1번째 주성분, ... p 번째 주성분이라고 한다.

주성분분석 (Principle Component Analysis)에서의 벡터와 행렬

- 고유벡터와 고유값의 정의에 의해서

$$\Sigma^{-1} = P\Lambda^{-1}P = \frac{1}{\lambda_1}\mathbf{v}_1\mathbf{v}_1' + \cdots \frac{1}{\lambda_m}\mathbf{v}_m\mathbf{v}_m'$$

이 된다.

- 따라서

$$\mathbf{x}'\Sigma^{-1}\mathbf{x} = \sum_{k=1}^m \frac{1}{\lambda_k} \|\mathbf{v}_k'\mathbf{x}\|^2.$$

- $p = 2$ 에서 장축은 $\mathbf{v}_1$, 단축은 $\mathbf{v}_2$ 가 된다.

수고하셨습니다.