


금융 분야 AI 활용과 컴플라이언스



목차

I. 금융AI의 용례(use cases)와 유형(taxonomy)

II. AI 기본법

III. 금융AI 가이드라인

IV. 금융AI의 공정성·투명성

V. 결론

I. 금융 AI의 용례 (use cases)와 유형 (taxonomy)

금융분야 AI 개발·활용 안내서 (2022. 8. 4.)

- 우리 금융 분야에서 AI가 가장 많이 활용되는 5대 서비스를 다음과 같이 지목
 - ✓ 은행: 신용평가 및 여신심사
 - ✓ 금투: 로보어드바이저
 - ✓ 생보: 챗봇
 - ✓ 손보: 맞춤형 추천
 - ✓ 여신: 이상거래탐지(FDS)
- 은행업에 대해서는 특히 이하 용례들을 지목

〈은행업의 AI 활용분야 및 수준〉



우리금융그룹 혁신금융서비스 지정 사례


sandbox.fintech.or.kr/business/enterprise_intro.do?lang=ko&search=우리&systemTypes=FINTECH

총 24개의 게시물이 있습니다.

선택 필터: 혁신금융서비스 X

No.	기업명	서비스명	지정일	공고문
24	우리은행	마이데이터를 활용한 금리인하요구권 대행 서비스	2025.12.17	↓
23	우리은행	은행대리업 서비스	2025.12.17	↓
22	우리카드	내부 업무용 단말기에서 SaaS형 협업툴 및 생성형 AI 이용...	2025.09.03	↓
21	우리에프아이에스	생성형 AI 연계 SaaS 협업툴 이용	2025.09.03	↓
20	우리금융캐피탈	생성형 AI 연계 SaaS 협업툴 이용	2025.09.03	↓
19	우리은행	내부 업무용 단말기(PC 및 모바일)에서 SaaS 및 생성형 AI 이용...	2025.07.09	↓
18	우리은행	생성형 AI 활용 대화형 로보어드바이저 연계 상담서비스	2025.06.25	↓
17	JB우리캐피탈	AI기반 기업대출 평가 및 의사결정 지원 서비스	2025.04.16	↓
16	우리은행	금융기관보험대리점의 판매비중 규제 개선	2025.04.16	↓
15	우리은행	생성형AI를 활용한 대화형 상담서비스	2025.01.15	↓

금융AI의 유형 · I: 개요



Types of AI:	Intelligent agents	Discriminative AI		Cognitive AI	Generative AI	
Examples	Robotics	Classifier	Regressor	CV	Seq2seq	Transformer
				NLU	VAE	GAN
Complementing:	Human action	Human judgment		Human cognition	Human expression	
Uses	Self-driving vehicles	Credit scoring	Recruiting	Biometric Identification	Conversational agent	
	Industrial robots	Sentencing	Ranking	Medical diagnostics	AI-powered painting	AI music composition

에이전트는 안전(금융의 경우 시장 안정성 포함), 판별AI는 차별/설명(이 중 인지AI는 사생활 보호/정확·견고성), 생성AI는 타인 권리 침해/오남용이 핵심 문제

금융AI의 유형 · II: 판별AI

전통적인 통계적 기법의 활용 범위와 일치:

- 계약심사: 신용평가(ACSS 등) 및 여신심사, 보험계약심사(underwriting)
⇒ 차별 금지와 설명이 관건
- 사기탐지(FDS): 보험손해사정(claims adjusting) 포함
⇒ 오판율 저감과 설명이 관건
- 건전성 규제 준수를 위한 CompTech?

금융AI의 유형 · III: 범용/생성AI

Top Generative AI Use Cases in Banking



How valuable would implementing this use case be for your organization?

Financial document search and synthesis with gen AI




Enhanced virtual assistants with gen AI



Capital markets research with gen AI



Regulatory code change consultant with gen AI



Personalized financial recommendations with gen AI



Extremely valuable Fairly valuable Somewhat valuable Not very valuable Not valuable at all N/A or "I Don't Know"


Source: Google Cloud Gen AI Benchmarking Study, July 2023, Financial services respondents n=200

⇒ 우리나라에서는 고객상담 챗봇에 주로 쓰이며, 6대 판매규제 준수 등으로의 좀더 활발한 활용이 기대됨

금융AI의 유형 · IV: 에이전트

- Algo trading: 시장 안정성을 위한 거래소 규제 적용
- Robo-advisor (자본시장법 시행령 제2조 제6호 “전자적 투자조언장치”): 우리나라에서는 투자 자문, 일임, 집합투자재산 형태이며,
- 향후 AI agent의 금융 분야 활용? Data pipeline 구축이 관건

AI Agents - Build and Host LLM Apps At Scale



II. AI 기본법

AI 기본법에 따른 수평 규제 + 금융 분야에서의 수직 규제

인공지능 발전과 신뢰 기반 조성 등에 관한 기본법 (2025. 1. 21. 제정, 2026. 1. 22. 시행)

- 단일 부처(과기정통부)가 고영향/생성형/고성능 AI를 통괄하여 규제하는 EU식 수평규제체계

	개념	규제
고영향 인공지능	“채용, 대출 심사 등 개인의 권리·의무 관계에 중대한 영향을 미치는 판단 또는 평가”, 에너지, 먹는물, 보건의료, 의료기기, 핵물질/원자력, 생체인식정보 수사 활용, 교통, 국가기관등의 의사결정, 학생 평가	• AI 기반 운용 고지 의무 • 고영향 확인 의무 • 사업자의 책무: 위험관리방안, 결과/기준/학습용데이터 설명, 이용자 보호 방안, 사람의 관리/감독, 문서 작성/보관
생성형 인공지능	입력한 데이터의 구조와 특성을 모방하여 글, 소리, 그림, 영상, 그 밖의 다양한 결과물을 생성하는 인공지능시스템	• AI 기반 운용 고지 의무 • 결과물 AI 생성 사실 고지/표시
고성능 인공지능	학습에 사용된 누적 연산량이 대통령령으로 정하는 기준 이상인 인공지능시스템	• 안전성 확보 의무

기존 금융 규제

- 차별 금지: 금융소비자보호법 제15조, 대부업법 제9조의8, 신용정보법 제22조의4 제2항 제1호, 제3호 등
- 설명의무: 신용정보법 제36조의2 등
- AI 에이전트 규제: 한국거래소 “시장감시위원회 알고리즘거래 위험관리 가이드라인”, 자본시장법 시행령 제2조 제6호 등
- 금융분야 AI 가이드라인

수평 규제 v. 맥락특유적 규제 · I

- EU는 2024. 5. 21. AI Act를 가결하여 8. 1. 발효되었으나, 2027. 12. 2.까지 단계별로 시행: 최초의 AI 포괄 규제
- 한국, 중남미(페루, 브라질, 칠레, 멕시코, 콜롬비아), 동남아(베트남)가 EU의 영향을 받은 수평적 규제체계 법안 추진



The infographic is a cheat sheet for the EU AI Act, organized into six main sections with icons: 'THE BASICS' (AI chip icon), 'KEY REQUIREMENTS: HIGH-RISK AI' (checklist icon), 'PROHIBITED AI' (no sign icon), 'HIGH-RISK AI' (warning sign icon), 'GENERAL PURPOSE AI' (GPT icon), and 'PENALTIES & ENFORCEMENT' (dollar sign icon).

THE BASICS

- **Definition of AI:** aligned to the recently updated OECD definition
- **Extraterritorial:** applies to organisations outside the EU
- **Exemptions:** national security, military and defence; R&D; open source (partial)
- **Compliance grace periods** of between 6-24 months
- **Risk-based:** Prohibited AI >> High-Risk AI >> Limited Risk AI >> Minimal Risk AI
- **Extensive requirements** for 'Providers' and 'Users' of High-Risk AI
- **Generative AI:** Specific transparency and disclosure requirements

KEY REQUIREMENTS: HIGH-RISK AI

- **Fundamental rights impact assessment** and **conformity assessment**
- Registration in **public EU database** for high-risk AI systems
- **Implement risk management** and **quality management** system
- **Data governance** (e.g., bias mitigation, representative training data etc.)
- **Transparency** (e.g., Instructions for Use, technical documentation etc.)
- **Human oversight** (e.g., explainability, auditable logs, human-in-the-loop etc.)
- **Accuracy, robustness and cyber security** (e.g., testing and monitoring)

PROHIBITED AI

- **Social credit scoring** systems
- **Emotion recognition** systems at work and in education
- AI used to **exploit people's vulnerabilities** (e.g., age, disability)
- **Behavioural manipulation** and circumvention of free will
- **Untargeted scraping of facial images** for facial recognition
- **Biometric categorisation systems** using sensitive characteristics
- Specific **predictive policing** applications
- **Law enforcement use of real-time biometric identification in public** (apart from in limited, pre-authorised situations)

HIGH-RISK AI

- **Medical devices**
- **Vehicles**
- **Recruitment, HR and worker management**
- **Education** and vocational training
- **Influencing elections and voters**
- **Access to services** (e.g., insurance, banking, credit, benefits etc.)
- **Critical infrastructure** management (e.g., water, gas, electricity etc.)
- **Emotion recognition** systems
- **Biometric identification**
- **Law enforcement, border control, migration and asylum**
- Administration of **justice**
- **Specific products and/or safety components** of specific products

GENERAL PURPOSE AI

- Distinct requirements for **General Purpose AI (GPAI)** and **Foundation Models**
- **Transparency** for all GPAI (e.g., technical documentation, training data summaries, copyright and IP safeguards etc.)
- Additional requirements for **high-impact models with systemic risk:** model evaluations, risk assessments, adversarial testing, incident reporting etc.
- **Generative AI:** individuals must be informed when interacting with AI (e.g., chatbots); AI content must be labelled and detectable (e.g., deepfakes)

PENALTIES & ENFORCEMENT

- Up to **7% of global annual turnover** or €35m for prohibited AI violations
- Up to **3% of global annual turnover** or €15m for most other violations
- Up to **1.5% of global annual turnover** or €7.5m for supplying incorrect info
- **Caps on fines for SMEs and startups**
- **European 'AI Office' and 'AI Board'** established centrally at the EU level
- **Market surveillance authorities** in EU countries to enforce the AI Act
- **Any individual can make complaints** about non-compliance

수평 규제 v. 맥락특유적 규제 · II

- 미/영, 일본, 이스라엘, 인도, 스위스, 싱가포르 등은 EU 식 수평 규제체계 거부: 맥락특유적 규제체계(context-specific framework)

Policy paper

A pro-innovation approach to AI regulation

Updated 3 August 2023

37. We have identified the essential characteristics of our regulatory regime. Our framework will be **pro-innovation, proportionate, trustworthy, adaptable, clear** and **collaborative**.^[footnote 79]

- **Pro-innovation:** enabling rather than stifling responsible innovation.
- **Proportionate:** avoiding unnecessary or disproportionate burdens for businesses and regulators.
- **Trustworthy:** addressing real risks and fostering public trust in AI in order to promote and encourage its uptake.
- **Adaptable:** enabling us to adapt quickly and effectively to keep pace with emergent opportunities and risks as AI technologies evolve.
- **Clear:** making it easy for actors in the AI life cycle, including businesses using AI, to know what the rules are, who they apply to, who enforces them, and how to comply with them.
- **Collaborative:** encouraging government, regulators, and industry to work together to facilitate AI innovation, build trust and ensure that the voice of the public is heard and considered.

NIST AI 100-1 Artificial Intelligence Risk Management Framework (AI RMF 1.0)



AI기본법의 문제점 · I

- 체계상 문제점:

- ✓ 수평규제로 인한 기존 규제와의 중복, 저촉, 충돌
- ✓ 포괄규제로 인한 과잉규제

- 축조상 문제점:

- ✓ 인공지능 정의: 합리성이 아닌 의인화에 입각하여 정의
- ✓ 고영향AI 규제: AI가 사람에게 미치는 영향 및 사업자 역할의 세분화에 실패하고 일률적 규제
- ✓ 생성AI 규제: 입법착오, 적용범위가 매우 좁음

AI기본법의 문제점 · II

대한민국 인공지능 행동계획

2026. 2. 25

국가인공지능전략위원회

㉔ 국가 AI 대전환을 뒷받침하는 AI 법제 환경 조성

○ 검토 배경

'26년 1월 시행된 AI기본법은 공백 상태였던 법·제도적 기반을 오랜 준비기간을 거쳐 마련했다는 점에서 의미가 있다. 특히 추진체계와 진흥 조항은 AI 개발과 사업화의 촉진에 기여할 것으로 기대된다. 다만 동법상 규제 조항 및 이에 대한 하위규정안은 명확성·형평성·이행가능성 및 국제적 정합성이 충분치 않고, 일부 항목에 대해서는 법률 개정 검토가 필요하다. 또한 하위규정의 최종안이 확정된 이후 시행일 전까지 개발자들의 신뢰·안전 투자에 충분한 기간이 주어졌어야 한다. 따라서 법의 시행 유예 및 후속 개정 방안을 우선적으로 검토하였으나, 국회와의 협의 등 현실적 제약을 고려한 차선택으로, 시행일 이후에라도 보완·개정되어야 할 사항을 제시하고자 한다. 또한, 각 부처에서 산발적으로 추진하는 AI 관련 법안들이 기존 법체계와 충돌하거나 중복 규제를 낳을 가능성이 상존하며, 이는 개발자들에게 예측 불가능한 부담을 안겨주고 국가 AI 경쟁력을 심각하게 저해할 수 있으므로, 개발 현장과 시민의 목소리를 지속적으로 청취하며 개선할 필요가 있다. 나아가 고영향 AI 해당 분야의 소관 부처들에 AI 전환에 맞춘 소관 법령의 정비를 독려 후 완료 시 AI기본법의 중복 적용을 해소하는 방식으로, 글로벌 트렌드에 부합하는 맥락특유적 규제체계로의 전환도 유도해야 한다.

○ 정책 권고사항

- 과기정통부는 국가AI전략위와 협의하여 AI기본법 하위법령 및 가이드라인을 보완한다.⁵⁶⁾
- 과기정통부는 글로벌 스탠다드에 맞추어 AI기본법상 규제 조항을 개선하기 위한 'AI기본법 개정 협의체'를 '26년 상반기까지 국가AI전략위와 협의하여 구성하고, 이를 통해 개정안⁵⁷⁾을 준비하여 국회와 협의한다.
- 국가AI전략위는 법제처, 국조실, 과기정통부와 협력하여 'AI 법·제도 협의체'를 '26년 1분기까지 신설하여 정례 운영하고, 동 협의체를 통해 ①법

정부적 관점에서 부처별 AI 관련 법령 제·개정 우선순위 검토, 법령 간 중복·충돌 방지, AI 개발 현장 목소리의 지속적 청취 등을 바탕으로 일관적·체계적인 입법 방향을 제시하며, ②고영향 AI 해당 분야의 소관 부처들⁵⁸⁾에 AI 전환에 맞춘 소관 법령의 정비를 독려하고, 완료 시 과기정통부는 AI기본법 시행령 [별표1] 추가 검토 등을 통해 중복규제를 해소한다.

AI기본법의 적용 범위 · I: 인공지능사업자

- 어떤 금융기관이 “인공지능사업자”에 해당?

제2조(정의) 이 법에서 사용하는 용어의 뜻은 다음과 같다.

7. “인공지능사업자”란 인공지능산업과 관련된 사업을 하는 자로서 다음 각 목의 어느 하나에 해당하는 법인, 단체, 개인 및 국가기관등을 말한다.

가. 인공지능개발사업자: 인공지능을 개발하여 제공하는 자

나. 인공지능이용사업자: 가목의 사업자가 제공한 인공지능을 이용하여 인공지능제품 또는 인공지능서비스를 제공하는 자

- ✓ 금융기관이 금융AI를 직접 개발(미세조정 등 실질적 변경 포함): “인공지능개발사업자” 해당하여 의무 적용 받음
- ✓ 금융기관이 타사가 개발한 금융AI 시스템 적용: AI가 구성요소로 포함된 서비스를 직접 제공해야 “인공지능이용사업자” 해당하여 의무 적용 받음

⇒ 대체로 **금융기관에 납품하는 IT 업체**들이 적용 대상이며, **운용자(deployer)인 금융기관**은 적용 범위에서 대부분 제외됨

AI기본법의 적용 범위 · II: 고영향AI

- “채용, 대출 심사 등 개인의 권리 · 의무 관계에 중대한 영향을 미치는 판단 또는 평가”(제2조 사목)가 고영향 인공지능에 포함되었고, 가이드라인상 금융 분야에서는 **대출 심사**만 포함: 기업 대출 제외, 최종 결정에 상당한 영향 없는 경우 제외

2.7.2 적용범위 및 '고영향'의 의미

- (적용범위) 대출 심사 등 금융분야에서 '고영향 인공지능'의 적용범위는 ① 금융업권에서 금융 거래나 대고객서비스에 인공지능시스템을 활용한 경우, 또는 ② 비금융업권이라도 인공지능 시스템의 활용 결과가 금융거래에 영향을 미치는 경우 적용한다.

① 금융상품 및 금융서비스의 제공을 위한 업무에 인공지능시스템을 직·간접적으로 활용하거나 활용하고자 하는 금융회사 및 ② 금융상품추천·신용평가 등 금융연관 서비스 제공을 위한 업무에 인공지능시스템을 직·간접적으로 활용하거나 활용하고자 하는 비금융회사가 이에 해당한다.

- 금융회사가 신용정보 등에 근거하여 대출 신청인의 신용 및 상환능력을 평가하여 대출의 승인 여부와 대출 조건을 결정하는 데 직접적으로 관련되는 업무에 한한다.

※ 대출 과정에서의 모든 관련 업무(상담, 본인 확인, 신청 접수, 심사 및 승인, 실행 및 사후관리 등)가 '대출 심사'에 포함되는 것은 아니다. 금융회사의 대출 등 신용공여 행위와 직접적으로 관련이 적은 챗봇 서비스, 이상거래탐지서비스(FDS) 등은 '대출 심사'에 포함되지 않고, 금융회사 내부 직원관리, 단순 업무 효율화 등 인공지능시스템의 활용으로 고객에게 미치는 영향이 없는 경우도 '대출 심사'의 범위에 포함되지 않는다.

※ 신용공여 행위에 해당하는 경우라도 카드발급, 리스는 대출 희망자의 기본권에 중대한 영향을 미치는 것으로 보기 힘드므로, 해당 업무에 활용되는 인공지능은 고영향 인공지능에 해당하지 않는다.


- 대출 심사는 “개인의 권리·의무 관계”와 관련되어야 하므로 원칙적으로 개인인 자연인(금융 소비자)에 대한 대출 심사를 의미하지만, 개인사업자가 사업용도로 대출 심사를 받으면서 사업자 정보뿐 아니라 개인적 정보도 활용되는 경우, 인공지능시스템에 의해 기본권을 침해할 우려가 있으므로 대출 심사의 적용범위에 포함된다.

- (‘고영향’의 의미) 인공지능시스템을 통해 대출 심사를 하는 과정에서 금융회사 등이 개인에 대한 부당한 차별 등 개인의 권익과 안전, 자유에 대해 중대한 영향을 미치는 것을 말한다.

- 인공지능시스템 활용에 따라 개인의 금융거래계약의 체결·유지 등에 직접적인 차별이 발생하는 경우 개인의 권리에 중대한 영향을 미친다고 볼 수 있으나, 실제 인공지능시스템의 활용 사례별 개인의 권리에 미치는 영향도를 판단함에 있어서 개별 요소를 종합적으로 고려하는 것이 필요하다.



「대출 심사」 분야 고영향 해당 인공지능 판단




AI기본법의 적용 범위 · III: 사업자책무

- 고영향AI에 해당하는 대출 심사의 경우 수범자인 인공지능 사업자가 고영향 AI 사업자 책무 이행해야: 대출신청인이 아닌 금융기관이 “이용자”로서 보호 대상이 됨.

법률	고시	사업자 책무 가이드라인(안)
1. 위험관리방안의 수립 · 운영	1-1. 위험관리정책 수립 및 이행	1-1-1. 위험관리 계획의 수립 / 1-1-2. 위험 식별 / 1-1-3. 위험 분석 및 평가 1-1-4. 위험 처리 / 1-1-5. 위험관리정책 개선
	1-2. 위험관리 조직체계 수립 및 운영	1-2-1. 위험관리 조직체계 구성 / 1-2-2. 정보의 제공 / 1-2-3. 유관 조직과의 협력
2. AI 도출 최종결과, 주요 기준, 학습용 데이터 개요 설명방안의 수립 · 시행	2-1. 인공지능이 도출한 최종 결과 및 기준에 대한 근거 마련	2-1-1. 투명성 및 설명가능성 확보
	2-2. 학습용데이터 정보의 관리	2-2-1. 학습용데이터 개요
	2-3. 설명 방안의 수립 및 시행	2-3-1. 설명 방안의 주요 내용 수립 / 2-3-2. 설명 방안의 시행
3. 이용자 보호방안의 수립 · 운영	3-1. 인공지능 개발 단계	3-1-1. 데이터 수집 및 관리 / 3-1-2. 알고리즘 설계 및 시스템 개발 / 3-1-3. 시험 및 평가
	3-2. 인공지능 운영 단계	3-2-1. 모니터링 및 대응 / 3-2-2. 피드백 수렴 및 적용 / 3-2-3. 이용자 권리 보장
4. 사람의 관리·감독	4-1. 인공지능 개발 단계	4-1-1. 사람의 개입 기준 / 4-1-2. 사람의 개입 방법
	4-2. 인공지능 운영 단계	4-2-1. 정기적 점검 / 4-2-2. 교육 및 훈련
5. 문서의 작성 · 보관	5-1. 문서화 및 관리 방안	5-1-1. 문서화 공통사항

AI기본법의 적용 범위 · IV: 생성AI 투명성



III. 금융AI 가이드라인

대한민국 인공지능 행동계획(2026. 2. 25.)

대한민국 인공지능 행동계획

2026. 2. 25

국가인공지능전략위원회

④ AI 기반 금융산업 혁신성장과 금융산업 AI 대전환

○ 검토 배경

금융산업은 데이터 기반 의사결정 비중이 높아지면서 AI의 활용 범위가 단순 자동화를 넘어 리스크 관리, 자산 배분, 고객 경험 개선 등 핵심 기능으로 확장되고 있다. 그러나 금융 데이터가 기관별로 분산되고 컴퓨팅 자원이 제한되어 대규모 AI 모델 개발과 실증이 어려운 구조가 지속돼 왔다. 이제는 데이터·인프라·규제 체계를 일관되게 정비해 금융권이 필요한 시점에 AI를 학습·검증·운영할 수 있는 기반을 갖추는 것이 금융 경쟁력의 핵심 과제로 부상하고 있다. 최근 금융회사들은 AI 도입을 확대하고 있지만, 보안 규제·망 분리·데이터 품질 등 구조적 제약이 남아 있어 기술 투자 효과가 충분히 발휘되지 못하고 있다. 동시에 AI 활용에 따른 리스크—투명성, 책임성, 공정성 문제—에 대한 체계적 관리 요구도 급격히 커지고 있다. 금융산업이 안정성과 혁신성을 동시에 확보하려면 공공·민간이 함께 활용할 수 있는 통합 데이터 허브, 금융 특화 AI 클라우드, 명확한 신뢰·거버넌스 체계를 준비하는 종합 전략이 필요하다.

○ 정책 권고사항

- 금융위는 과기정통부, 기획예산처와 협력하여 '26년 4분기까지 금융 데이터 허브를 조성해 공공·민간 금융 데이터의 연계와 표준화를 추진하고, 이를 기반으로 '28년 4분기까지 금융산업의 AI 혁신을 뒷받침할 데이터·컴퓨팅·플랫폼 인프라를 통합적으로 구축하며, 동시에 GPU 기반 금융 AI 클라우드를 마련해 금융사가 활용할 AI 모델 학습·검증 환경과 데이터 생태계를 조성하며 데이터 독점 및 시장 지배력이 강화되지 않도록 명확한 접근·활용 기준을 제공한다.
- 금융위는 금융산업 전반의 AI 내재화를 통해 금융 AI 서비스 혁신을 위해 「금융권 AI 활용 활성화 지원 방안」을 '26년 2분기까지 수립하며, 동 지원 방안에는 ① AI 혁신을 유도하기 위한 ‘망 분리’ 등 규제 유연화, ② AI를 활용한 민간 금융기관의 혁신 역량 강화, ③ AI기반의 금융 신산업 육성 등의 내용과 함께, 대형금융사, 빅테크에 대한 특례로 변질되지 않도록 하기 위한 조건이 포함되어야 한다.

- 금융위는 AI 활용 확대에 따른 소비자 피해와 시스템 리스크를 관리하고 금융 AI 거버넌스와 신뢰 체계를 확립할 수 있도록 ① 금융기관의 공정성·투명성·책임성 확보와 「인공지능기본법」 준수를 위한 「금융산업 AI 가이드라인」을 '26년 1분기까지 마련하고, ② 금융 분야 AI 위험 관리 등에 대한 상시 모니터링 체계를 '26년 4분기까지 구축하며, ③ AI 기술 변화와 「인공지능기본법」 시행 결과 및 금융권 AI 활용 현황 등을 반영하여 '27년 1분기까지 「금융산업 AI 가이드라인」 보완을 추진한다.

2021년 금융위 금융분야 AI 가이드라인의 개요 · I

가. 목적과 범위

- (목표) 금융분야 AI 시스템의 개발, 사업화 및 활용의 전 과정에서 신뢰성을 제고하여 AI 활성화에 기여
- (적용) 금융권 AI 시스템 전반을 대상으로 하되 금융기관이 AI서비스의 특성을 감안하여 가이드라인 적용 여부 자율결정

√ 가이드라인 적용 대상

- (대상업권) AI를 금융거래 및 금융서비스 등에 적용한 **금융업권**
→ 실무지침의 경우 AI 활성화 정도 등을 감안하여 은행, 보험, 금융투자업권 등 대형 금융업권 위주로 마련하되,
 - 금융연관분야라 하더라도 AI활용에 따르는 금융서비스 등에 미치는 위험이 크다고 판단되는 경우(예:CB사, 전자금융업 등) 확대 적용
- (활용분야) AI를 접목한 **금융서비스**를 대상으로 하되, 금융소비자에 미치는 영향이 없는 **Back Office** 관련 분야(예:RPA 등)의 경우 제외

나. 거버넌스의 구축

- (조직 내 AI윤리 마련) 조직 내 가치, AI 활용 상황 등을 고려하여 인공지능 이용에 관한 **내부윤리 원칙과 기준**을 수립
- (책임·권한의 정의) AI시스템의 위험 평가·관리를 위한 **구성원의 역할·책임·권한**을 구체적으로 정의(필요시, AI윤리위 별도 설치)

√ AI 조직의 역할 예시

- ① AI 활동에 대한 책임과 감독
- ② AI 정책 및 절차 관리
- ③ AI 활용에 대한 영향평가
- ④ AI 서비스에 대한 자체평가
- ⑤ 소비자 권리보장을 위한 체계 운영(이의제기 처리, AI서비스 공시 등)
- ⑥ 기업 내 AI 책임 문화 확산 촉진
- ⑦ AI 모델 및 학습데이터 거버넌스 관리
- ⑧ AI 관련 이슈 발생시 감독당국과의 설명 등 소통

- (위험관리정책 마련) AI 시스템의 위험에 대한 **평가·관리 정책** 마련
 - 개인권리에 중대한 위험을 초래할 수 있는 AI 활용사례에는 내부통제 및 승인절차를 마련하고, 승인책임자 지정을 권고

√ 개인권리에 중대한 위험을 초래할 수 있는 AI 활용사례란?

- AI 활용에 따라 개인의 금융거래계약의 체결·유지 등에 직접적인 차별이 발생하는 경우 (예 : 신용평가, 대출심사, 보험심사 등)
- 다만, 실제 사례별·기능별 차이를 감안하여 금융회사가 개인권리에 중대한 위험을 초래할 수 있는지 자체평가하여 결정

2021년 금융위 금융분야 AI 가이드라인의 개요 · II

다. 기획·설계 단계

- (기획) AI 활용목적이 **윤리원칙에 부합**하는지 여부, AI시스템 활용의 **사회적·경제적·문화적 영향**, **잠재적 피해 가능성** 등 평가
- (설계) AI가 인간의 의사결정과정을 대체하는 경우, AI시스템을 **감독·통제**하고 **책임성**을 유지할 수 있도록 **시스템**을 설계

√ <참고> 보험상품 설명시 음성봇 활용 요건 (보험업법 시행령 입법예고안)

- ① 설명속도, 음량 등을 조절할 수 있는 기능을 제공할 것
- ② 소비자가 AI 음성봇 사용 중단을 요청하면 즉각 중단
- ③ 소비자가 설명내용에 대해 질문이나 추가설명을 요청하면, 설계사가 실시간으로 직접 응대할 수 있는 시스템을 갖출 것
- ④ 음성봇이 상품설명을 한다는 사실 및 ①·②·③에 대해서 소비자에게 미리 안내하고 동의를 받을 것

라. 개발 단계

- (데이터) AI 학습 데이터의 **품질 검증·개선** 및 **최신성 유지** 등
 - * 예시 : 데이터 출처의 정확한 파악, 데이터 규격 문서화, 데이터 품질 검증(누락, 중복, 불일치 등), 편향되지 않은 충분한 학습데이터 확보, 무결성 검증 및 주기적 갱신 등 관리 활동 수행
- (개인정보) 사생활 정보, 민감정보 등을 활용하는 경우 **비식별 조치** 등 **충분한 안전조치** 후 **개인정보 활용 필요성** 등을 평가

√ 국제표준화기구(ISO), AI 관련 데이터 생명주기별 프라이버시 위협 고려사항

구 분	고려 사항
데이터 확보	- AI 성능을 위한 데이터 확보와 개인정보보호를 위한 데이터 최소화 원칙 간 관계 고려 - 공격자의 데이터 스토리지 손상 위협에 대한 대비
데이터 전처리 및 모델링	- AI를 활용하여 일반 정보에서 민감정보를 추론하거나 비식별화된 데이터의 재식별 가능성 등이 있으므로 이에 대비
모델 쿼리(Query)	- 공격자가 모델 탈취 공격으로 민감정보를 유출하거나 본래 목적과 다르게 AI 모델을 악용할 수 있으므로 이에 대비

- (설명가능성) 신뢰성, 통제가능성 확보 등을 위하여 **설명가능한 AI 기술 도입** 노력

2021년 금융위 금융분야 AI 가이드라인의 개요 · III

마. 평가·검증 단계

- (성능) AI 시스템 오류 유형간 통계적 상충관계* 등을 고려하여 **적합한 성능 목표 및 성능평가지표를 선정**하고 **충족여부** 확인

* 예: 은행이 대출부적격자를 걸러내기 위해 여신심사를 강화하는 경우 대출적격자(True)에 대한 여신이 거절(False)되는 경우도 증가

√ 서비스 특성별 성능 판단기준(예시)

- 소비자에 금융거래 기회를 제공하는 기능을 수행하는 경우(예 : 신용평가, 대출심사, 보험심사 등) : **False Negative 오류**(True를 False로 구분) **최소화**
- 사기탐지, 규제 미준수 등 위법·부당사례 탐지 기능을 수행하는 경우 (예 : FDS, Reg-tech) : **False Positive 오류**(False를 True로 구분) **최소화**

- (공정성) AI 시스템 **공정성 평가지표**를 선정·측정, 불균형이 발견된 경우 **공정성 개선**을 위한 기술적·관리적 노력 제고

√ 서비스 특성별 공정성 판단기준(예시)

- 특정 계층·집단에 대한 **결과적 평등**을 고려할 필요가 있는 경우(예 : 금융 소외계층 금융접근성 제고) : **인구통계적 동등성 기준 적용**
(예 : 집단간 대출승인율 동등)
- 소비자에 금융거래 기회를 제공하는 기능을 수행하는 경우(예 : 신용평가, 대출심사, 보험심사 등) : **기회의 균등 기준**을 적용(예 : 집단간 재현율* 동등)
* 재현율(True Positive Rate) : 전체 대출적격자 중 AI가 대출적격자로 정확하게 예측한 비율

- (설명가능성) **상황에 맞는 설명**이 도출되는지 여부를 확인하고, 설명가능성을 합리적 수준으로 개선하기 위해 노력

바. 도입·운영·모니터링

- 대고객 AI시스템 운영시 고객에게 AI 이용을 **사전고지**하고, 자동화평가(Profiling) 대응권* 등 **소비자의 권리** 및 **이의신청·민원제기 방식** 등 **권리구제 방안**을 고지

* AI 등 자동화평가 결과에 대해 설명요구, 이의제기, 기초데이터의 제출·정정, 결과의 재산정을 요구할 수 있는 권리 (「신용정보법」 §36-2)

- AI시스템 성능을 주기적으로 **모니터링**하고, **재학습 필요성 여부**를 검토하는 등 **성능 개선 가능성 확인** 및 **개선 추진**
- AI시스템 이용자에 의한 **오용·악용 가능성**을 방지, AI 개발 환경의 **보안취약성 상시통지 시스템 마련** 등

√ 국제표준화기구(ISO), AI위험 완화 조치 전략 (☞참고2)

- AI 시스템 운영에 따르는 위험을 완화하기 위한 10가지 전략*을 제시하고, 서비스 생명주기 전반에 대해 **위험완화 조치의 주기적 수행 권고**
* 투명성, 설명가능성, 통제가능성, 편향성 완화, 프라이버시, 신뢰성·복원력·견고성, 하드웨어 결함 완화, 기능적 안전성, 테스트·평가, 활용·적용성

2021년 금융위 금융분야 AI 가이드라인의 개요 · IV

사. AI 업무위탁에 관한 특례

- (지침 마련) AI 시스템 개발·운영 등을 외부기관에 위탁할 경우 **수탁기관이 준수하여야할 위험관리지침을 마련·공유**
 - **AI 윤리 및 위험관리정책의 주요내용을 포함하여** 마련함으로써 수탁기관도 위탁기관의 AI 운영원칙에 따라 시스템 개발·운영
 - * 소규모 금융회사로 자체적인 AI 시스템 운영 없이 외부기관 위탁만으로 AI시스템을 개발·운영하는 경우 위험관리지침으로 위험관리정책을 갈음
- (주기적 점검) 위탁한 AI시스템 개발·운영이 **위험관리지침에 따라 이루어졌는지 주기적인 보고·점검 체계 구축·운영**
 - 개인권리에 중대한 위험을 초래할 수 있는 AI 활용사례에 대해서는 **내부통제 및 승인절차에 준한 사전 점검**을 거칠 수 있도록 함
 - * 예시 : AI 개발·운영 계획(사용 데이터, 잠재적 위험에 대한 발생가능성에 대한 평가 및 조치내역 등) 등에 대한 위탁기관의 사전확인, AI 시스템 관련 소비자 피해 발생시 조치 및 보고 절차 마련 등

√ EU 「신뢰할 수 있는 AI 자체평가」 세부내용 中

- 제3자(공급업체, 이용자, 근로자 등)가 AI시스템의 잠재적인 취약성, 위험, 편향을 보고할 수 있는 절차를 마련했는지?
- 이러한 보고절차가 위험관리 절차의 개선에 반영되는지?

- (소비자 피해) 소비자 피해 발생에 따른 **책임주체를 명확히** 하고, 위탁계약 체결시 **손해배상 지연** 등을 방지하기 위한 **명확한 책임조항 및 손해배상 처리 절차** 등을 기재

현재 금융위 금융분야 AI 가이드라인 개정 중

금융위원회는 이러한 의견들을 반영하여 수차례 협의회 논의를 통해 **금융권 AI 개발·활용의 주요 원칙**을 마련하였다.

< 금융 AI 7대 원칙(안) >	
분야	7대 원칙
거버넌스	① 최고경영자를 포함한 경영진 은 AI 개발·활용에 대한 관심 을 갖고 역할과 책임 을 분담해야 함
	② AI 활용 전단계에서 금융·AI 등 관련 법규 를 준수해야 함
	③ 현 단계에서 AI는 업무의 보조 수단 이므로 최종 의사결정 과 그에 따른 책임은 임직원 이 수행함
AI 개발 단계	④ AI 개발 과정에서 신뢰할 수 있는 데이터와 모델 을 사용해야 함
	⑤ AI 설계·학습 등 전과정에서 금융 안정성 위험을 최소화해야 함
AI 활용 단계	⑥ AI 활용 시 금융소비자의 이익 을 최우선으로 해야 함
	⑦ AI활용 시 보안성 기준 및 점검·개선 체계를 마련해야 함

금융분야 AI의 거버넌스와 개발·활용에 관한 명확한 원칙을 제시하고, 원칙에 대한 **구체적인 내용**들은 향후 유관기관, 업계 전문가 등과 논의를 거쳐 **안내서로 제시**할 계획이다. 안내서에는 금융 AI 7대 원칙의 적용 기준, 생성형 AI 관련 윤리 등을 반영한 자세한 설명과 사례를 담을 예정이다. 이번 「금융분야 AI 가이드라인」 개정으로 금융회사들이 실제 업무에 AI를 활용할 때 불확실성이 상당 부분 해소될 것으로 기대된다.

감독원 “금융분야 AI 위험관리 프레임워크(AI RMF)” (2026. 1. 26.) · I

I 배 경

□ **(금융권의 AI 활용 동향)** 최근 AI는 기술 진보를 넘어 산업·사회 전반에 패러다임 전환을 촉진하며 경제성장의 핵심 동력으로 부상

- 금융권 또한 AI 기반의 대고객 서비스를 출시하거나 내부 업무 혁신에 AI를 활용하는 사례가 크게 확대*

* 세계경제포럼(WEF)은 AI 혜택이 가장 큰 분야로 금융산업을 지목하며 업무의 32~39%를 완전 자동화할 수 있고 추가로 34~37%는 AI로 크게 보조될 수 있다고 평가(25.1월)

국내 금융업권별 AI 활용 현황

(25.4월말 기준, 단위 : 개)

구 분	은행	증권	보험	카드	합계
대상 회사 수 (a)	20	37	53	8	118
AI 서비스 수 (준비중 포함) (b)	299	143	145	66	653
회사별 평균 AI 서비스 수 (b/a)	15.0	3.9	2.7	8.3	5.5

□ **(그간의 감독방향)** 금융당국은 금융권이 AI 대전환을 선도할 수 있도록, 다각도로 지원하며 금융혁신을 유도 중

- 망분리 규제 합리화, 인프라·데이터 제공 등을 통해 AI의 잠재력이 금융분야에서 현실화될 수 있도록 지원하고 있으며,
- 다양한 형태의 가이드라인* 등을 마련하여 금융회사가 AI를 도입·활용하는 과정에서 참고할 수 있도록 제공

* ① 운영 가이드라인(21.7.) ② 개발·활용 안내서(22.8.) ③ 보안 가이드라인(23.4.)

II 금융권의 AI 위험관리 현황

□ **(금융 AI의 위험)** 다만, AI의 복잡성, 불투명성, 데이터 의존성 등으로 인한 새로운 유형의 위험이 대두되면서 금융소비자의 권익을 침해하거나 금융안정을 훼손할 수 있다는 우려가 점중

- 특히 금융 분야는 자금 중개라는 본질적 특성상 AI 위험이 산업·사회 전반과 금융소비자에게 큰 영향*을 미칠 수 있는 데다,

* (예시) AI 모델이 환각 현상을 보이거나 학습데이터가 편향된 경우 거짓·왜곡된 결과를 산출할 수 있으며, 차별 등 사회적 불평등 및 윤리적 논란이 심화할 소지

- 실시간 거래가 이루어지는 금융시장에서는 AI 오류가 여타 산업에 비해 빠르고 광범위하게 전파*되어 시스템 위협으로 발현 가능

* 심지어 AI 시스템이 정상 작동하더라도 유사 알고리즘이 특정 신호에 동시 반응하여 급격한 시장 변동을 유발하는, 이른바 ‘플래시 크래시(Flash Crash)’ 가능성도 상존

□ **(금융회사 위험관리 현황)** 이러한 금융 AI 위험의 차별적 특성 및 파급력에도 불구하고, 거버넌스 및 위험관리는 대체로 미진한 상황

- 국내 금융회사 점검* 결과, 소수의 회사만이 AI 거버넌스를 구축하거나 위험관리·내부통제 등 관련 내규를 마련**한 가운데,

* 은행(20), 카드사(8), 증권사(37), 보험사(53) 등 총 118개사 대상 전수 조사(25.4월)

** 은행 5개(25%), 보험사 4개(7.5%), 증권사 1개(2.7%)만 의사결정기구를 설치하였으며, 약 85%의 금융회사는 AI 윤리원칙, 위험관리 기준 등 미마련

- AI 서비스를 개발·활용하는 과정에서 감독당국이 제시한 AI 관련 가이드라인을 적용한 비율도 약 60%로 저조

- 한편, 상당수 금융회사는 AI 거버넌스 및 위험관리 등에 관한 불확실성 해소 및 책임소재 명확화 등을 위해 금융권의 특수성을 반영한 가이드라인 제시를 희망

➡ 금융감독원은 금융권이 혁신과 책임의 균형 하에 건전하게 AI를 활용할 수 있도록, 「**금융분야 AI 위험관리 프레임워크**(이하 ‘AI RMF’)」를 마련하여 **금융회사 스스로 위험을 관리**할 수 있는 **구조적 기반**을 제시

※ AI RMF는 ‘25.12.22. 발표한 「인공지능 대전환(AX), 금융이 선도하겠습니다」(금융위·금감원 등)의 “금융분야 AI 가이드라인 개정 방향”과 관련된 사안으로, 동 가이드라인에 포함된 금융 AI 7대 원칙 중 “① 거버넌스 원칙”을 구체화

감독원 “금융분야 AI 위험관리 프레임워크(AI RMF)” (2026. 1. 26.) · II

III 금융분야 AI RMF의 주요 내용



※ (적용 방식) AI RMF는 법적 강제력이 없는 가이드라인 형태의 자발적 지침으로, 각 회사 사정*에 따라 강화·완화 또는 선택 적용 가능

* 규모, 인적·물적 자원, 영위 업무, AI 활용 범위·수준 및 기술 성숙도 등

1 AI 거버넌스

금융 AI	정성적 요소
7대 원칙 반영	① 거버넌스 ② 합법성 ③ 보조수단성

- ◆ 금융회사는 AI 위험관리 등을 위한 ^①의사결정기구 및 ^②전담조직을 구성하고, ^③관련 내규를 마련하는 등 거버넌스 체계를 구축
 - 명확한 책임소재를 바탕으로 ‘전제와 균형’ 하에 AI 시스템의 기획, 구축, 운영 전 단계에 걸친 잠재적 위험을 평가·관리

- (의사결정기구) AI 위험관리 등을 위한 의사결정기구(예: AI 윤리 위원회, AI 위험관리위원회)를 설치하여 AI 도입·활용에 적극 관여*

* AI 윤리원칙 등 AI 관련 내규 제·개정, 위험관리·소비자보호정책 수립, 고위험 AI 서비스 승인 등 AI 관련 중요사항을 심의·의결

- 특히, 위원장은 CEO가 AI와 관련된 사업계획, 전략, 위험 등을 명확히 인식할 수 있도록 CEO에게 정기적으로 보고*


* 7대 원칙 ① 거버넌스 원칙 최고경영자를 포함한 경영진은 AI 개발·활용에 대한 관심을 갖고 역할과 책임을 분담해야 함

- ※ 책무구조도를 도입한 금융회사는 AI 관련 내부통제 및 위험관리 등에 관한 책무를 반영하여 AI 도입·활용에 따른 책임소재를 명확화하는 방안을 고려

- (위험관리 전담 조직) AI 도입·개발 추진 조직과 독립된 위험관리 전담 조직을 설치하여 AI 관련 업무 전반을 통제·관리

- AI 위험의 인식·측정·평가 등 위험관리 전반을 통괄하고, 「AI 기본법」 등 관련 법규상 각종 의무의 준수 여부를 관리·감독

예시 AI 거버넌스 체계 구성



- ※ 회사의 규모, 자원, 영위업무, AI 활용 범위 등을 고려하여 조직을 구성하되, 이해상충 방지를 위한 독립성 확보 방안을 수립할 필요

- (내규) AI 윤리기준을 근간으로 AI 위험관리규정 및 지침 등 AI 관련 내규*를 수립하고, 세부적인 업무매뉴얼을 마련

* AI 거버넌스 구조, 위험의 인식·측정·관리, 고위험 AI 통제, AI 시스템 기획·개발·운영·활용 절차, 보안 업무, 소비자보호 업무, 관련 법규 위반 시 처리 등을 포함

- 특히, 금융 및 AI 관련 법규 준수 의무*를 부과하고, 최종 의사 결정 책임을 임직원이 지도록 내규화**

* 7대 원칙 ② 합법성 원칙 AI 활용 전 단계에서 금융·AI 등 관련 법규를 준수해야 함

** 7대 원칙 ③ 보조수단성 원칙 현 단계에서 AI는 업무의 보조 수단이므로 최종 의사 결정과 그에 따른 책임은 임직원이 수행함

- 한편, 표준화된 매뉴얼을 통해 AI 도입·활용 전 프로세스를 관리하고, 부서간 역할 및 책임을 명확화하여 잠재 위험에 대응

예시 AI 관련 내규 체계



감독원 “금융분야 AI 위험관리 프레임워크(AI RMF)” (2026. 1. 26.) · III

2

AI 위험평가

금융 AI

정량적 요소

7대 원칙 반영② 합법성④ 신뢰성⑥ 신의성실⑦ 보안성

◆ 금융회사는 AI 위험의 체계적인 인식·측정·관리 등을 위해서 위험기반 접근방법(Risk-based approach)의 종합 평가체계를 구성*

* 단, 규칙 기반 접근방법(Rule-based approach) 등 금융회사의 AI 도입 범위, 규모, 인력 등 자체 실정에 맞는 위험등급 분류도 허용

□ (평가체계) “금융 AI 7대 원칙” 중 정량적 요소를 토대로 위험평가 체계를 설계하고, 원칙 준수를 위한 기본요소를 평가 항목 등에 반영*

* 7대 원칙 ② 합법성 원칙 AI 활용 전 단계에서 금융AI 등 관련 법규를 준수해야 함

7대 원칙 ④ 신뢰성 원칙 AI 개발 과정에서 신뢰할 수 있는 데이터와 모델을 사용해야 함

7대 원칙 ⑥ 신의성실의 원칙 AI 활용 시 금융소비자의 이익을 최우선으로 해야 함

7대 원칙 ⑦ 보안성 원칙 AI 활용 시 보안성 기준 및 점검·개선 체계를 마련해야 함

○ ① 위험 인식·측정 → ② 위험 경감 → ③ 잔여위험 평가 → ④ 위험등급 산정 등 종합적·체계적 평가를 통해 AI 서비스별 위험을 분류

예시 AI 서비스 위험평가 절차(세부 항목 조정 가능)

부문	① 위험 인식·측정	② 위험 경감	③ 잔여 위험	④ 위험등급 산정
합법성 원칙 (20%)	금융소비자보호법 위반 가능성	8 (4)	4	Σ 9
	AI기본법 위반 가능성	4 (3)	1	
	데이터 관련법 위반 가능성	4 (2)	2	
	개별 업권법 위반 가능성	4 (2)	2	
신뢰성 원칙 (30%)	품질	6 (4)	2	Σ 18
	편향성	6 (2)	4	
	공정성	6 (2)	4	
	설명가능성	6 (1)	5	
신의성실 원칙 (20%)	성능	6 (3)	3	Σ 10
	계약 권리 침해	6 (3)	3	
	책임 투명성	6 (3)	3	
	소비자 보호방안	8 (4)	4	
보안성 원칙 (30%)	보안	8 (3)	5	Σ 17
	안정성	8 (4)	4	
	위탁/관리	8 (3)	5	
	프라이버시	6 (3)	3	

위험 점수

75 상용 서비스 출시 재검토

50 고위험 서비스 추가 통제 및 관리 강화

25 중위험 서비스 기본 통제 및 관리 적용

저위험 서비스 통제 완화

총합 54점

- (고영향 AI) 법체계와 정합성 확보를 위해 「AI기본법」상 고영향 AI에 대해서는 위험점수에 따른 등급 분류와 관계없이 고위험 서비스로 분류
- * AI 기본법(§2 iv)은 고영향 AI의 예시로 '대출 심사' 등 개인의 권리·의무 관계에 중대한 영향을 미치는 판단 또는 평가를 포함

3

AI 위험통제

금융 AI

정성적 요소

7대 원칙 반영② 합법성⑤ 금융안정성

◆ 금융회사는 위험 수준별 차등화된 통제·관리를 수행하고, 초고위험 AI에 대해 출시 여부 재검토 등 위험통제를 위한 제반 절차 이행

□ (위험기반 통제) 위험평가 세부 절차를 따라 산출한 AI 서비스의 위험등급을 기준으로, 위험별로 차등화된 통제·관리 수행

예시 서비스 위험 수준에 따른 차등화된 통제·관리 수행방안

저위험: 통제 완화	기본 통제관리	고위험: 통제 강화
승인절차 및 작성 문서 등 축소	- 상품·서비스 출시 전 경감조치 검증 - 상품·서비스 운영단계 모니터링 기준 적용·보고 - 상품·서비스 위험 변경시 위험 수준 재평가 - AI 세부 업무 방법에 따른 관리 (AI 위험관리 업무매뉴얼, 검증매뉴얼 등)	- AI윤리위원회 사전 승인/사후 검증 - 제3자에 의한 평가검증 - 운영 단계 모니터링 강화

□ (초고위험 AI 출시 재검토) 초고위험* AI 시스템 등에 대해서는 AI 의사결정기구를 통해 출시 여부를 재검토

* 금융안정성 훼손 또는 소비자 권익 침해 우려가 있다고 AI 의사결정기구가 판단하는 경우 등

□ (제반 내부통제 절차 이행) 모니터링·사후관리, 문서화 및 교육, 감독당국 정보공유 등 위험통제를 위한 제반 절차 이행

IV 향후 계획

- 금융감독원은 업권별 협회* 등을 통해 금융권에 AI RMF(안)을 배포하고, 설명회·간담회 등을 통해 충분한 의견수렴을 거친 후 금년 1분기 중 최종안을 확정·시행할 예정

* '26.1.16.(금)부터 금융권 AI 플랫폼(<https://finai.kcredit.or.kr>)의 공지사항 메뉴를 통해서도 확인 가능

- 아울러, 모범사례 전파, 도입회사 실태점검 등을 통해 AI RMF의 거버넌스, 위험관리 및 위험통제 프로세스가 금융회사의 내부통제 체계에 안착할 수 있도록 충실히 지원할 계획

금융위/감독원/협회, 금융분야 AI 개발활용 안내서 (2022)

- AI가 가장 많이 활용되는 5대 서비스별 체크리스트 형태로 구성: 신용평가 및 여신심사, 로보어드바이저, 챗봇, 맞춤형 추천, 이상거래탐지(FDS)
- 금융업권 및 기능·서비스별 특성을 고려하여 개발 활용 단계별 세부 안내서 마련: 기획·설계 → 개발 → 평가·검증 → 도입·운영·모니터링 등 각 단계별로 안내

체크리스트 다-2-1-A

불합리한 차별이 나타나지 않도록 공정성 판단기준을 설정하고 충족여부를 평가하고 개선하였는가?

체크리스트

- 1) 공정성 목표 수준 및 공정성 판단 지표를 선정, 관리하는가?
 - 학력, 성별, 연령, 종교 등 불합리한 차별이 발생 가능한 요소를 선정하고, AI 기반 신용평가·여신심사 평가 결과를 확인하여 상기 요소에 따른 불합리한 차별이 발생하고 있지 않은지 점검한다.
 - 공정성 목표 수준 및 공정성 판단 지표를 선정 및 관리하고 있는지 확인한다.

예시 데이터 샘플링을 통해 데이터 분포 검증을 수행하는지 확인
YES ☐ | NO ☐ | N/A ☐

- 2) 공정성 판단지표에 따라 불균형이 발견된 경우, 공정성을 개선시킬 기술적, 관리적 방안을 검토하여 조치하는가?
 - 편향방지 방법론을 활용하는 등 편향을 완화하기 위한 방안을 검토하였거나 조치하였는지 확인한다.

YES ☐ | NO ☐ | N/A ☐

준수사례 (예시)

- A은행은 AI를 적용한 신용평가모형의 결과를 확인하여 성별·학력·연령 등에 따른 차별이 있는지 확인한다. 다른 조건이 유사함에도 학력, 성별, 연령, 종교 등에 따라 신용등급이나 평점에 큰 폭(자체 등급 3단계 이상)의 차이가 있거나, 공정성 목표 수준 또는 판단기준에 미달되는 경우 모형의 수정을 검토한다.

체크리스트 다-3-1-A

AI 시스템이 학습한 모형이 상황에 맞게 설명 가능한지 확인하고, 설명가능성을 적법한(또는 합리적인) 수준으로 개선하고자 노력하였는가?

체크리스트

- 1) 고객에 대한 설명의무, 금융서비스의 위험 수준 등을 고려하여 고객 및 이해관계자 등 설명 대상자들에 대해 AI 시스템 설명가능성 수준을 평가할 수 있는 기준 및 절차가 수립되어 있는가?
 - 내부 규정, 업무매뉴얼 등에 설명가능성 수준에 대한 평가 기준 및 절차가 수립되어 있는지 확인한다.

예시 신용평점 또는 등급 산출결과에 따른 연체 이력, 소득 감소 등 주요 사유를 제공 여부 확인, 개별 샘플 리뷰를 통해 설명가능 인공지능 기술 등이 제공한 주요 사유로 AI 모형의 출력결과가 의미있게 설명되는지 여부 확인
YES ☐ | NO ☐ | N/A ☐
- 2) AI 시스템의 설명가능성이 기준이 적법한(또는 합리적인) 수준에 도달하지 못할 경우 개선 방안(재학습이나 알고리즘 수정 등)을 검토하여 조치하고 있는가?
 - 평가 기준에 도달하지 못했을 경우 수행했던 개선 방안 검토 및 조치 결과를 확인한다.

YES ☐ | NO ☐ | N/A ☐

준수사례 (예시)

- A은행은 AI 기반 여신심사 평가모형에 입력된 핵심 데이터들이 결과에 미친 영향력을 백분율(%)로 시각화하고, 증액된 소득을 입력하면 대출 승인으로 변경됨을 제시하는 등 설명가능한 방식을 도입하여 사용하고 있다.

금융위, AI기반 신용평가모형 검증체계 (2023)

① (데이터 관리) 신용평가에 활용하는 비금융·비정형 데이터에 대한 적절한 관리체계를 구축하였는지 점검합니다.

- 비금융·비정형 데이터를 신뢰성 높은 출처로부터 수집하고 데이터의 일관성·정확성* 등을 주기적으로 확인합니다.

* (예시) 개인사업자 매출 데이터가 전월 대비 10% 이상 변동시 동 매출 데이터 오류가능성 재점검

② (모형 선택) 다양한 AI 알고리즘의 특징과 장단점을 고려하여 신용평가에 최적화된 모형을 선택했는지 모형 선정 과정을 점검합니다.

- CB사는 다양한 알고리즘* 중에서 하나를 선택하거나 다양한 알고리즘 결과를 조합하여 모형을 개발하는 만큼, 알고리즘 선정 목적, 변수 선정 과정 등 모형 개발의 상세 과정을 확인합니다.

* AI 신용평가모형의 알고리즘은 크게 '신경망', '의사결정나무' 계열 등으로 구분되며, 다양한 세부 알고리즘이 존재

③ (설명 가능성) 금융소비자에게 신용평가모형 및 신용평가 결과 등을 충분히 설명할 수 있는지 확인합니다.

- CB사는 평가결과에 대한 설명의무*가 있는 만큼, 설명가능한 AI 기법의 적용 여부, 해당 기법을 통한 모형의 해석 가능성 등을 점검합니다.

* 개인은 신용평가 결과, 평가 기준, 평가에 이용되는 정보의 내용 등에 대하여 설명을 요구 가능(신용정보법 제36조의2)

④ (모형 성능) AI 방법론의 특성을 반영하여 모형의 변별력·안정성 등 통계적 유의성을 점검합니다.

- 과적합(overfitting*) 가능성 점검, 학습·검증·테스트 데이터의 유사성** 확인 등 AI 모형에 특화된 성능 확인 방법을 마련했습니다.

* 모형이 학습 데이터에 과도하게 의존하는 것을 의미 → 학습 데이터에 대해서는 정확한 예측을 제시하지만 미학습 데이터에 대해서는 부정확하게 예측할 우려

** 학습 데이터와 검증-테스트 데이터의 특성이 지나치게 다른 경우, AI 모형의 성능이 낮은 원인이 AI 모형의 문제인지 데이터 특성이 달라서인지 파악하기 곤란하여 모형 검증의 신뢰성이 낮아짐

금융보안원, 금융분야 AI 보안 가이드라인 (2023) · I

● 제3장 ●

AI 학습 데이터 및 모델 보안 관리

본 장에서는 보안 관점에서 AI 모델의 개발주기별로 AI 학습 데이터 및 모델을 안전하게 관리하는 방안에 대해서 안내한다.

- AI 모델 개발주기는 AI 모델 개발을 위해 데이터 수집부터 전처리·설계·학습·검증·테스트를 수행하는 과정이다.
 - 금융회사 등은 자체적으로 AI 모델 개발주기 별로 보안 점검항목을 개발하고 자체점검을 수행하여 AI 보안성을 높일 수 있다.

[AI 모델 개발주기 단계]

1 AI 학습 데이터 수집	- AI 모델 학습에 필요한 데이터 수집 단계 - 사내 내부 또는 외부 공개된 소스를 통한 데이터 수집
2 학습 데이터 전처리	- AI 모델에 적합한 형태로 변환하고 데이터 오염여부를 확인하는 단계 - 클리닝, 통합, 변환, 축소 등의 작업 수행
3 모델 설계·학습	- AI 모델을 설계하고 학습하는 단계 - 강건성 높도록 설계하는 것이 중요
4 모델 검증·테스트	- AI 모델의 성능 확인 및 테스트 단계 - 모델 입·출력값, 정보가 유출되지 않는 것이 중요

1 학습 데이터 수집

가. 개요

- 학습 데이터 수집은 AI 서비스에 활용할 데이터를 수집하는 단계로 금융회사 등의 내부 데이터 외에도 오픈소스 등 외부의 데이터를 활용하거나 인터넷 등을 통해 직접 수집하여 활용할 수 있다.
 - 외부에서 수집한 학습 데이터는 악의적인 정보 삽입 등의 데이터 오염 가능성을 주의하고, 데이터 정보를 관리해야 한다.
 - * 출처, 버전, 구축 시점, 메타정보 등

나. 보안 고려사항

- ① (신뢰할 수 있는 출처) 학습 데이터는 신뢰할 수 있는 출처로부터 수집하여 활용한다.
 - AI 모델은 학습 데이터의 특성에 따라 기능 및 성능이 결정되기 때문에 오염된 데이터를 학습하면 성능이 저하되거나 보안성 관련 문제가 발생할 수 있다.
 - 예를 들어 침입탐지시스템의 학습 데이터는 정상(Normal) 이벤트의 비중에 비해 비정상(Abnormal) 이벤트의 비중이 작다는 특징이 있다.
 - 학습 데이터가 이런 특징을 보이는 경우 비정상 이벤트의 분포 및 특성이 AI 모델 성능을 크게 좌우하여, 데이터가 약간만 오염되어도 서비스에 큰 영향을 끼칠 수 있다.
 - 또한, 단순 오류 등으로 인한 오류 값은 '데이터 전처리'를 통해 쉽게 발견할 수 있으나, 도메인 지식 기반의 정교한 데이터 변조는 발견이 어렵기 때문에 수집 단계부터 신뢰할 수 있는 데이터를 수집하는 것이 중요하다.
- ② (AI 학습 데이터 정보 관리) 출처, 버전, 구축 시점, 메타정보* 등 학습 데이터의 정보를 관리하도록 한다.
 - * 칼럼 정보, 데이터 타입(유형), 파일 포맷 등

금융보안원, 금융분야 AI 보안 가이드라인 (2023) · II

- AI 모델 개발·고도화 시에는 다양한 데이터를 학습하게 되며, 학습·운영 과정에서 오염된 데이터를 통한 공격*과 이로 인한 피해가 발생할 수 있다.
* [참고1] 데이터 오염 공격 참조
- 학습 데이터로 인해 발생한 보안 문제를 해결하기 위해서는 데이터에 대한 정보 관리가 필요하다.
- 학습 데이터를 수집한 출처와 시점, 수정 이력, 메타정보 등의 관리를 통해서 공격과 장애의 원인을 파악할 수 있다.

2 학습 데이터 전처리

가. 개요

■ 학습 데이터 전처리는 수집한 데이터를 AI 모델 입력이나 분석에 적합한 형태로 가공하는 단계이다.

- 전처리 과정을 통해 학습 데이터의 품질뿐 아니라 AI 모델의 보안성 개선도 가능하다.
- 데이터의 품질 및 보안성은 AI 모델의 성능과도 직접적으로 관련 있는 만큼, 학습 데이터 전처리 단계에서 데이터의 품질 및 보안성을 확보하는 것이 중요하다.

나. 보안 고려사항

㉠ (이상치 처리) 데이터 내에 불필요한 값을 제거하고 이상치를 검출하여 처리한다.

- 이상치 처리는 방식에 따라서 기계적 전처리와 의미적 전처리로 분류할 수 있다.
 - (기계적 전처리) 데이터의 통계치를 기반으로 데이터를 변환하거나 데이터 증강 등의 기법을 통해서 데이터 품질을 확보한다.
 - (의미적 전처리) 데이터에 대한 도메인 지식을 바탕으로 변환*하여 데이터의 품질을 확보한다.
* 클러스터링, 레이블링, 특징 공학 등

㉡ (데이터 변조 확인) 학습 데이터의 전반적인 추이 또는 샘플링한 값을 분석하여 데이터 변조 여부를 확인한다.

- 레이블 변조 및 의미적인 개념의 변조는 이상치 검출 기법으로 데이터를 발견하기가 어렵기 때문에 보다 세밀한 분석이 필요하다.
- 데이터가 변조되면 데이터 중독 공격 등을 통해 AI 모델 자체가 손상될 수 있으므로 학습 데이터를 변조로부터 안전하게 보호해야 한다.

㉢ (적대적 예제 생성) 적대적 예제*를 생성하여 AI 모델의 학습 데이터에 포함·학습하여, AI 모델을 적대적 공격**으로부터 보호한다.

* AI 모델이 잘못된 예측을 하도록 의도적으로 변조한 데이터

** 적대적 예제를 활용하여 AI 모델이 잘못 판단하도록 조작하는 공격

- AI 모델은 회피 공격* 등의 적대적 공격에 취약하기 때문에 이를 탐지하는 방안을 고려해야 한다.

* [참고5] 회피 공격 참조

- 공격자는 AI 모델을 파악하기 위해 AI 모델의 입·출력*을 수집하는데 이러한 공격자의 행동 방식을 탐지에 참고할 수 있다.

- 적대적 공격은 화이트박스*와 블랙박스* 기반의 공격으로 분류한다.

- 화이트박스 공격은 모델의 아키텍처, 입·출력값, 가중치, 파라미터 등 모델에 대한 정보를 사전에 파악한 상태에서 적대적 예제를 생성한다.
- 블랙박스 공격은 무작위적으로 적대적 예제를 생성하는 방식으로 FGSM²⁾, Deepfool³⁾, JSMA⁴⁾, CW⁵⁾, BPDA⁶⁾ 등의 연구가 있다.

- 적대적 예제를 생성하여 학습*하는 것은 AI 모델의 강건성을 확보할 수 있는 방안으로써 적대적 공격을 사전에 예방한다.

* 일종의 데이터 증강(Data Augmentation) 방식으로 다량 데이터 학습으로 AI 모델의 강건성을 높일 수 있음

- 이미지 데이터의 경우 회전·패딩·필터 등의 방식으로 데이터를 변환해서 적대적 예제를 생성하고 학습할 수 있다.

㉣ (데이터 확장·학습) 재현 데이터* 등의 기법을 활용하여 확장한 데이터를 학습할 수 있다.

* 원본 데이터의 통계적 특성을 활용하거나 AI 기법 등을 이용하여 생성한 모의 데이터

- 확장한 데이터를 학습하는 방식을 통해 AI 모델의 강건성을 개선할 수 있다.

금융보안원, 금융분야 AI 보안 가이드라인 (2023) · III

3 AI 모델 설계·학습

가. 개요

■ AI 모델을 구성하고 데이터를 학습하여 AI 모델에 지능을 부여하는 단계를 말한다.

- 데이터가 가지고 있는 상관성이 학습을 통해 AI 모델에 반영된다.

■ AI 모델이 취약할 경우 공격자는 AI 서비스를 무력화하거나 모델을 복제할 수 있으므로 AI 모델의 보안성을 확보하는 것이 중요하다.

- 이를 위해서는 AI 설계 단계에서부터 강건성이 우수한 모델을 활용하고 보안 고려사항을 반영하여, 공격으로부터 안전하게 보호해야 한다.

나. 보안 고려사항

㉠ **(강건성 높은 모델 선정)** 공격자가 AI 모델에 대한 정보를 쉽게 유추하기 어렵고, 데이터에 대한 민감도가 상대적으로 낮은 모델을 선택한다.

- AI 모델의 구조 및 알고리즘이 단순한 경우 공격자는 상대적으로 쉽게 AI 모델에 대한 정보를 파악할 수 있다.

- 공격자는 AI 모델에 대한 정보를 파악하여, 모델 추출 공격, 모델 인버전 공격 등의 공격을 수행할 수 있다.

※ [참고3] 모델 추출 공격, [참고4] 모델 인버전 공격 참조

- AI 모델 설계 시 강건성이 상대적으로 높은 알고리즘을 적용하여 AI 모델 정보에 대한 보안성을 강화할 수 있다.

- 배깅(Bagging), 부스팅(Boosting) 등의 앙상블(Ensemble)*기법을 모델 설계에 적용하면 공격자가 모델을 유추하기 어려워진다.

- 로지스틱 회귀(Logistic Regression) 등 단순한 모델 설계보다는 DNN(Deep Neural Network) 방식 등과 같이 복잡한 방식의 설계가 회피 공격으로부터 상대적으로 안전하다.

※ '[참고5] 회피 공격' 참조

- 다만, AI 모델의 의사결정에 대한 설명이 필요한 경우 AI 모델의 구조가 복잡할수록 설명 가능성 확보가 어려울 수 있어 유의하여 설계해야 한다.

㉡ **(모델 튜닝)** AI 모델을 튜닝하여 적대적 공격과 모델 유추가 어렵게 모델의 강건성을 높인다.

- 모델 튜닝 시에 노이즈를 삽입하거나 매개변수 축소 등의 기법을 적용하여 적대적 공격으로부터 강건성을 확보할 수 있다.

• 회피 공격은 AI 모델의 경사도와 경계선을 찾아, AI 모델의 결정을 회피하는 방식을 사용하기 때문에 경사도를 마스킹하여 노출을 방지하면 공격을 어렵게 할 수 있다.¹⁾

• 또는 경사도 자체를 정규화하여 경사도에 대한 정보를 공격자가 유추하기 어렵게 한다.²⁾

㉢ **(신뢰성이 확보된 출처)** 사전학습 모델 활용 시에는 신뢰할 수 있는 출처로부터 받았는지 확인 후 활용한다.

- 방대한 데이터를 사전에 학습하여 생성하는 사전학습 모델은 알고리즘은 공개되어 있으나, 학습 데이터를 공개하는 경우는 거의 없다.

- 사전학습 모델이 학습한 데이터에 대한 신뢰성 보장이 어렵기 때문에 사용하기 전 사전학습 모델 출처의 신뢰성을 확인하는 것이 중요하다.

㉣ **(비잔티움 에러* 대처)** 연합학습 방식을 통해 학습을 진행할 경우는 비잔티움 에러를 방지할 방안을 마련한다.

* 클라이언트에서 중앙서버로 메시지를 전달할 때 일부 클라이언트가 오염된 메시지를 전달하여 발생하는 오류

- 연합학습 방식의 AI 시스템을 운영하는 경우 악의적인 클라이언트, 또는 전송 과정 중 변조 등으로 인해 오염된 메시지를 전달받을 수 있다.

- 비잔티움 에러 발생 시 AI 모델이 오염될 수 있으므로 연합학습 방식 사용 시 악성 클라이언트와 오염된 메시지를 탐지·배제할 방안이 필요하다.

- 비잔티움 에러를 완화하기 위해서 클라이언트로부터 학습되는 과정을 확인하거나 통계적인 기법을 확인하는 방법이 연구되고 있다.

- **(학습과정 확인을 통한 탐지³⁾)** 클라이언트로부터 중앙 서버의 AI 모델의 학습 정도가 변화되는 과정을 확인하여, 악성 클라이언트를 탐지한다.

금융보안원, 금융분야 AI 보안 가이드라인 (2023) · IV


4 AI 모델 검증·평가

가. 개요

■ 학습 후 AI 모델의 성능을 확인하기 위해서 검증 및 평가(테스트)를 시행하는 단계이다.

- **(모델 검증)** 학습이 완료된 모델을 검증하기 위한 단계로 학습 시에 이용된 데이터셋의 일부를 검증에 이용한다.
※ 홀드아웃 검증, K폴드 교차검증 등의 기법 활용 가능
- **(평가)** 학습과 검증 후에 모델의 최종 성능을 평가하기 위하여 테스트하는 단계로 학습·검증용 데이터셋과 별개의 평가 데이터셋을 준비해 평가에만 사용한다.

참고 AI 서비스 개발 시의 데이터셋 구분¹⁰⁾



나. 보안 고려사항

㉠ **(정보 관리)** 검증·테스트 시에 이용한 데이터셋, AI 모델 매개변수 등의 정보를 관리한다.

- AI 모델을 개발하는 데 있어, 투명성은 서비스의 품질 및 사고 대응에 도움이 되며, 보안 팀이나 개발자가 성능 저하 및 장애가 발생한 시기와 지점을 확인할 수 있다.

㉡ **(적대적 공격 테스트)** AI 모델을 대상으로 적대적 공격 등을 수행하여, 성능 수준을 평가한다.

- AI 모델 성능이 일정 수준 이하로 저하된다면, 적대적 예제를 다시 학습하거나 적대적 공격 탐지 기법 적용 등 강건성 확보 대책을 마련할 수 있다.

㉢ **(최종 출력값 확인)** 개인정보 등 민감한 정보가 이용자에게 출력되는지 확인한다.

- 민감한 정보가 출력되는 경우, 불특정 다수 또는 타인에게 노출이 되지 않도록 하는 방안을 마련한다.
※ AI 학습 데이터의 개인정보 활용과 관련된 상세한 사항은 개인정보보호법 및 인공지능(AI) 개인정보보호 자율점검표('21.5., 개인정보위) 참조

㉣ **(출력 횟수 제한)** AI 모델의 출력 횟수를 제한하여 모델의 정보 및 학습 데이터 유출을 어렵게 한다.

- 공격자는 AI 모델의 입·출력값을 기반으로 모델의 정보를 유추하고, 공격을 시도한다.
※ [참고3] 모델 추출 공격, [참고4] 모델 인버전 공격, [참고5] 회피 공격 참조
- 실제로 입·출력값 수집을 통해 아마존과 BigML의 유료 AI 모델을 99% 이상의 유사성으로 복제한 사례가 있다.¹¹⁾
- AI 모델 정보의 유출과 모델 복제를 막기 위해서는 입·출력 횟수와 시간을 제한하는 방법 등을 적용할 수 있다.
- 출력 횟수를 제한하는 경우 AI 모델이 사용되는 업무나 서비스 특성을 고려해 가급적 낮은 수준으로 정한다.
* (예시) 챗봇의 경우 1분에 10회 미만 등

㉤ **(신뢰 점수 제한)** 정확도, 신뢰 점수* 등을 공개하지 않거나 범주화 등 비식별하여 제공함으로써 학습 데이터 및 모델 관련 정보 노출을 최소화한다.

- AI 모델이 데이터를 얼마나 믿을 수 있는지에 대한 점수 척도
- 공격자가 출력 결과에 대한 정확성, 신뢰 점수 등 모델에 대한 정보를 획득하면 모델 복제를 더 쉽게 할 수 있다.
※ [참고3] 모델 추출 공격, [참고4] 모델 인버전 공격, [참고5] 회피 공격 참조
- 따라서, 모델에 대한 정보 노출을 최소한으로 제한하여 공격을 어렵게 할 필요가 있다.
※ 다만, AI 의사결정 과정에 대한 설명의무가 있는 경우 설명에 불필요한 정보의 제공을 최소화한다.

㉥ **(적대적 공격 탐지)** 적대적 공격을 탐지할 수 있는 기법을 적용한다.

- AI 모델은 적대적 공격에 취약할 수 있으며 공격이 발생하는 경우 차단 또는 재학습 등의 조치가 필요하므로 적대적 공격 탐지 방안을 고려해야 한다.
- 적대적 공격을 탐지하기 위한 기법으로는 노이즈 탐지¹²⁾, 입력데이터 인코딩¹³⁾, 중요도 맵 활용¹⁴⁾ 등이 있다.

금융위원회, “금융분야 망분리 개선 로드맵” (2024)

첫째, 금융회사 등의 생성형 AI 활용을 허용한다.

대부분의 생성형 AI가 클라우드 기반의 인터넷 환경에서 제공되는 반면, 국내 금융권은 인터넷 등 외부 통신 활용 제한 등으로 인해 생성형 AI 도입에 제약이 있는 상황이다.

이에, 샌드박스를 통해 인터넷 활용 제한 등에 대한 규제 특례를 허용한다. 이와 함께, 예상되는 리스크에 대한 보안대책을 조건으로 부과하고 금융감독원·금융보안원이 신청 기업별 보안 점검·컨설팅을 실시하는 등 충분한 안전장치를 마련할 계획이다.

둘째, 클라우드 기반의 응용 프로그램(SaaS) 이용 범위를 대폭 확대한다.



기존에는 문서관리, 인사관리 등 비중요 업무에 대해서만 SaaS 이용이 허용되고, 고객 개인신용정보를 처리할 수 없는 등 엄격한 샌드박스 부가조건이 부과되어 활용이 제한되었다.

이에, 보안관리, 고객관리(CRM) 등의 업무까지 이용 범위를 확대하고, 가명정보 처리 및 모바일 단말기에서의 SaaS 이용까지 허용하는 등 SaaS 활용도 제고할 예정이다. 마찬가지로, 규제 특례 확대에 따른 보안 우려에 대응하기 위해 보안대책을 마련하여 샌드박스 지정 조건으로 부과할 계획이다.

셋째, 금융회사 등의 연구·개발 환경을 개선한다.

‘22.11월 연구·개발 환경에서 인터넷을 자유롭게 활용할 수 있도록 한차례 규제가 개선되었으나, 연구·개발 환경의 물리적 분리 및 개인신용정보 활용 금지 등에 따라 고객별 특성·수요에 맞는 혁신적인 서비스 연구·개발에 제약이 크다는 지적이 지속 제기되었다.

이에, 「전자금융감독규정」을 개정하여 금융회사 등이 연구·개발 결과물을 보다 간편하게 이관할 수 있도록 물리적 제한을 완화하고, 가명정보 활용을 허용하는 등 혁신적인 금융상품을 개발할 수 있는 환경을 제공하고자 한다.



금융위, “금융권 생성형 AI 활용 지원 방안” (2024)

상용 AI

- 기업에서 **상업적**으로 제공하여 사용 **비용**이 발생하는 대규모 언어 모델
- 직접 설치가 어렵고 주로 **클라우드 기반**으로 제공되어 **보안환경에 제약**
- 대형 모델로 **성능이 높음**

GPT-4 HyperCLOVA


금융분야 망분리 개선 로드맵
(24.8.13)

오픈소스 AI

- 누구나 **무료**로 다운로드 받아 사용할 수 있도록 **공개**된 모델
- 금융회사 **내부 서버**에 직접 설치하여 **높은 보안환경** 구축 가능
- 모델 크기에 따라 **성능이 다양**

Llama 3 Grok EXAONE

금융권 AI 플랫폼



2026. 1. 20. 전자금융감독규정 시행세칙 개정안 사전예고

1. SaaS를 망분리 규제의 명시적 예외 사유로 규정

- 「클라우드컴퓨팅 발전 및 이용자보호에 관한 법률 시행령」 제3조제2호에 따른 “응용프로그램 등 소프트웨어를 사용하는 서비스(SaaS)”가 전자금융거래법 제21조 및 전자금융감독규정 제15조에 따른 망분리 규제를 적용받지 않도록 명시
- 이에 따라 금융회사는 원칙적으로 별도의 혁신금융서비스(규제 샌드박스) 지정을 거치지 않더라도, 일정 요건을 충족하는 SaaS를 내부 업무에 활용할 수 있는 제도적 기반을 확보
- 다만, 이용자의 고유식별정보 또는 개인신용정보를 처리하는 SaaS의 경우에는 개인정보 유출 위험 등을 고려하여 이번 망분리 예외 적용 대상에서 제외되었으며, 이러한 서비스에 대해서는 종전과 같이 엄격한 규제가 유지됨

2. 망분리 완화에 대응한 정보보호 통제체계의 구체화

- 전자금융감독규정 시행세칙 별표 7 ‘망분리 대체 정보보호통제’(이하 “별표 7”)를 통해 엄격한 정보보호통제장치 마련 의무화
 - ✓ 침해사고대응기관(금융보안원)의 평가결과 ‘충족’을 획득한 SaaS 이용 및 관련 서류의 최신성 유지
 - ✓ 접속 단말기(모바일 단말 포함)에 대한 보호대책 수립·적용
 - ✓ 접속 단말기 및 사용자 등록·관리, 안전한 인증 방식 적용, 최소 권한 부여 등 접근 제어 및 권한 관리
 - ✓ 중요정보 입력·처리·유출 여부에 대한 모니터링 및 통제
 - ✓ SaaS 내 데이터의 불필요한 공유·처리 방지
 - ✓ 허용된 SaaS를 제외한 외부 인터넷 접근통제
 - ✓ SaaS 이용을 위한 네트워크 구간에 대한 보호대책(암호화 등) 수립·적용
 - ✓ 접속·이용 행위에 대한 모니터링 및 로그 수집
 - ✓ 허용된 기능 외 추가 기능(제3자 앱, 플러그인 등)에 대한 접속·이용 통제
 - ✓ SaaS 정보보호 통제를 위한 상시 관리·체계 확보
- 금융회사는 위와 같은 정보보호통제 이행 여부를 반기에 1회 자체 평가하고, 그 결과를 정보보호위원회(위원장: CISO)에 보고



IV. 금융AI의 공정성·투명성

금융소비자 보호 법제상 차별금지


- 차별(discrimination) 금지 조항: 금융소비자보호법 제15조, 대부업법 제9조의8, 신용정보법 제22조의4 제2항 제1호, 제3호 등
 - 일정한 차별금지사유를 정하여 차별을 금지: 금소법 제15조의 경우 “성별 · 학력 · 장애 · 사회적 신분”
 - ✓ 학력이 적절? 감사원의 2012. 7. 23.자 신한은행 CSS 승인 관련 감사결과 ⇒ 2012. 1. 30. 은행연합회 “불합리한 차별행위 방지 모범규준” (2014. 11. 12. 폐지)
 - ✓ 직업 · 직종이 사회적 신분에 해당? 보험업감독업무시행세칙 제5-13조 [별표 14] 첨부 표준사업방법서가 긍정
 - ✓ 성별에 따른 보험료율 차등? 위 표준사업방법서가 허용
 - 신용위험, 보험위험률 등 merit를 무시하고 결과적 평등만 추구할 경우 역선택 초래, 건전성규제 정책목표에 역행
 - ✓ 그러나 차별적 대우(disparate treatment) 뿐 아니라 차별적 효과(disparate impact)도 포함된다고 보아야: 출력중심(output-centric) 접근이 불가피하나, 학력 등 merit적 요소의 경우 입력중심 접근도 병행 불가피
 - 공정취급(fair treatment)만 의미하는지, 아니면 공정접근(fair access)까지 보장하는 것인지? 즉, 차별금지가 포용금융(financial inclusion)까지 포괄하는가? (Dodd-Frank Act: Yes)
- 차등(differential pricing) 금지 조항: 금융투자업법 제58조 제2항, 보험업법 제129조 제3호, 여신전문금융업법 제18조의3 제1항, 온라인투자연계금융업법 제11조 제4항 등
 - 차별금지사유를 정하지 않고 차등을 금지
 - 실무상 일물일가주의까지는 아니고 차등을 상당히 허용하나, 금융AI와 관련해서는 탄력적 해석 필요

투입중심(input-centric) v. 출력중심(output centric)

- 법에서는 이를 각각 차별적 취급(disparate treatment), 차별적 효과(disparate impact)라 부름
- 대용변수(proxy) 문제 때문에 대체로 출력중심 접근이 이뤄져야 한다는 점에 대한 컨센서스는 이뤄지고 있음
(장애인차별금지법 제4조 제2호는 명문으로 출력중심 접근 표명)



여성




남성

그

그녀

정확성 지표(accuracy metrics) · I

		예측 (predicted; $\hat{y}$)	
		양성 (positive)	음성 (negative)
실제 (actual; y)	양성 (positive)	진양성 (TP; true positive)	위음성 (FN; false negative) = 1종 오류 (Type 1 error)
	음성 (negative)	위양성 (FP; false positive) = 2종 오류 (Type 2 error)	진음성 (TN; true negative)



		예측	
		+	-
실제	+	4	1
	-	2	3

정확성 지표(accuracy metrics) · II

		예측 (predicted; $\hat{y}$)	
		양성 (positive)	음성 (negative)
실제 (actual; y)	양성 (positive)	진양성 (TP; true positive)	위음성 (FN; false negative) = 1종 오류 (Type 1 error)
	음성 (negative)	위양성 (FP; false positive) = 2종 오류 (Type 2 error)	진음성 (TN; true negative)

위양성(FP; Type 2)의 예

- 코로나에 안 걸렸는데 확진(+)
- 자질도 없는데 합격(+)
- 죄가 없는데 유죄판결(+)

위음성(FN; Type 1)의 예

- 병에 걸렸는데 음성(-)
- 자질이 있는데 불합격(-)
- 죄가 있는데 무죄판결(-)

FP v. FN?

- 의학진단: 위음성(FN; Type 1)이 더 심각
- 채용심사/신용평가 등: (채용/대출적격을 양성이라고 보면) 차별금지 관점에서는 위음성(FN; Type 1)이 더 심각
- 형사사법: 위양성(FP; Type 2)이 더 심각


정확성 지표(accuracy metrics) · III

		예측 (predicted; $\hat{y}$)		
		양성 (positive)	음성 (negative)	→
실제 (actual; y)	양성 (positive)	진양성 (TP; true positive)	위음성 (FN; false negative) = 1종 오류 (Type 1 error)	Sensitivity = $\frac{TP}{TP+FN}$
	음성 (negative)	위양성 (FP; false positive) = 2종 오류 (Type 2 error)	진음성 (TN; true negative)	Specificity = $\frac{TN}{TN+FP}$

환자의 위음성(FN)을 최소화하거나 자질 있는 사람의 불합격을 최소화(기회균등 equal opportunity)하려면?

sensitivity (민감도) = recall (재현율) = true positive rate (TP rate; 진양성율)

$$Sensitivity = TP\ rate = \frac{TP}{TP + FN} = 1 - \frac{FN}{TP + FN} = 1 - FN\ rate$$



반대로 정상인(비환자)를 최대한 잘 가려내거나 자질 없는 사람의 합격을 최소화(예측균등 predictive equality)하려면?

specificity (특이도) = true negative rate (TN rate; 진음성율)

$$Specificity = TN\ rate = \frac{TN}{TN + FP} = 1 - \frac{FP}{TN + FP} = 1 - FP\ rate$$



정확성 지표(accuracy metrics) · IV

		예측 (predicted; $\hat{y}$)	
		양성 (positive)	음성 (negative)
실제 (actual; y)	양성 (positive)	진양성 (TP; true positive)	위음성 (FN; false negative) = 1종 오류 (Type 1 error)
	음성 (negative)	위양성 (FP; false positive) = 2종 오류 (Type 2 error)	진음성 (TN; true negative)
	↓	Precision = $\frac{TP}{TP+FP}$	NPV = $\frac{TN}{TN+FN}$

유죄판결 받은 사람이 억울한 사람인 경우(위양성; FP)나 (기업 입장에서) 뽑은 사람이 실제로는 엉망인 경우를 최소화하려면(예측동등 predictive parity)?


precision (정밀도) = positive predicted value (PPV; 양성예측치)

$$Precision = \frac{TP}{TP + FP} = 1 - \frac{FP}{TP + FP} = 1 - FD \text{ (false discovery) rate}$$

그 밖에...


negative predicted value (NPV; 음성예측치)

$$NPV = \frac{TN}{TN + FN} = 1 - \frac{FN}{TN + FN} = 1 - FO \text{ (false omission) rate}$$



공정성 지표 · I: 독립성(independence)

X를 Y로 분류함에 있어, A가 민감속성(성별, 인종, 성적 지향 등)이고, R이 분류모델의 예측(합격 여부 등)이라고 할 때, 만약 민감속성 A가 예측 R에 대해 **통계적으로 독립**이면, (R, A)는 **독립성** 충족



$$P(R = +|A = a) = P(R = +|A = b) \quad \forall a, b \in A$$

왼쪽 사례에서, 첫번째 예: 위 확률 모두 1/3
두번째 예: 위 확률 모두 2/3

직관적 설명: 성별 별로 합격 또는 불합격으로 분류될 확률 동일 (결과적 평등).


다음과 같은 다양한 명칭으로도 불림:

- 집단공정성(group fairness)
- 통계적 동등성(statistical parity)
- 인구통계적 동등성(demographic parity)

현실에서는 완화된 형태로 적용: 할당제(채용목표제), 가점제 등

공정성 지표 · II: 분리성(separation)

X를 Y로 분류함에 있어, A가 민감속성(성별, 인종, 성적 지향 등)이고, R이 분류모델의 예측(합격 여부 등)이라고 할 때, 만약 민감속성 A가 **주어진 Y 하에서** 예측 R에 대해 통계적으로 독립이면, (R, A, Y)는 **분리성** 충족



회색은 merit가 없는 사람들

$$P(R = +|Y = y, A = a) = P(R = +|Y = y, A = b) \quad \forall a, b \in A, y \in \{+, -\}$$

왼쪽 사례에서, 첫번째 예: $y = +$ 에 대해 모두 0.5, $y = -$ 에 대해 모두 0
두번째 예: $y = +$ 에 대해 모두 0.5, $y = -$ 에 대해 모두 0.5

직관적 설명: Merit가 같으면 성별 별로 합격 또는 불합격으로 분류될 확률 동일.


Accuracy 개념으로 설명: 양성의 recall (= sensitivity) 및 specificity 동일

다음과 같은 다양한 명칭으로도 불림:

- 승산비 균등화(equalized odds)
- 차등적 불리취급(disparate mistreatment)
- 조건부 절차 정확도 균등(conditional procedure accuracy equality)

공정성 지표 · III: 충분성(sufficiency)

X를 Y로 분류함에 있어, A가 민감속성(성별, 인종 등)이고, R이 분류모델의 예측(유무죄 등)이라고 할 때, 만약 민감속성 A가 **주어진 예측 R 하에서** Y에 대해 통계적으로 독립이면, (R, A, Y)는 **충분성** 충족



회색은 무죄 판결 받은 사람들

$$P(Y = + | R = r, A = a) = P(Y = + | R = r, A = b) \quad \forall a, b \in A, r \in \{+, -\}$$

왼쪽 사례: 첫번째의 경우, $r = +$ 에 대해 모두 0.5, $r = -$ 에 대해 모두 0
두번째의 경우, $r = +$ 에 대해 모두 0.5, $r = -$ 에 대해 모두 0.5

직관적 설명: 성별이 다른 두 사람이 모두 유죄 또는 무죄라면, 진짜 범인일 확률이 동일함

다음과 같은 다양한 명칭으로도 불림:



- 보정(calibration)
- 조건부 이용 정확도 균등(conditional use accuracy equality)

공정성 지표를 통한 학습된 모델의 교정

이미 훈련된 classifier 모델을 민감속성에 대한 공정성 제약(fairness constraint) 하에 재조정

- 장점: 어떤 종류의 black-box 분류기에 대해서도 적용 가능. 다시 훈련시킬 필요 없음. 훈련 절차에 관여할 수 없을 경우 사실상 유일한 방안.
- 단점: 후처리를 위해 개개인의 민감속성에 접근해야 함(개인정보 이슈)

특히 분리성(separation) 달성을 위한 후처리의 예: 그룹 a와 그룹 b가 동일한 recall (= sensitivity) 및 specificity




이 지점에서 양 그룹의 recall과 specificity가 일치하게 됨

이러한 후처리 외에도 전처리, 훈련 과정에서의 제약 설정 등 방법론이 모색되고 있음

공정성 지표의 한계

- 공정성 지표는 결국 관측(observation)에 의존: 인과성(causality)을 간과하게 되고, 올바른 개입(intervention) 방식을 도출하지 못할 수 있음
 - 예컨대 Simpson's paradox: 여러 그룹들에서 관측되는 트렌드가 하나로 모을 때 사라지는 현상



	Men		Women	
	Applicants	Admitted	Applicants	Admitted
Total	8442	44%	4321	35%

Department	Men		Women	
	Applicants	Admitted	Applicants	Admitted
A	825	62%	108	82%
B	560	63%	25	68%
C	325	37%	593	34%
D	417	33%	375	35%
E	191	28%	393	24%
F	373	6%	341	7%

1973년 U.C. Berkeley의 gender bias 관련 논란

법 적용 관련 시사점

- **정확(accurate)**하지 않은 모델로 분류함으로써 야기되는 차별의 경우 (특히 데이터 비가용성 등 제약이 없다면) 차별의 의도가 인정될 가능성: AI의 veil 뒤에 숨기 어려울 것임
- **간접차별(disparate impact)**을 차별로 인정하는 이상 (과거의 데이터에 비추어볼 때 정확하더라도) 공정성 제약(fairness constraint)을 설정하지 않은 결과 공정성 지표(fairness metrics) 달성에 실패한 분류모델에 따른 사람의 평가는 차별로 인정될 가능성
 - 일반적으로 상대적 평등 원칙 상 합리적 차별을 부정하는 독립성(independence)보다는 merit를 고려한 분리성(separation)과 충분성(sufficiency) 기준이 합리적
 - √ 분리성과 충분성의 동시의 만족이 불가능할 수 있으므로, 사안에 따른 보다 합당한 기준의 선택 필요:
합격/신용평가의 경우 분리성, 형사사법/Regtech의 경우 충분성 등
 - √ 다만, 결국은 무엇이 merit이고, 무엇이 민감속성(sensitive attribute)인지가 핵심인데, 규범적 판단의 문제로서 건건이 사회적 합의 필요
 - 단, 예외적으로 적극적 평등실현조치(affirmative action)에 있어서는 독립성 원칙을 근간으로 판단해야 할 수도
 - 현실에서는 칼같이 공정성 지표를 충족하기는 어려우므로 slack ϵ 의 규범적 범위 설정이 중요 (Four-Fifths Rule 등)

신용정보법상 자동화평가(제36조의2) · I

자동화평가 규제는 (1) 개인신용평가, (2) 신용공여, 대출, 대부계약, 연계대출, 신용카드/시설대여/할부금융 거래 등의 설정 및 유지 여부, 내용의 결정, (3) 이들 거래에 관한 계약의 청약 또는 승낙 여부의 결정에 한정



신용정보법상 자동화평가(제36조의2) · II

제36조의2(자동화평가 결과에 대한 설명 및 이의제기 등) ① 개인인 신용정보주체는 개인신용평가회사 및 대통령령으로 정하는 신용정보제공 · 이용자(이하 이 조에서 “개인신용평가회사등”이라 한다)에 대하여 다음 각 호의 사항을 설명하여 줄 것을 요구할 수 있다.

1. 다음 각 목의 행위에 자동화평가를 하는지 여부

가. 개인신용평가

나. 대통령령으로 정하는 금융거래의 설정 및 유지 여부, 내용의 결정(대통령령으로 정하는 신용정보제공 · 이용자에 한정한다)

다. 그 밖에 컴퓨터 등 정보처리장치로만 처리하면 개인신용정보 보호를 저해할 우려가 있는 경우로서 대통령령으로 정하는 행위

2. 자동화평가를 하는 경우 다음 각 목의 사항

가. 자동화평가의 **결과**

나. 자동화평가의 **주요 기준**

다. 자동화평가에 이용된 **기초정보**(이하 이 조에서 “기초정보”라 한다)의 개요

라. 그 밖에 가목부터 다목까지의 규정에서 정한 사항과 유사한 사항으로서 대통령령으로 정하는 사항

$$\hat{y} = \theta^T x \text{에서 } \hat{y} \text{ (“결과”), } \theta \text{ (“기준”), } x \text{ (“기초정보”)}$$

② 개인인 신용정보주체는 개인신용평가회사등에 대하여 다음 각 호의 행위를 할 수 있다.

1. 해당 신용정보주체에게 자동화평가 결과의 산출에 유리하다고 판단되는 정보의 제출

2. 자동화평가에 이용된 기초정보의 내용이 정확하지 아니하거나 최신의 정보가 아니라고 판단되는 경우 다음 각 목의 어느 하나에 해당하는 행위

가. 기초정보를 정정하거나 삭제할 것을 요구하는 행위

나. 자동화평가 결과를 다시 산출할 것을 요구하는 행위

③ 개인신용평가회사등은 다음 각 호의 어느 하나에 해당하는 경우에는 제1항 및 제2항에 따른 개인인 신용정보주체의 요구를 거절할 수 있다.

1. 이 법 또는 다른 법률에 특별한 규정이 있거나 법령상 의무를 준수하기 위하여 불가피한 경우

2. 해당 신용정보주체의 요구에 따르게 되면 금융거래 등 상거래관계의 설정 및 유지 등이 곤란한 경우

3. 그 밖에 제1호 및 제2호에서 정한 경우와 유사한 경우로서 대통령령으로 정하는 경우

④ 제1항 및 제2항에 따른 요구의 절차 및 방법, 제3항의 거절의 통지 및 그 밖에 필요한 사항은 대통령령으로 정한다.

신용정보법상 자동화평가(제36조의2) · III

시행령 제31조의2(개인신용평가 결과에 대한 설명 및 이의제기 등) ① 법 제36조의2제1항 각 호 외의 부분에서 “대통령령으로 정하는 신용정보제공 · 이용자”란 「금융위원회의 설치 등에 관한 법률」 제38조 각 호의 자를 말한다.

② 법 제36조의2제1항제1호나목에서 “대통령령으로 정하는 금융거래”란 다음 각 호의 거래를 말한다.

1. 법 제2조제1호의3가목1)부터 4)까지의 규정에 따른 거래
2. 그 밖에 제1호와 유사한 거래로서 금융위원회가 정하여 고시하는 거래

③ 법 제36조의2제1항제1호나목에서 “대통령령으로 정하는 신용정보제공 · 이용자”란 제1항에 따른 신용정보제공 · 이용자를 말한다.

④ 법 제36조의2제1항제1호다목에서 “대통령령으로 정하는 행위”란 제2항에 따른 거래에 관한 계약의 청약 또는 승낙 여부의 결정을 말한다.

⑤ 법 제36조의2제3항제3호에서 “대통령령으로 정하는 경우”란 다음 각 호의 어느 하나에 해당하는 경우를 말한다.

1. 개인인 신용정보주체가 정정 또는 삭제 요청한 내용이 사실과 다른 경우
2. 정당한 사유 없이 동일한 금융거래 등에 대해 3회 이상 반복적으로 법 제36조의2제1항 및 제2항에 따른 권리를 행사하는 경우

⑥ 개인인 신용정보주체는 서면, 전자우편, 인터넷 홈페이지 또는 어플리케이션 등을 통해 금융위원회가 정하여 고시하는 서식에 따라 법 제36조의2제1항 및 제2항에 따른 권리를 행사해야 한다.

⑦ 개인신용평가회사등은 법 제36조의2제1항 및 제2항에 따른 권리를 행사한 신용정보주체에게 설명 · 정정 · 삭제 등 필요조치를 하고 그 결과를 서면, 전자우편, 인터넷 홈페이지 또는 어플리케이션 등을 통해 금융위원회가 정하여 고시하는 서식에 따라 해당 신용정보주체에게 설명해야 한다.


⑧ 개인신용평가회사등은 개인인 신용정보주체에게 설명을 하는 경우 다음 각 호의 구분에 따라 설명해야 한다.

1. 법 제36조의2제1항제2호가목의 사항을 설명하는 경우: 개인인 신용정보주체의 별도 요청이 없으면 요구 시점에서 가장 최근에 실시한 자동화평가의 결과로서, 개인신용평가회사등이 자체적으로 정한 **신용등급 또는 점수**(백분율을 포함한다) 등으로 표시할 수 있다.
2. 법 제36조의2제1항제2호나목의 사항을 설명하는 경우: 자동화평가지 법 제2조제1호에서 정하고 있는 **신용정보의 종류별**(신용거래 판단정보, 신용도 판단정보, 신용거래능력 판단정보 등) **반영 비중**을 안내하거나 또는 각 금융권역 협회에서 마련한 양식에 따라 안내할 수 있다.
3. 법 제36조의2제1항제2호다목의 사항을 설명하는 경우: 설명을 요구한 개인인 신용정보주체 본인, 종합신용정보집중기관 및 개인신용평가회사등으로부터 금융회사 등이 직접 입수한 **신용정보**를 안내할 수 있다. 다만, 금융회사 등이 기초정보를 **자체적으로 가공하여 생성 또는 추론한 정보는 제외**할 수 있다.


⑨ 개인신용평가회사등은 법 제36조의2제3항에 따라 개인인 신용정보주체의 요구를 거절한 경우 거절의 근거 및 사유를 서면, 전자우편, 인터넷 홈페이지 또는 어플리케이션 등을 통해 안내해야 한다.

XAI와의 관계


국소설명(local explanation) 방식도 물론 사용 가능




ICE (individual conditional expectation)



LIME (local interpretable model-agnostic explanations)




Counterfactual explanations




Shapley Value


다만, 법상 신용정보의 종류별 반영 비중만 안내하면 되므로, 사전적인 전역설명(global explanation)도 가능



PDP (partial dependence plot)



Feature interaction



Functional decomposition

반사실적 설명(Counterfactual Explanations; CFE) · I

- CFE of a prediction = 예측을 사전 정의된 출력으로 변화시키기 위한 특성값의 가장 작은 변화(smallest change to the feature values that changes the prediction to a predefined output)


- Wachter et al. (2017)의 방법

$$L(x, x', y', \lambda) = \lambda \cdot (\hat{f}(x') - y')^2 + d(x, x')$$

$$d(x, x') = \sum_{j=1}^p \frac{|x_j - x'_j|}{MAD_j}$$

$$MAD_j = \text{median}_{i \in \{1, \dots, n\}} (|x_{i,j} - \text{median}_{l \in \{1, \dots, n\}} (x_{l,j})|)$$

$$\arg \min_{x'} \max_{\lambda} L(x, x', y', \lambda)$$



- Dandl et al. (2020)의 방법: Feature가 범주형일 때도 작동

$$L(x, x', y', X^{obs}) = (o_1(\hat{f}(x'), y'), o_2(x, x'), o_3(x, x'), o_4(x', X^{obs}))$$


o_1 : counterfactual 하 예측과 바람직한 예측 y' 간 거리(맨해튼 거리)

o_2 : counterfactual과 instance x 간 거리(Gower 거리)

o_3 : 변화된 특성값의 수

o_4 : counterfactual이 얼마나 현실성 있는 특성값 또는 조합인지 측정 (counterfactual과 가장 가까운 데이터 포인트 간 Gower 거리)

가중치를 두지 않고, 네 목표값을 적자생존 방식으로 동시에 최소화:
Nondominated Sorting Genetic Algorithm (NSGA)



반사실적 설명(Counterfactual Explanations; CFE) · II

- Dandle et al. (2020)의 예시

나이	성별	직업	주거	잔고	대출 금액	기간	목적	나이	성별	직업	대출 금액	기간	Predicted Prob
58	여성	미숙 련	자유	거의 없음	6143	48	차 량 구 입			숙련		-20	0.501
상환의 Predicted Prob = 24.2%										숙련		-24	0.525
										숙련		-22	0.513
								-6		숙련		-24	0.505
								-3		숙련		-24	0.515
								-1		숙련		-24	0.522
								-3	남성			-24	0.501
								-6	남성			-25	0.501
								-30	남성	숙련		-24	0.590
								-4	남성		-1254	-24	0.506

- 문제점: Predicted probabilities를 50% 이상으로 높일 복수의 방법이 가능할 수 있으며, 이 중 무엇을 설명해야 하는지 기준이 없음 (소위 “Rashomon effect” (Molnar 2020))

금융 에이전트와 금융 안정성

- Algo trade:

- ✓ 시스템 오류 주문실수 등 부주의의 증폭 : 2012 년 미국 Knight Capital 주문오류 사건 , 2010 년 미국 Flash Crash 사태 → 시장변동성 증폭
- ✓ 유사한 기법을 이용할 가능성이 높고 추세추종(trend following) 전략이 널리 사용 → 시장 쏠림 현상 야기
- ✓ 한국거래소 “시장감시위원회 알고리즘거래 위험관리 가이드라인” (2014): 시스템 설계/테스트, 리스크 관리(자체 주문한도 설정하고, 한도 초과시 주문거부 등), 거래 적용/사고대응/사후검증(특히 최초 가동시 유의사항), 전단처리서버(FEP) 통제 등
- ✓ 증권선물위원회, 2023. 1. 26. 시타델 증권에 국내에서의 고빈도 알고리즘 매매를 이용한 시장질서 교란행위를 이유로 118억 8천만원 과징금 부과(서울행정법원에서 행정소송 계속 중)
- ✓ 금융당국, 거래자 등록제(2023. 4. 25. 의무화), 시장감시 기준 운영, 시장감시 강화

- Robo-advisor:

- ✓ 자본시장법 시행령 제2조 제6호 “전자적 투자조언장치”로 법제화 ⇒ 투자 자문, 일임, 집합투자재산 형태
- ✓ 알고리즘의 불완전성/비정교함 , 위기 대처 능력 낮음으로 인한 부적합한 추천, 시장 과점에 따른 시세 조종/시장질서 교란행위 , 이해상충 방지의무 위반 등에 대한 보완 논의 중

금융AI를 통한 6대 판매규제 준수 (CompTech)

6대 판매 규제 주요 내용

① 적합성 원칙	고객정보를 파악하고 부적합한 상품은 권유 금지
② 적정성 원칙	고객이 청약한 상품이 부적합할 경우 사실 고지
③ 설명 의무	상품 권유 시 또는 소비자 요청 시 상품을 설명
④ 불공정 영업 금지	우월적 지위 이용한 소비자 권익 침해 금지
⑤ 부당권유 금지	불확실한 사항에 단정적 판단을 제공하는 행위 등
⑥ 광고 규제	광고 필수 포함사항 · 금지행위

- 고객상담 녹취 정보를 텍스트변환(Speech-to-Text; “STT”)한 후 자연어처리를 통해 분석함으로써 불완전판매 여부를 감지(detection)
- 소비자의 재산상황 · 구매목적 · 경험 등을 확인하여 적합성 · 적정성 여부를 분류하는 고객실사(KYC) 프로세스를 자동화
- 텍스트의 음성 변환(Text-to-Speech; “TTS”)을 통한 설명의무 이행
- 챗봇(chatbot) 등 대화형 에이전트(conversational agent)의 활용

Q&A