

KOSPI Downside-oriented State-Dependent Risk Indicator

상태추정모델 + ML 기반 금융시장 위험지표 개발

KOSPI 하방위험 정량화 및 투자전략·리스크관리 의사결정 지원

목차

02

문제의식에서 출발해 데이터, 모델링, 성능평가, 최종 후보, 활용 방안 순으로 설명

1 추진 배경 및 목표

추진 배경 · 연구 동향 · RI 정의 · 개발 프로세스

2 데이터 구축

입력 데이터 · Core/Extended

3 실험 설계 및 모델링

Rolling Window · 모델 후보군 · State+ML 결합

4 성능 평가 및 최종 결과

성능 평가 체계 · Benchmark · 최종 결과

5 활용 방안 및 향후 과제

활용 시나리오 · 운영 고도화

★ Appendix

연구·데이터·수식·성능지표 상세

1. 추진 배경 및 목표 (1/2)


투자전략 수립과 리스크관리에 활용 가능한 신뢰성 높은 정량 Risk Indicator가 필요

⚠ 기존 한계 및 추진 배경

- 로보어드바이저 Risk Indicator 한계
 - 당행 로보어드바이저 2025년 오픈
 - 단변량 Rule-based Risk Indicator 사용
 - 지표 신뢰도 한계로 담당자 정성 보정 후 활용
- 파편화된 리스크관리 체계
 - 금융투자상품 리스크관리, 위기관리 대책 시스템, 시장리스크 시스템 간의 구조적 단절 존재
- 구조적 한계점 극복 필요
 - 산술적 리스크 측정 중심
 - 금융 데이터 간 비선형 관계 반영 제한
 - 투자·리스크관리 의사결정용 통합지표 부재

★ 본 프로젝트 차별점 (State + ML)

- 관련 연구 동향 비교



- 다변량 금융·거시·신용·유동성 데이터 반영
- 시장 국면(State)을 설명하는 변수 중요도를 ML로 학습
- KOSPI 하방위험 중심으로 단일 점수화

1. 추진 배경 및 목표 (2/2)

현재 시장에 내재된 KOSPI 하방위험 압력을 0~100 점수로 정량화

🌐 Risk Indicator (0 ~ 100)




향후 수익률을 직접 예측하는 지표가 아니라,
현재 금융시장·거시경제·신용·유동성 환경에 내재된 KOSPI 하방위험 압력을
하나의 점수로 정량화하는 지표

📈 Downside-oriented

- 일반적인 변동성은 상승·하락 변동을 모두 위험으로 인식
- 투자전략·리스크관리 관점에서는 상승보다 하락 변동성 중요
- 손실압력, drawdown 압력, 신용·유동성 스트레스, 위험회피 심리 반영

🔄 전체 개발 프로세스



Data & Clean

입력 데이터 수집 휴일·결측·빈도 차이 보정

Features & Filter

파생변수 생성 및 필터링(정상성·중복성 확인 등)

State & ML RI

State Model 학습 및 ML 기반 RI 산출

Validate & Select

모델 검증 및 우수 모델 확인

2. 데이터 구축

한국은행 100대 경제지표 기반 국내외 데이터를 폭넓게 수집하고 모델 입력변수로 정제, 장기 안정성과 정보량 확대를 구분

☰ 데이터 수집, 전처리 및 변수 선별 프로세스

84종 → 68종 → 611개 → 239개
 원천 수집 유사변수 제거 파생변수 생성 최종 피쳐

• 데이터 수집

- 한국은행 100대 경제지표 기반 국내 거시·금융 대표성 확보
- 주요 금융위험 연구에서 활용되는 주식·채권·외환·신용·자금시장 변수 반영

• 전처리 및 변수 선별

- 중복성 검토: 상관관계 기반 유사 변수 제거
- 정상성 검토: ADF Test, KPSS Test
- 정상성·결측·중복성 기준을 거쳐 RI 산출에 적합한 변수로 정제

📄 Core / Extended Dataset 입력 데이터 선별

Core Dataset (장기 안정성 특화)

- 최종 입력 변수 수 : 193개 변수
- 시계열 기간 : 2001-01-02 ~ 2026-03-31
- 장기 변수 중심, 장기 안정성·운영 가능성 검증


Extended Dataset (정보량 극대화)

- 최종 입력 변수 수 : 239개 변수
- 시계열 기간 : 2008-01-02 ~ 2026-03-31
- 확장 변수 대부분 포함, 정보량 확대 효과 검증

3. 실험 설계 및 모델링 (1/2)

금융시장 구조 변화에 대응하기 위해 단일 Train/Test가 아닌 Rolling Window 방식으로 반복 검증

특정 구간에만 우연히 잘 맞는 모델이 아니라, 서로 다른 시장국면에서 반복적으로 안정적인 성능을 보이는 모델을 선별하기 위한 방식



? Rolling Window가 필요한 이유

- 금융시장은 시기별 위험 구조가 달라짐
- 2008 금융위기, 2020 코로나19, 2022 금리충격은 서로 다른 성격
- 단일 Test 구간은 이벤트 포함 여부에 따라 성능 왜곡 가능
- 실제 운영에서는 주기적 재학습 정책 검증 필요

🔄 최종 실험 구조

- State Model 재학습: 연 1회
- ML Model 재학습: 3개월마다
- Core 실험 구간: 60개
- Extended 실험 구간: 32개

3. 실험 설계 및 모델링 (2/2)

State-only 기준모델에서 출발해 ML 결합 효과와 KOSPI 하방위험 반영 효과를 단계적으로 검증

⚙ State + ML 결합 전략에 따른 모델 후보군

M0

State-Only

시장상태만으로 기준 RI 산출

State Model

- **HMM**: 잠재 상태를 확률적으로 추정
- **MSM**: 시계열의 상태 전환 구조 추정
- **Clustering**: 유사 시장상황을 군집화

State 수

- $k = 3, 4, 5$ 비교
- 낮은 위험 / 중간 위험 / 높은 위험 등
시장 상태를 몇 개로 나눌지 검토

M1

ML 기본 결합

State 설명 변수 중요도 반영

M2

KOSPI 하방 관련성

하방위험 관련 변수 강조

M3

하락구간 집중 학습

하락위험 구간을 더 중요하게 학습

M4

M2 + M3

관련성과 집중학습 동시 반영

ML Model

- Random Forest
- XGBoost
- LightGBM
- Transformer

State Model은 현재 시장국면을 구분하고, ML Model은 해당 State를 설명하는 변수 중요도를 학습

▶ 현재 State 정보 × State를 설명하는 변수 중요도 × 변수별 현재 위험점수 → EWMA 5D 안정화 → 0~100 Risk Indicator

4. 성능 평가 및 최종 결과 (1/4)

하방위험 식별력, 이벤트 탐지력, 지표 안정성, 운영성을 종합평가하고 Benchmark와 비교

≡ 성능 평가 체계

안정성	순위화	이벤트 탐지	M0 대비 개선	운영성
20%	30%	25%	15%	10%

평가영역	가중치	포함 지표	의 미
Technical Stability	20%	RI 변동성, turnover, 결측 여부, 범위 위반	지표가 안정적으로 산출되는지
Downside Ranking	30%	Spearman IC, Pearson IC, D10-D1 spread	RI 고위험 구간의 이후 관측 하방손실이 컸는지
Event Detection	25%	AUROC, AUPRC, Precision/Recall/Lift@Top10	RI 고위험 구간과 실제 이벤트 일치 정도
Incremental vs M0	15%	M0 대비 Spearman 개선도	ML 결합 후 기준모델 대비 개선 여부
Operational Score	10%	False alarm ratio, High risk ratio	과도한 경고 또는 비현실적 신호 여부

📊 Benchmark 비교

비교 목적

- 단순 손실을 또는 변동성 지표 대비 제안 모델이 종합적으로 우수한지 검증
- 운영 시 기존 단순 지표를 대체하거나 보완할 수 있는지 판단

Benchmark
최근 5일 KOSPI 하락률
최근 20일 KOSPI 하락률
KOSPI 20일 이동평균 대비 괴리율
KOSPI 20일 고점 대비 drawdown
KOSPI 20일 하방변동성
VKOSPI 수준
VKOSPI 20일 z-score
주요 단순 지표를 평균한 복합 벤치마크

4. 성능 평가 및 최종 결과 (2/4)

EWMA 5D로 안정화한 Transformer 기반 모델이 최종 우수 후보로 선정

✓ 최종 우수 모델

- Dataset: Extended
- RI 산출 방식: EWMA 5D 안정화
- 결합 방식: M3
- State Model: HMM
- State 수: k=3
- ML Model: Transformer


Consensus Score	5D Score	10D Score	20D Score
81.91	83.37	80.68	81.92
Avg Spearman	Avg AUPRC	Lift@Top10	Avg Turnover
0.0897	0.1327	1.6145	0.0517

💡 결과 해석

- 최종 1위 모델은 단기·중기 평가기간에서 모두 80점대 수준의 안정적인 성과
- HMM k=3 구조는 시장상태를 과도하게 세분화하지 않고 주요 국면을 안정적으로 구분
- Transformer는 시계열·비선형 패턴 반영에 강점
- M3 방식은 하방위험이 컸던 구간을 더 중요하게 학습해 위험국면 식별에 유리

4. 성능 평가 및 최종 결과 (3/4)

최종 선정된 RI는 주요 위험구간에서 상승하고 안정 구간에서는 낮아지는 패턴을 보임



- 코로나 충격, 금리충격, 최근 변동성 확대 구간에서 RI가 고위험 기준선에 근접하거나 상회
- 시장 불안·변동성 확대 구간과 RI 상승이 대체로 일관된 방향성
- 배경의 State 전환과 함께 RI 수준이 달라져 상태추정모델과 ML 결합 구조가 실제 시계열에 반영
- EWMA 5D 기반 RI는 일별 노이즈를 완화하면서도 고위험 국면을 식별하는 운영형 모니터링 지표로 활용 가능

4. 성능 평가 및 최종 결과 (4/4)

EWMA 5D 안정화 RI 후보군에서 Transformer와 k=3 State 구조가 상위권 성과를 주도

상위 후보군 주요 패턴

ML Model	Transformer	26
State <i>k</i>	<i>k</i> =3	17
State Model	HMM/Clustering	상위권
Combination Method	M1~M4	상위권

≠ Benchmark 비교 해석

- 단순 Benchmark는 일부 이벤트 탐지 지표에서 강점
- 최상위 Benchmark의 전체 순위는 State + ML 기반 최종 후보보다 낮음
- Benchmark는 최종 모델을 대체하기보다 비교 기준으로 유지

운영 후보군 분류 및 선정 이유

구 분	후 보	선정 이유
최종 1위 후보	Extended / EWMA 5D / M3 / HMM k=3 / Transformer	전체 1위, 단기/중기 균형 우수
평균 안정성 후보	EWMA 5D / Clustering / k=5 / Transformer	후보군 전체의 평균 성능과 안정성 우수
Core 기반 후보	Core / EWMA 5D / M2 / HMM k=3 / Transformer	장기 데이터 기반 운영 안정성 확인용
Benchmark	BM_MA_GAP_20D 등	단순 시장지표 대비 성능 비교 기준

5. 활용 방안 및 향후 과제

투자전략 수립과 시장 모니터링을 지원하는 정량 보조지표로 활용

주요 활용 시나리오

- **House View 작성 지원**
 - 월간 투자전략 수립 시 시장위험 판단 보조
 - 위험자산 비중 조정 논의 시 정량 근거
- **자산배분 의사결정 보조**
 - KOSPI 하방위험 상승 시 위험자산 축소·방어자산 확대 검토
 - 위험점수 변화 추이를 활용한 시장국면 판단
- **로보어드바이저 RI 고도화**
 - 기존 단변량 Rule-based RI 보완
 - 포트폴리오 리밸런싱 또는 위험경보 보조지표
- **시장 모니터링 및 리뷰**
 - 고위험 구간 조기 식별
 - 위기구간별 원인 분석 및 사후 리뷰

향후 과제

- 데이터 업데이트 체계 구축
- 재학습·검증 프로세스 정례화
- 설명가능성 분석 보강
- 업무 프로세스와 연계 및 서비스화 검토

본 프로젝트는 다변량 금융시장 데이터와 State + ML 구조를 활용해 KOSPI 하방위험을 정량화할 수 있음을 확인함.

향후 데이터 업데이트, 재학습, 설명가능성 체계를 보강하면 투자전략·자산배분·시장 모니터링에 활용 가능한 정량 지표로 확장 가능함.

SUPPLEMENTARY MATERIALS

Appendix

상세 근거 및 방법론

Appendix 1. 관련 연구 검토

금융위험 측정·탐지 분야의 ML 활용 연구 흐름을 참고하여 KOSPI 하방위험 RI를 설계

본 프로젝트와의 연결 시사점

- 기존 연구는 금융위기 조기경보, systemic risk 예측, 금융 stress 탐지를 중심으로 ML 활용 가능성을 제시
- 본 프로젝트는 이를 KOSPI 시장 하방위험 측정 문제에 적용
- 미래 수익률 예측이 아니라 현재 시장환경에 내재된 KOSPI 하방위험 압력을 0~100 점수로 정량화
- State Model과 ML을 결합해 시장국면 변화와 비선형 위험요인을 함께 반영

구 분	주요 연구	시사점
금융위기 조기경보	Machine learning as an early warning system to predict financial crisis, International Review of Financial Analysis, 2020	ML을 활용한 금융위기 조기경보 가능성
해석가능 ML	Predicting systemic financial risk with interpretable ML, The North American Journal of Economics and Finance, 2024	금융위험에서 설명가능성 중요
Systemic risk prediction	Systemic risk prediction using ML, International Review of Financial Analysis, 2024	위험 전이와 ML 예측 가능성
RNN 기반 위기에측	Predicting systemic financial crises with RNN, Journal of Financial Stability, 2020	시계열 기반 위기신호 포착
ML-enhanced measure	Machine-Learning-enhanced systemic risk measure, Journal of Banking & Finance, 2022	기존 위험측정 지표에 ML 결합
Review/Methodology	Machine Learning in Asset Pricing, PUP, 2021; ML methods for systemic risk analysis, 2019	자산가격·systemic risk 분야 ML 활용 확대

Appendix 2. 데이터 전처리

원천 데이터를 모델 학습에 적합한 일 단위 시계열 데이터로 정합화하고 최종 입력변수 선별

⚙ 데이터 검토 및 선별 프로세스

1

정합성 처리

휴일·결측치 처리
빈도 차이 보정
forward fill

2

파생변수 생성

수익률·변화율
누적수익률·MA 괴리
z-score·drawdown

3

정상성·품질 검토

ADF Test
KPSS Test
관측치·표준편차

4

변수 선별

상관관계 기반
중복 변수 제거
최종 239개

▼ 데이터 검토 및 선별 결과

구 분	변수 수
전체 파생변수	611개
정상성 양호	400개
경계 / 추가 확인	191개
비정상 가능성 큼	20개
최종 입력변수	239개
Core Dataset	193개
Extended Dataset	239개

거시경제 지표는 실제 발표시차가 존재하므로
look-ahead bias 가능성 검토 필요

Appendix 3-1. State + ML 실험 Variant 상세: 기본 기호 및 공통 구조

M0~M4는 기준선에서 출발해 ML 결합, KOSPI 관련성, 하락구간 집중학습 효과를 단계적으로 검증

√* 공통 RI 산출 수식 구조

공통 RI 산출 구조

- m은 M1~M4 중 하나를 의미
- 각 Variant는 변수 가중치 $w_{i,k}^{(m)}$ 정의 방식에 따라 구분
- M0는 ML 변수 중요도를 사용하지 않는 State-only 기준모델

$$RI_t^{(m)} = 100 \times F_t \left[\sum_k \gamma_{t,k}^{State} \sum_i w_{i,k}^{(m)} u_{i,t} \right]$$

M0. State Model only

- 현재 시장상태 확률 사용
- State별 하방위험 강도를 결합해 기본 RI 산출
- State + ML 모델과 비교하기 위한 기준선

$$RI_t^{M0} = 100 \times F_t \left[\sum_k \gamma_{t,k}^{State} D_k \right]$$

▣ 변수 설명

구성	역할
$\gamma_{t,k}^{State}$	현재 시점 t 가 State k 에 가까운 정도
$Imp_{i,k}^{State}$	State k 를 설명하는 변수 i 의 중요도
Rel_i^{KOSPI}	변수 i 가 KOSPI 하방위험과 관련된 정도
$u_{i,t}$	변수 i 의 현재 위험수준
$F_t[\cdot]$	산출값을 0~100 범위로 변환하는 scaling 함수
D_k	State k 의 하방위험 강도
A_t^{KOSPI}	시점 t 의 KOSPI 하방위험 강도 또는 고위험 구간 지표
λ	하방위험 구간 학습가중치의 민감도
$w_{i,k}^{(m)}$	Variant m 에서 사용하는 변수 i , State k 의 최종 가중치

Appendix 3-2. State + ML 실험 Variant 상세: M1~M4 수식

M1은 ML 결합, M2는 KOSPI 관련성, M3는 하락구간 집중학습, M4는 결합 효과를 검증

M1. ML-State Importance

- State 확률 또는 label을 학습
- State를 설명하는 변수 중요도 산출
- ML 결합 자체의 효과 확인

$$w_{i,k}^{M1} = Imp_{i,k}^{State}$$

$$RI_t^{M1} = 100 \times F_t \left[\sum_k \gamma_{t,k}^{State} \sum_i Imp_{i,k}^{State} u_{i,t} \right]$$

M2. KOSPI Downside Relevance

- M1 변수 중요도에 KOSPI 하락위험 관련성을 추가 반영
- State를 잘 설명하면서 KOSPI 하락위험 관련 높은 변수에 더 큰 비중

$$w_{i,k}^{M2} = Imp_{i,k}^{State} \times Rel_i^{KOSPI}$$

M3. High Downside Sample Weighted ML

- KOSPI 하락위험이 컸던 시점에 더 높은 학습가중치 부여
- 오차를 더 크게 반영해 ML 학습
- 학습 후 산출된 WeightedState 중요도를 활용

$$sample_weight_t = 1 + \lambda A_t^{KOSPI}$$

$$RI_t^{M3} = 100 \times F_t \left[\sum_k \gamma_{t,k}^{State} \sum_i Imp_{i,k}^{WeightedState} u_{i,t} \right]$$

M4. M2 + M3 결합 모델

- 하락구간을 중요하게 학습한 변수 중요도에 KOSPI 하락위험 관련성을 추가 반영
- 하락위험 구간과 관련 변수를 동시에 강조

$$w_{i,k}^{M4} = Imp_{i,k}^{WeightedState} \times Rel_i^{KOSPI}$$

Appendix 4. 성능지표 상세

최종 평가에 사용된 개별 지표의 의미

지 표	의 미
Spearman IC	RI 순위와 이후 관측된 하방손실 순위의 상관
Pearson IC	RI와 이후 관측된 하방손실 간 선형 상관
AUROC	하방위험 이벤트 구분 능력
AUPRC	불균형 이벤트 탐지 정밀도
Precision@Top10	RI 상위 10% 중 실제 이벤트 비율
Recall@Top10	전체 이벤트 중 RI 상위 10%가 포착한 비율
Lift@Top10	Top10 적중률이 전체 평균 대비 몇 배인지
D10-D1 loss spread	RI 고위험 구간과 저위험 구간의 이후 관측 손실 차이
False alarm ratio	고위험 신호 중 실제 이벤트가 아닌 비율
High risk ratio	전체 기간 중 고위험 신호 발생 비율

성능평가는 단순 적중률이 아니라, 위험순위 정렬 능력, 이벤트 탐지력, 경보 안정성, 실무 운용 가능성을 함께 평가함.

Q & A



감사합니다