

# FinHealth Score

은행·마이데이터 실제 활용을 위한 재무건강도 Scoring 및 예측 프로세스  
데이터 검증 과정, 모델·서비스 설계, 각 단계의 의사결정 근거를 중심 PoC

가계금융복지조사 2021-2025 · 5개년 패널 · 24,964가구 데이터 활용

# 0. 강의 내용 연계

본 프로젝트는 강의 내용을 활용하여, 추후 업무 진행 시 활용/참고할 수 있도록 설계하였습니다.

| 영역             | 프로젝트 내 적용 내용                    | 참고 강의자료                                               |
|----------------|---------------------------------|-------------------------------------------------------|
| 데이터 분할·일반화     | 가구 단위 train/test 분할, 과적합·일반화 개념 | 0424추가자료_lec00_introml (Intro to ML)                  |
| 변수 선정·회귀분석     | 5개 재무비율 선정, 로지스틱 회귀 베이스라인       | Lab 2.ipynb (Feature Selection, 회귀분석 실습)              |
| 최적화·하이퍼파라미터    | GroupKFold 기반 GB/로지스틱 튜닝        | lec02_optimization (Gradient Descent, Hyperparameter) |
| 정규화·검증 방법론     | 부트스트랩 신뢰구간, 시간기준 재평가            | lec03_regularization (Train/Test, Generalization)     |
| 시퀀스 모델(LSTM)   | 조기경보 모델 (2) — LSTM 실험           | lec05_RNN (RNN/LSTM 구조)                               |
| Transformer 비교 | 시퀀스 확장 실험 중 Transformer 적용      | lec06_transformer                                     |
| 성능 측정·평가지표     | AUC·PR-AUC·Lift, RAG 코칭 품질 관점   | lec10_MeasureAI (Measuring the Success of AI)         |

# 1. 프로젝트 배경 및 목적

AS-IS

은행은 재무 상태 악화 이후에 반응하는 구조 - 연체 발생 후에야 관리 대상화

WHAT- IF

t+1 시점 악화 가구를 문제 발생 전에 사전 식별 가능하다면 다양하게 활용 가능하지 않을까?

TO-BE

분석 → 예측 → 실행(직원 활용·마이데이터 서비스)으로 이어지는 파이프라인 전체 PoC 검증

## 2. 데이터 신뢰성 검증 및 표본 확장

가계금융복지조사(통계청·한국은행·금융감독원 공동), 2021-2025년 5개년 패널

5년 완주 검증

3,028가구

통계청 5년 로테이션 설계와  
실제 데이터 일치 확인

5년 완주 표본만 쓸 경우

3,189가구

표본(전이쌍) 12,405건

연속 2개년 이상 확장

24,964가구

표본(전이쌍) 53,756건 (4.3배)

### 왜 표본을 확장했나


표본을 4.3배 확대해도 지속률·이탈률 등 핵심 수치 차이 미미 - 스냅샷 모델(로지스틱·GB)엔 유리한 확장으로 판단해 안정적으로 채택

2020년·2025년 자료 비교 시 중복 가구 0건 - 조사에 명시된 5년 주기 표본 전면 교체 확인

# 3. 등급 산출과 타당성 검증

5개 지표 종합점수를 연도별 3등분(하위33% 취약·중간34% 보통·상위33% 건강)하여 등급 구성

## 등급 타당성 검증



[그림1/그림2] 등급 지표에 사용된 5개 지표 각각이 취약·보통·건강순으로 일관되게 갈리는지 확인 (구성 일관성 체크 - 지표간 상충 없음)


[그림3] 등급 계산에 미사용된 실제 연체율이 1분위 9.7%→10분위 0.05%까지 단조 감소 - 독립 검증

## 왜 3등분인가

그룹 간의 차이를 보여주면서 표본 크기를 확보하는 표준적 구간이라 판단 (5분위는 표본 부족, 2분위는 너무 단순하다 판단)

# 4. 등급 전이 분석

같은 가구의 등급이 해를 거듭하며 어떻게 바뀌는지 추적 - 자연 회복 대기는 매우 소수로, 선제적 개입의 정량적 근거 확인함




# 5(1) 로지스틱 베이스라인 설정 및 GradientBoosting 최적화

가구 단위 분할로 로지스틱 베이스라인(AUC 0.753)을 베이스라인으로 설정하고 선정한 GradientBoosting 최적화

## 로지스틱 계수

|        |           |        |        |        |
|--------|-----------|--------|--------|--------|
| 부채비율   | 저축자산_소득배율 | 금융자산비율 | 소비지출비율 | DSR    |
| +0.928 | -0.656    | -0.570 | +0.371 | +0.247 |

## GB 하이퍼파라미터 최적화 (GroupKFold)



튜닝 전(default) 0.7921

→ 튜닝 후(GroupKFold) 0.7970

가구 단위 교차검증으로 재탐색해 test AUC 개선


최적 조합: n=200, depth=3, lr=0.05

CV AUC 0.8027로 4개 조합 중 최고 성능

\* 부채·소비는 위험 신호, 저축·금융자산은 보호 신호, DSR은 유의하나 영향은 작음. 변수 선정은 FHN Methodology 4개 축 참고.

# 5(2) 모델 성능 비교 및 최종 선정

선정 기준 : 성능 · 설명가능성 · 서비스 적용 용이성



통계적 유의성

95% CI  
[+0.037, +0.052]

부트스트랩 재검증  
(0 포함안됨..우연 아님)

동일 표본 매칭

GB 0.798  
우위 유지

로지스틱 0.755 ·  
LSTM 0.787 대비  
(5,631건 매칭)

역할 분리

GB=선정  
로지스틱=설명

시퀀스 모델은  
짧은 패널로  
강점 제한 확인



## 6(1) 검증 요약

세 가지 핵심 질문에 대한 데이터 기반 답변

미래도 예측되는가?

**AUC 0.771**

과거(t년)→미래(t+1년) 예측 정확도  
무작위 분할 대비 오히려 상회

자기 자신을 예측하는 건 아닌가?

**AUC 0.748**

점수 계산 미사용 실제 연체 데이터로 재검증  
표본은 적으나(양성 277건) 참고 가능

실제 효용성이 있는가?

**사전 포착률 53.7%**

Recall(커버율) 기준

위험도(GB 기준) 상위 20%만 관리 시  
실제 위험 가구 중 53.7%를 미리 찾아냄  
(11p Lift 개념 참고)

\* 등급 자체가 "상대적 하위 1/3"이라는 구조적 한계 보유하여 다각도 검증 시도

# 6(2) 평가지표

관리 대상 비율별 Precision · Recall · Lift 지표. 불균형 데이터(양성 12%)에서 ROC-AUC 단독으로는 실무 효율 판단이 제한적 - 평가지표 복수 사용

## 모델 비교 (ROC-AUC는 5-2 참조)

| 모델               | PR-AUC | 상위10% Precision | 상위10% Recall |
|------------------|--------|-----------------|--------------|
| 로지스틱             | 0.284  | 34.0%           | 28.1%        |
| RandomForest     | 0.313  | 33.8%           | 28.0%        |
| GradientBoosting | 0.344  | 42.2%           | 35.0%        |

## GB 기준 운영 lift table - 관리 대상 규모별 실제 효율


| 상위 비율 | 대상자 수 | Precision | Recall(커버율) | 실제 포착 수 |
|-------|-------|-----------|-------------|---------|
| 5%    | 400   | 48.0%     | 19.9%       | 192건    |
| 10%   | 801   | 42.4%     | 35.2%       | 340건    |
| 20%   | 1,602 | 32.4%     | 53.7%       | 519건    |
| 30%   | 2,403 | 27.2%     | 67.5%       | 653건    |

base rate(전체 취약전략 비율) = 12.1% — 상위 10% Precision(42.2%)은 이 값의 약 3.5배

## [참고] Lift 20%의 의미


같은 100명 중 20명만 관리할 수 있다면, 무작위 선택과 모델 기반 선택의 차이는 이렇습니다.

무작위로 20명 선택



2 / 20명 적중

모델 기반 상위 20% 선택



7 / 20명 적중


● 실제 다음 해 위험고객(12명/100명) ○ 테두리 = 관리 대상으로 선택된 고객

모델 활용시 동일한 관리 자원(20명)으로 3.5배 더 많은 위험고객 포착

# 7. 추가 인사이트


메인 예측 모델과 별개로, 다음 8(1) 활용방안의 타겟팅 근거가 되는 데이터 패턴 3가지

## ① 부채×저축 - "곱하기"로 작동




부채없음×고저축 3.1 % → 고부채×저저축 32.6%, 약 10배 차이  
“부채는 있으나 저축여력 없음” 교집합 고객을 최우선순위로 분리해 정밀 타겟팅에 활용 가능

## ② 부동산 비중 — U자형



무주택 10.5%로 적정 보유(9.0%)보다 오히려 위험, 80% 초과는 17.1%까지 상승  
부동산은 “많을수록 안전”이 아닌 U자형 패턴

## ③ 회복은 실제 행동 변화



회복군 부채비율 변화 -0.133 vs 지속(고착)군 -0.014 : 원래 형편이 아닌 실제 행동 변화가 회복을 좌우 (RAG 코칭이 유도하는 목표 행동과 동일)

# 8(1) 은행 내부 활용방안

탐지는 검증(PoC) 완료, 실제 업무 활용 시 개입 효과검증 필수적

핵심: 하나의 위험도 모델로 손실 방지(리스크관리)와 마케팅 효율화, 두 업무를 동시에 지원 기대

## ① 은행 리스크 관리

보조지표 활용 및 인력 효율적 운영

### 검증된 것:

상위 20%(1,602명) 관리 시 위험가구 519명 사전 포착  
(정밀도 32.4%, 커버율 53.7%)

### 적용 논리:

포착된 519명 중 개입성공률 20~30% 가정 시 104~156건 부실 예방  
→ 업무 우선순위 보조지표로 활용

### 한계:

정확한 손익분기점은 은행 내부 데이터로 산정 필요

## ② 타겟 마케팅 효율화

마케팅/디마케팅 고객 선별을 통한 비용 절감

### 검증된 것:

(예) 고부채·저저축 교집합군 위험률 32.6%

### 적용 논리:

“추천 금지” 로직의 역발상 - 고객별 적합 상품 선별 마케팅

### 한계:


타겟팅 정밀도 향상 ≠ 반응을 개선 — A/B 테스트 확인 필요

정리: 위험 탐지는 검증 완료 — 총당금 절감·마케팅 반응을 개선 효과는 A/B 테스트로 추후 확인할 가설입니다.

# 8(2) 은행 내부 활용방안 - 직원 업무용 시스템 적용


은행 내부 업무

WINI 또는 BI 등 당행 실 시스템 적용 화면 예시 : 하나의 위험도 모델을 두 업무에 적용



## ① 부실 연락 우선순위 (여신 관리 등)

원인 설명 카드의 위험 기여도를 그대로 재사용



## ② 디마케팅 리스트 (마케팅 등)

“디마케팅 리스트” 캠페인 시스템에 연동




▶ [데모 보기](#)

은행 내부 업무 시스템 화면 예시 — 고객 앱과는 별도의 서비스입니다.

# 9(1) 마이데이터 활용방안

마이데이터 기관 연결을 통해 이 순환을 시작하여 마이데이터 고객 및 기관등록 수 확보, 서비스 신뢰도 향상



① 마이데이터 기관 연결로 실제 고객 데이터 확보

→ ② PoC 검증 방법론을 개인 단위로 세분화해 서비스 고도화


→ ③ 진단·코칭 정교화로 신뢰도·만족도 상승

→ ④ 이용자 증가에 따른 연결 데이터 확대

→ 다시 ① ... 선순환 기대

## 9(2) 마이데이터 서비스 제공

고객 서비스



### 1 원인 설명 카드

개인별 위험 기여도 계산 → 실행 가능한 재무지표로만 위험 사유 설명  
(나이·소득분위는 예측에는 반영하되 설명 사유에서는 제외하고 또래비교에만 사용)

### 2 상품 추천 및 추천 제외 활용

현 시점 권유 부적합 상품을 판단하는 고객보호형 필터. 부채·저축·DSR 규칙 재사용

### 3 RAG 기반 코칭

검수된 안내 문서 범위 내 답변으로 제한된 코칭 제공



▶ [데모 보기](#)

QR 스캔 또는 클릭 시 실시간 시연 화면으로 연결.



## 9(3) LLM · RAG 실제 구현

고객 서비스

프롬프트 설계 및 Claude API 연동 완료



```
def retrieve(query, top_k=2):
    sims = cosine_similarity(
        query_vec, kb_matrix)[0] # TF-IDF
    return [(KNOWLEDGE_BASE[i], sims[i])
            for i in top_idx]
```

```
prompt = f'''...
[내부 참고용 위험확률] {risk_prob*100:.1f}%
# 톤 결정에만 사용, 고객 비노출
```

반드시 지킬 것:

- 숫자는 [가구 지표] 제시값만 인용
- 위험확률 수치는 고객에게 절대 노출 안함
- 확정 예측 대신 "~할 가능성" 등 정성적 표현

```
'''
```

```
def call_claude(client, prompt_text):
    response = client.messages.create(
        model="claude-sonnet-5",
        max_tokens=300,
        messages=[{"role": "user",
                    "content": prompt_text}])
    return response.content[0].text
```

# 10. 실제 적용 시 운영 프로세스

MyData플랫폼부 내 본업지원 및 신규 서비스 활용 시

로그 추적 → 성능 저하 감지 시 재학습



# 결론 및 한계

## 결론

- GradientBoosting을 주 모델로, 로지스틱을 베이스(설명) 모델로 병행 - 성능과 설명가능성 동시 확보
- 시간 기준 재평가, 독립 타깃 검증, 부트스트랩 신뢰구간으로 검증
- 원인 설명 카드, 상품 금지 추천, RAG 기반 코칭으로 분석과 서비스를 화면 단위까지 연결
- 리스크관리·타겟 마케팅 등 은행 내부 업무 활용방안과 실제 직원 화면 예시까지 구체화
- 공공 통계 기반 검증 이후, 마이데이터 고객 데이터로 세분화 시 서비스 고도화 → 고객 유입 확대에 이어지는 선순환 기대

## 한계 및 아쉬운점

- 은행 내부 고객 데이터 활용이 불가하여 가계금융복지조사(전국 표본조사)활용하여 실제와 상이할 수 있어 재검증 필요
- 등급은 "상대적 하위 3분의 1" 기준 - 절대적 취약 여부와는 별개 개념으로 본업과의 협업으로 등급 재정의 가능
- LLM-as-Judge 개념 적용 못해봄